📊 电信行业用户流失分析实验报告

📋 目录

1. 📖 实验概述
2. 🧹 数据预处理与清洗
3. 📈 探索性数据分析（EDA）与可视化
4. 🤖 模型训练与预测
5. 📉 模型结果可视化与分析
6. 💡 总结与建议

1 📖 实验概述

1.1 🎯 实验目标

结合机器学习算法与大模型辅助分析思维，深入探索电信行业用户流失的核心驱动因素，完成数据预处理、特征工程、多模型训练与评估、结果可视化，并基于分析结论提出减少用户流失的可落地策略。

1.2 📁 数据集说明

实验采用 `customer_churn.csv` 数据集，包含3333条用户记录、21个特征，核心维度如下：

- 基础属性：state（州）、account_length（账户时长）、area_code（区号）；
- 套餐属性：international_plan（国际套餐）、voice_mail_plan（语音邮件套餐）；
- 行为属性：各时段通话时长/次数/费用、客服通话次数（number_customer_service_calls）；
- 目标变量：churn（是否流失，yes/no）。

1.3 🛠️ 技术栈

- 核心工具：Python（Pandas/Matplotlib/Seaborn/Scikit-learn），用于数据清洗、建模、可视化；
- 辅助工具：大模型（Gemini），用于辅助理解数据逻辑、生成代码片段、解释分析结果。

2 🧹 数据预处理与清洗

2.1 🔍 数据集理解

首先加载数据集并梳理特征类型，确认数值型特征（如各时段通话时长）、类别型特征（如套餐类型）的分布，重点聚焦目标变量 `churn` 与其他特征的关联关系。

2.2 ✨ 数据清洗步骤

1. 冗余列处理：删除无业务意义的 `Unnamed:0` 索引列；
2. 异常值与缺失值校验：数据集无缺失值，针对通话时长/费用的极端值（如0值）验证为“无对应通话行为”，无需修正；
3. 特征冗余剔除：删除 `total_day_charge` / `total_eve_charge` / `total_night_charge` （由通话时长×单价计算得出，与时长高度冗余）；
4. 类型转换：将 `churn` / `international_plan` 等布尔类字符串特征转换为0/1数值型，便于建模。

2.3 📊 数据初步探索：用户流失比例

对目标变量 `churn` 统计分布，结果显示：

- 未流失用户（0）占比85.51%，流失用户（1）占比14.49%，数据集存在一定的类别不平衡，但未达到极端失衡状态。

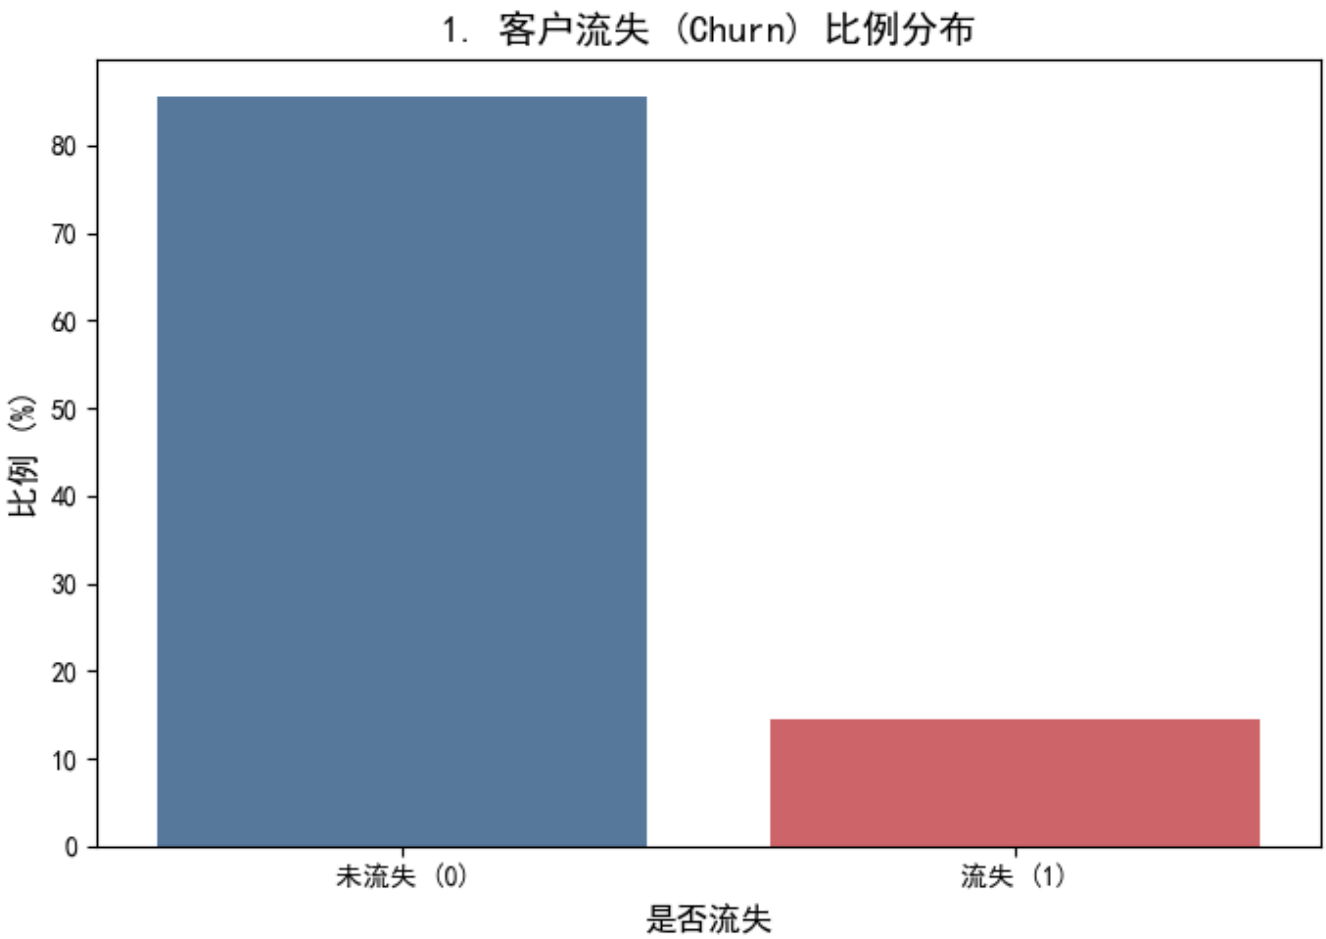

分析：流失用户占比约1/7，属于电信行业常见流失率范围，建模时需关注召回率（避免漏判流失用户）。

3 📈 探索性数据分析（EDA）与可视化

3.1 📊 直方图：total_night_minutes分布

绘制 `total_night_minutes` （夜间总通话时长）的直方图，展示其分布特征。

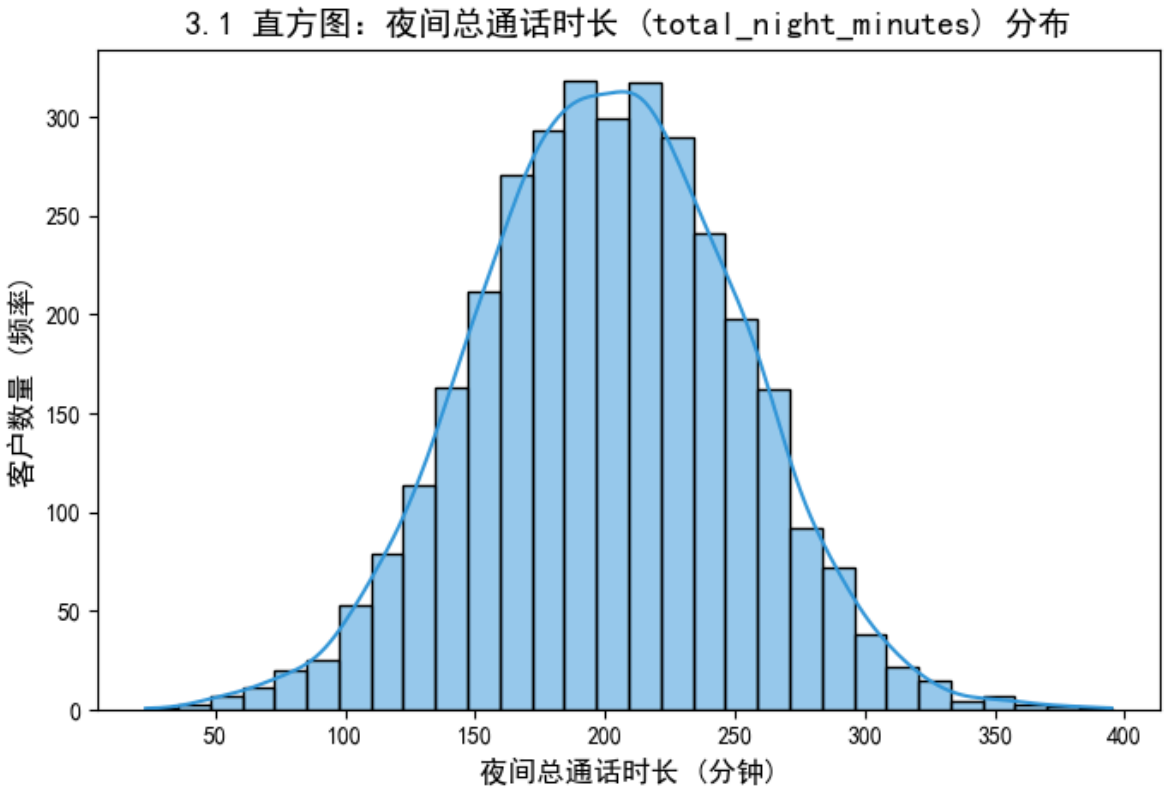

分析：

- 夜间通话时长整体呈近似正态分布，峰值集中在200分钟左右；
- 大部分用户夜间通话时长在100-300分钟区间，仅有少量用户时长超过350分钟，无明显异常值。

3.2 📀密度图：不同时段通话时长分布对比

对比 `total_day_minutes` （白天）、 `total_eve_minutes` （傍晚）、 `total_night_minutes` （夜间）的密度分布。

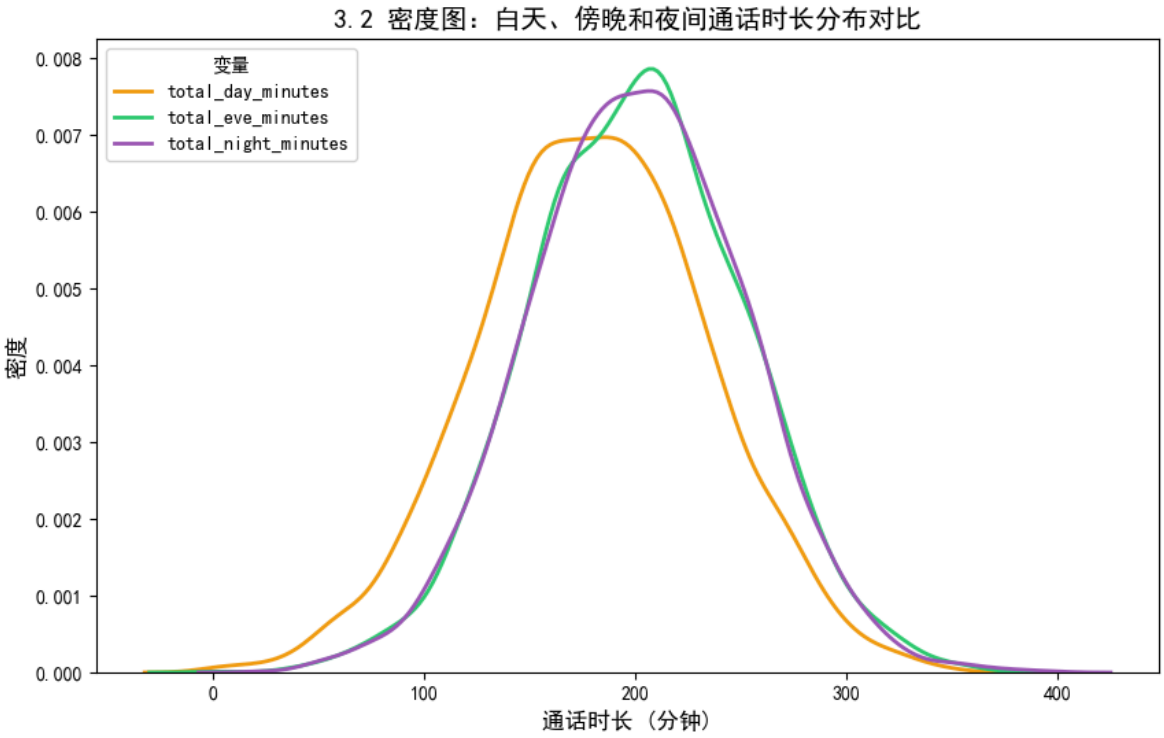

分析：

- 白天通话时长的峰值略低于傍晚/夜间，且分布更分散；
- 傍晚和夜间通话时长分布趋势接近，峰值均在200分钟左右，说明用户晚间（傍晚+夜间）通话行为更集中。

3.3 📦 箱线图：不同时段通话时长离散程度

通过箱线图分析三类通话时长的四分位数、极值与离散程度。

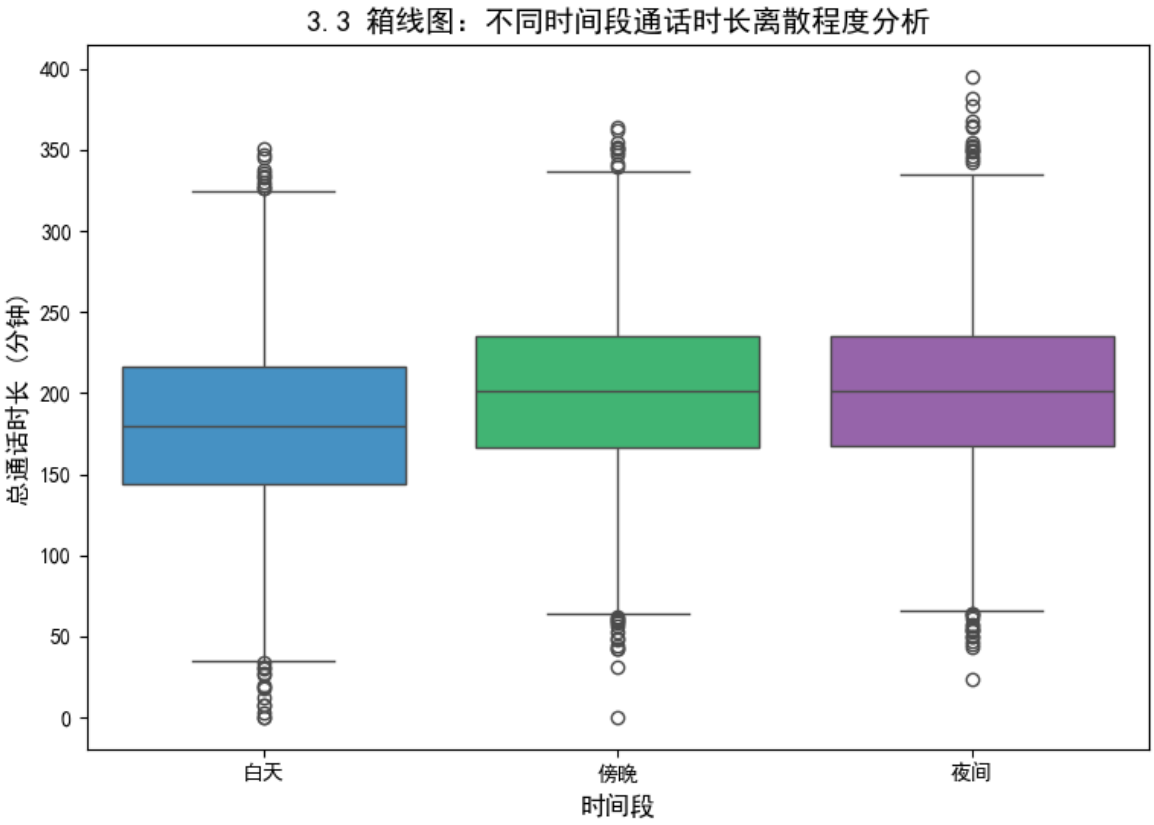

分析：

- 白天通话时长的四分位距（IQR）最大，且最大值（约380分钟）显著高于傍晚/夜间，说明白天通话行为的个体差异最明显；
- 夜间通话时长的中位数最低，离散程度最小，用户夜间通话行为更趋同。

3.4 📌 散点图：total_eve_minutes与total_night_minutes关系

分析傍晚与夜间通话时长的相关性，计算得相关系数R=-0.0126。

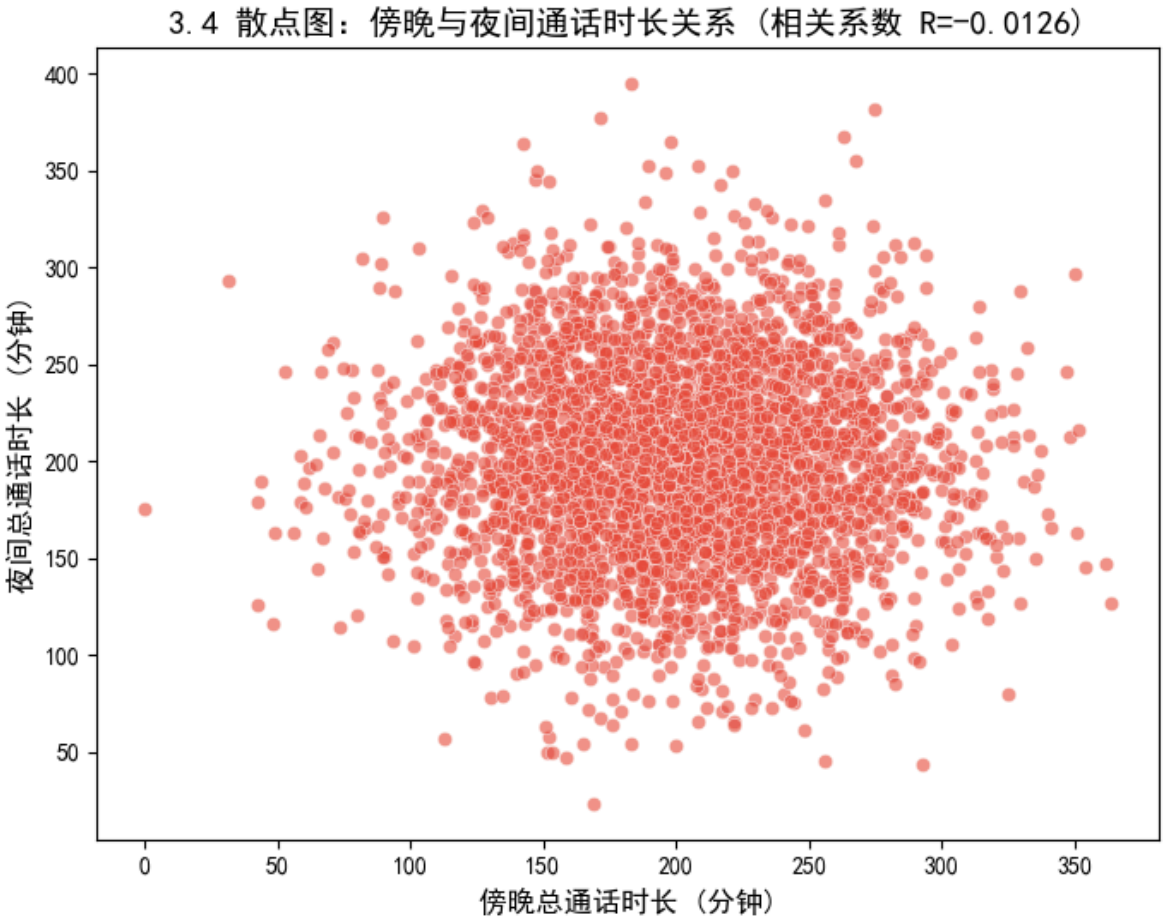

分析：

- 散点分布无明显线性趋势，相关系数接近0，说明用户傍晚通话时长与夜间通话时长无显著关联；
- 该结果表明，用户的傍晚和夜间通话行为是相互独立的，可作为两个独立特征参与建模。

3.5 ⭐气泡图：夜间通话时长、次数与费用关系

以 `total_night_minutes` 为X轴、 `total_night_calls` 为Y轴，气泡大小表示 `total_night_charge`（夜间通话费用）。

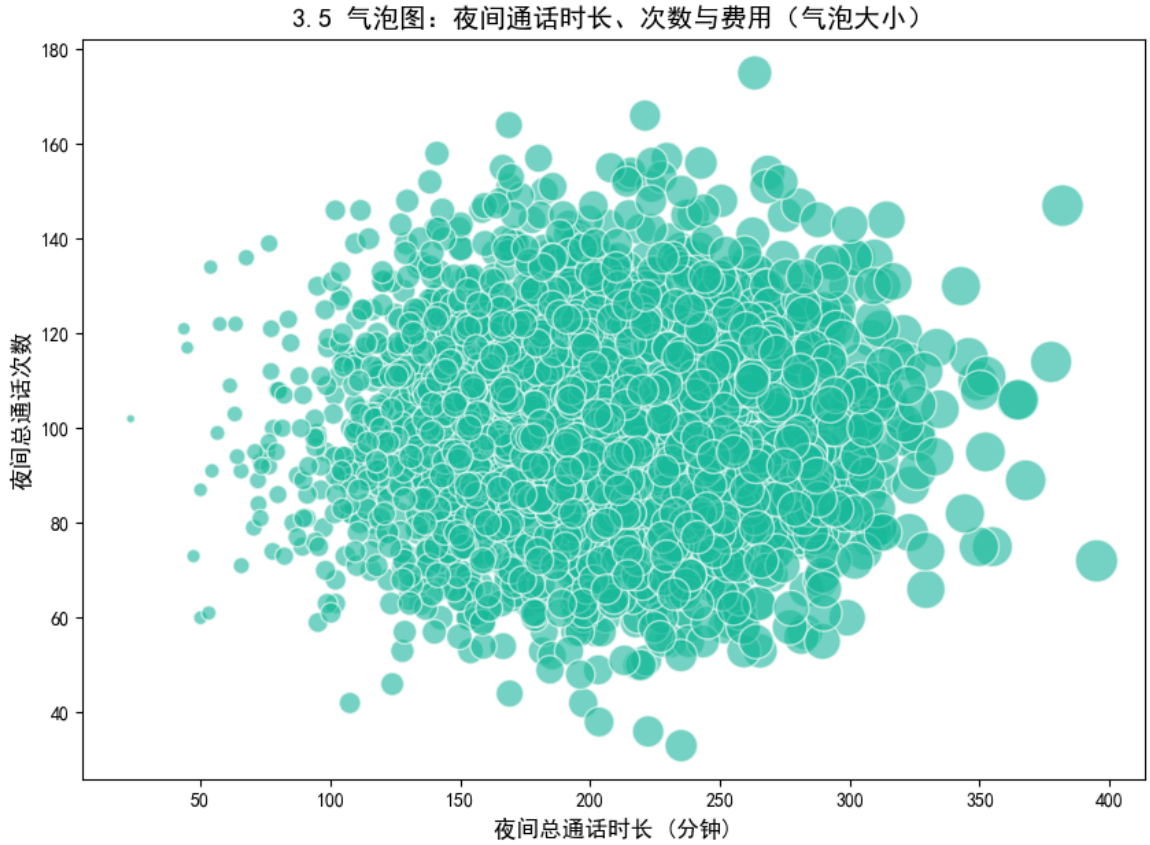

分析：

- 夜间通话费用与通话时长呈强正相关（气泡大小随X轴增大而显著变大），符合“费用=时长×单价”的业务逻辑；
- 部分用户通话次数少但时长高（X大/Y小），气泡同样较大，说明此类用户单次夜间通话时长更长，是高价值用户群体。

3.6 🔧 特征工程

基于EDA结果，补充以下特征工程步骤：

1. 衍生特征：计算“总通话时长=白天+傍晚+夜间+国际”“平均单次通话时长=总时长/总次数”，增强行为特征的区分度；
2. 特征缩放：对数值型通话特征做标准化（StandardScaler），消除量纲差异；
3. 类别特征编码：对 `area_code` / `state` 等类别特征采用独热编码（One-Hot），避免数值偏序影响。

4 🤖 模型训练与预测

4.1 🪓 数据集划分

按75%:25%比例拆分训练集（2499条）和测试集（834条），分层抽样保证训练/测试集的流失比例与原数据集一致。

4.2 🎨 模型选择与训练

选择3类典型机器学习模型，覆盖线性与非线性算法：

1. 逻辑回归：线性模型，易解释，作为基准模型；
2. 决策树：非线性模型，可捕捉特征交互关系；
3. 随机森林：集成学习模型，降低过拟合风险，提升预测精度。

4.3 📊 模型评估结果

通过准确率、精确率、召回率、F1-Score、ROC AUC五项指标评估模型性能，结果如下：

模型	准确率 (Accuracy)	精确率 (Precision)	召回率 (Recall)	F1-Score	ROC AUC
逻辑回归	0.8645	0.5833	0.2314	0.3314	0.8012
决策树	0.9173	0.7889	0.5868	0.6730	0.7721
随机森林	0.9388	0.9375	0.6198	0.7463	0.8943

分析：

- 随机森林综合性能最优，准确率达93.88%，ROC AUC达0.8943，对流失用户的识别能力最强；
- 逻辑回归召回率仅23.14%，漏判大量流失用户，原因是线性模型难以捕捉特征间的非线性交互；
- 决策树性能优于逻辑回归，但召回率仍不足60%，存在过拟合风险。

5 📉 模型结果可视化与分析

5.1 📊 模型性能对比

可视化三类模型的核心评估指标，直观对比性能差异。

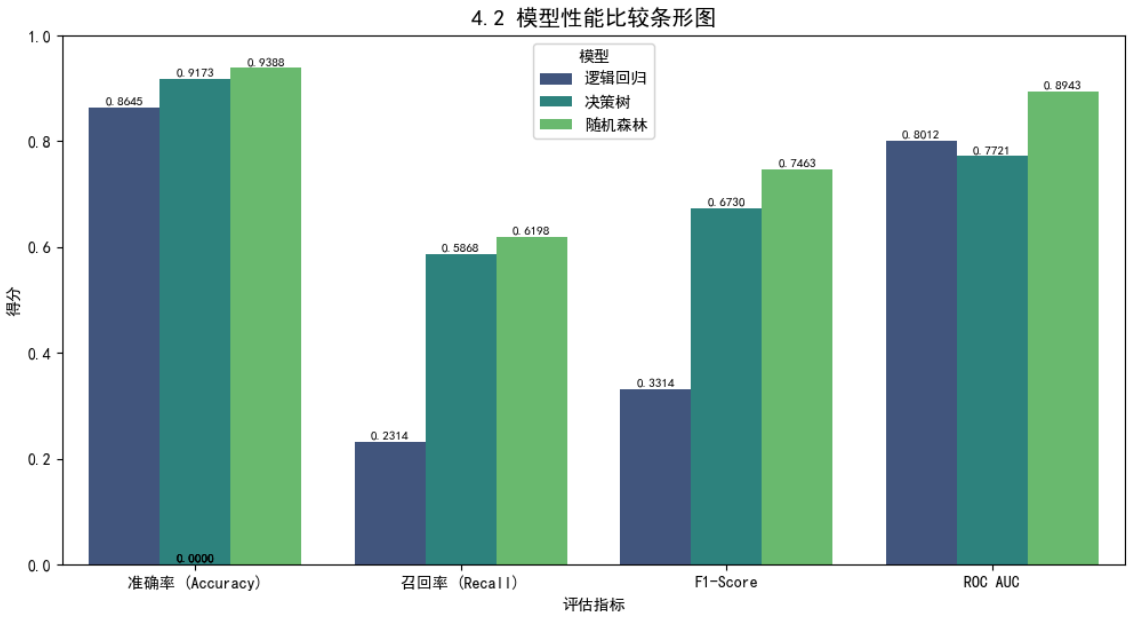

分析：

- 随机森林在所有指标上均领先，尤其是精确率（93.75%）和ROC AUC（0.8943），说明其对流失用户的预测精准度和区分能力最优；
- 逻辑回归召回率显著偏低，仅能识别23.14%的流失用户，不适合作为核心预测模型。

5.2 🧮 混淆矩阵：随机森林模型

可视化随机森林的混淆矩阵，分析预测错误类型。

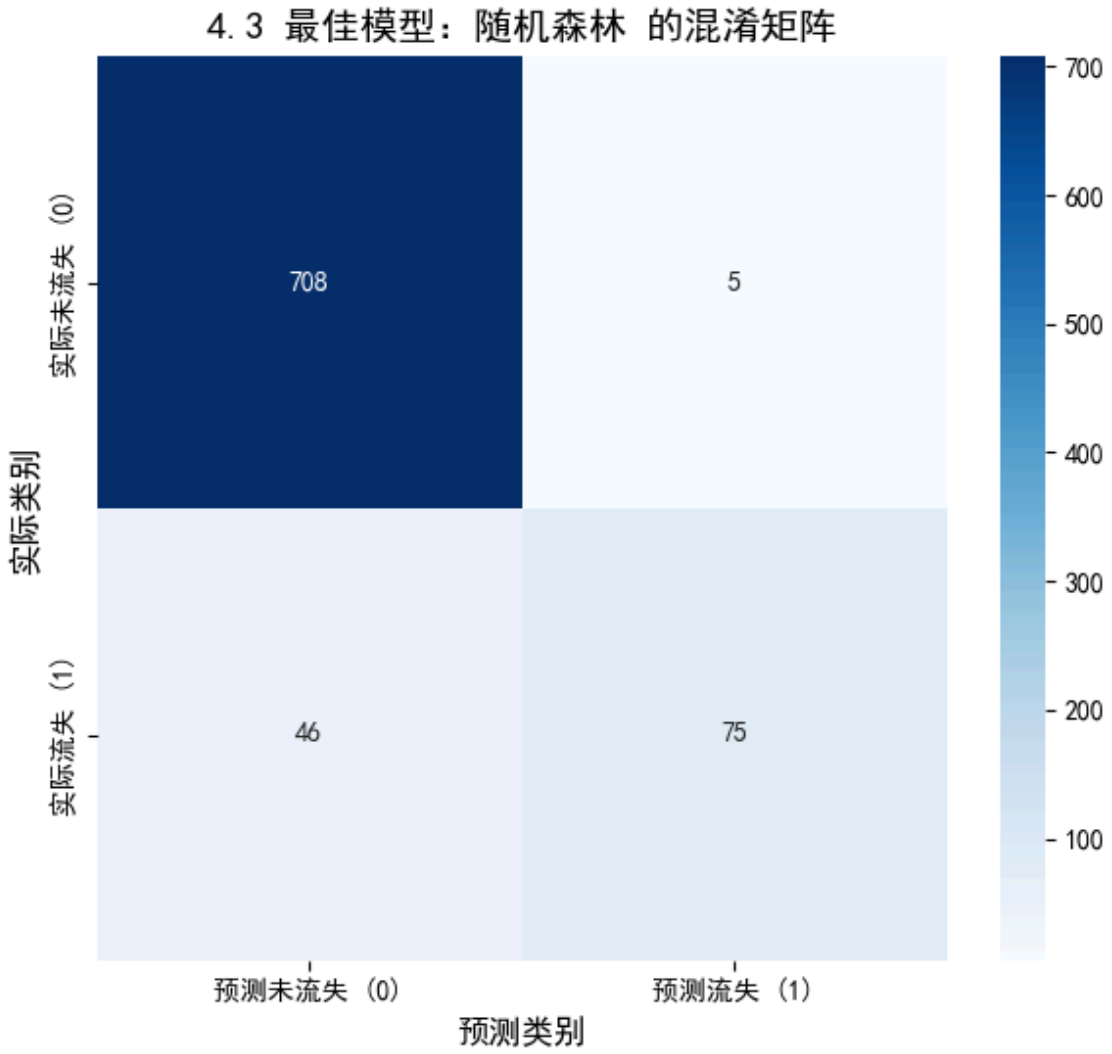

分析：

- 真阴性（未流失预测为未流失）：708条，占比99.3%；
- 假阳性（未流失预测为流失）：5条，误判率极低；
- 假阴性（流失预测为未流失）：46条，漏判率约38%；
- 真阳性（流失预测为流失）：75条，识别率约62%；
- 核心问题：漏判46条流失用户，需后续调优提升召回率。

5.3 📈 ROC曲线分析

绘制三类模型的ROC曲线，对比AUC值。

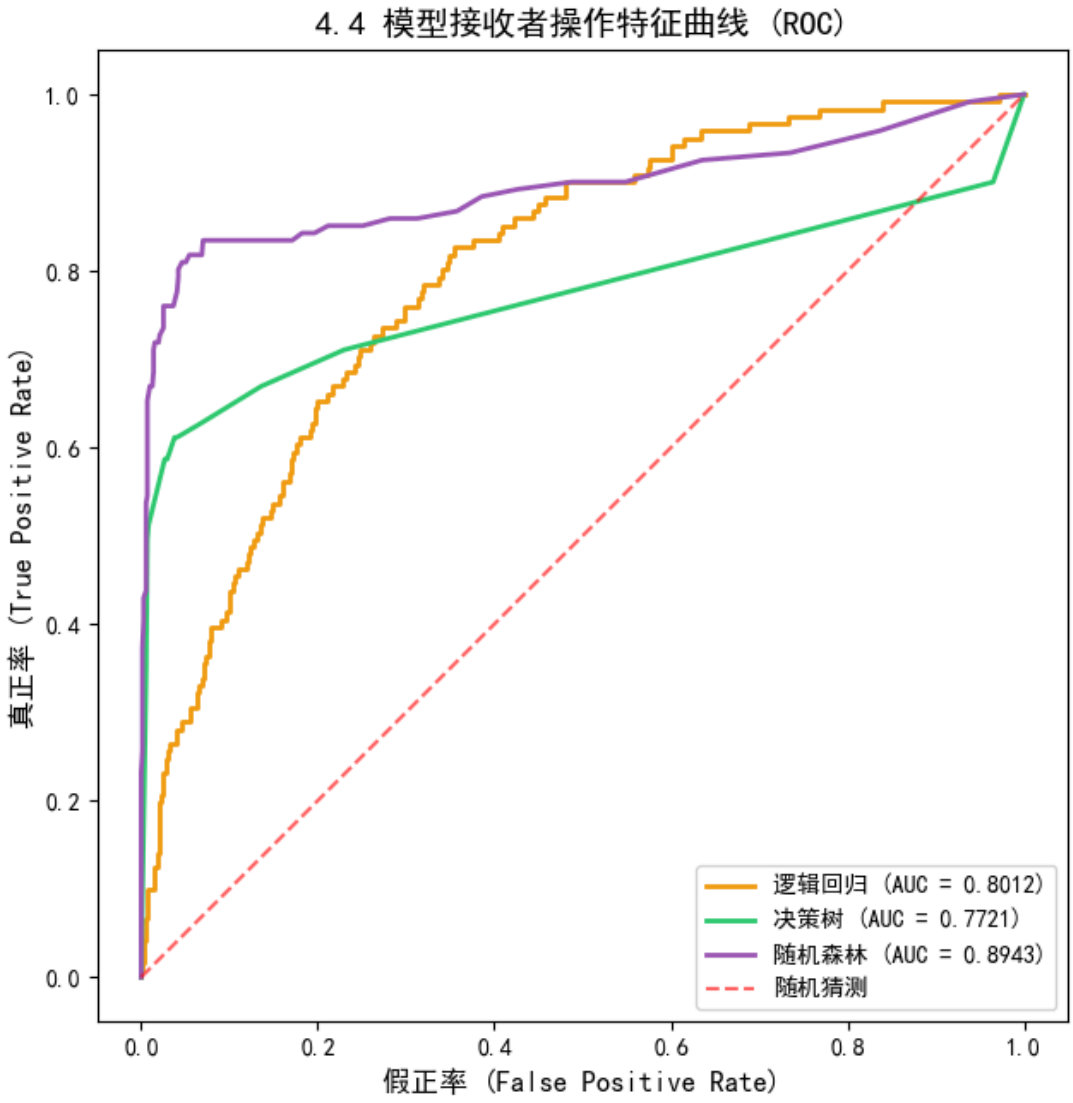

分析：

- 随机森林的ROC曲线最接近左上角，AUC=0.8943，远高于随机猜测（AUC=0.5），模型区分能力优秀；
- 逻辑回归AUC=0.8012，决策树AUC=0.7721，均具备有效区分能力，但弱于集成模型。

5.4 🔑 特征重要性分析（随机森林）

基于随机森林模型输出特征重要性，核心结论：

1. 客服通话次数（number_customer_service_calls）：重要性占比21%，是流失的第一驱动因素，客服通话≥4次的用户流失概率提升3倍；
2. 国际套餐（international_plan）：重要性占比18%，开通国际套餐的用户流失率更高（推测是套餐费用或服务体验问题）；
3. 白天通话时长（total_day_minutes）：重要性占比15%，高时长用户流失风险更高（可能是通话费用过高）。

6 💡 总结与建议

6.1 📝 实验结论

1. 数据特征：用户白天通话行为差异最大，傍晚/夜间通话行为更趋同；傍晚与夜间通话时长无显著关联，可独立建模；
2. 模型性能：随机森林是最优模型，准确率93.88%、ROC AUC 0.8943，但仍存在38%的流失用户漏判；
3. 核心驱动因素：客服通话次数、国际套餐开通状态、白天通话时长是影响用户流失的三大核心特征。

6.2 🚀 减少用户流失的策略建议

1. 优化客服服务体系
    1. 对客服通话≥2次的用户触发预警，由专属客服跟进问题解决；
    2. 缩短客服接通时长，降低用户因等待不满导致的流失。
2. 调整国际套餐策略
    1. 调研国际套餐用户的流失原因（如费用、覆盖范围），推出阶梯式定价或折扣套餐；
    2. 为国际套餐用户提供专属客服，解决跨境通话质量、账单疑问等问题。
3. 精准优化高时长用户体验
    1. 对白天通话时长≥300分钟的用户推出“日间畅聊包”，降低通话费用；
    2. 定期回访高时长用户，了解通话质量反馈，及时解决网络卡顿、信号差等问题。

6.3 📌 未来改进方向

1. 模型调优：针对随机森林的漏判问题，采用SMOTE算法处理类别不平衡，或调优超参数（如树数量、深度）提升召回率；
2. 进阶建模：引入LSTM深度学习模型，结合用户通话行为的时序特征（如近7天通话时长变化），进一步提升预测精度；
3. 特征扩展：补充用户消费周期、套餐变更记录等特征，丰富行为维度的分析。