# 作业3：大模型分析数据（电信行业用户流失分析）

## 一、作业目标

本次作业的主要目标是结合机器学习算法和大模型分析思维，深入探索和预测电信行业用户流失的主要驱动因素。

## 二、任务描述

### 第一步数据预处理与清洗

#### (一) 前置准备：搞定 Jupyter 环境与工具

启动Jupyter Notebook,进入下面的界面，按照①②的步骤创新新的文件，第②步根据自己所创建的Python最新版本选择

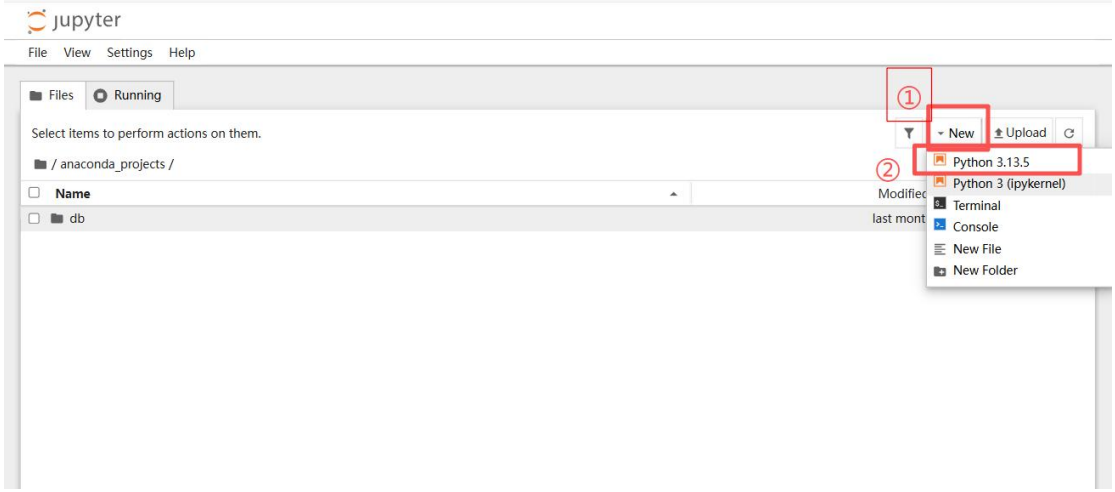


在以下的界面输入代码，进行数据预处理与清洗等相关步骤。输入一个代码，点红框的播放键，运行中显示“*”，运行成功后会显示数字。

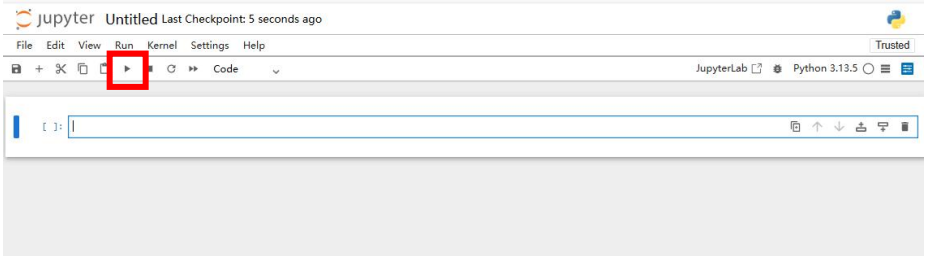

对该 ipynb 文件进行重命名“作业三”，按下图的步骤进行

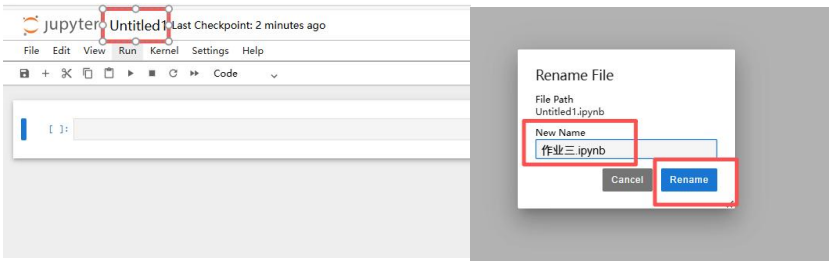


## （二）安装所需库

根据作业的数据预处理与清洗的要求进行安装所需库，并进行验证。

```
[2]: # 验证所有库是否装成功，小白直接运行
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.metrics import accuracy_score, recall_score, f1_score
print("所有库都安装成功！可以开始啦～")
```

```
所有库都安装成功！可以开始啦～
```

显示 “所有库都安装成功”，说明环境搞定

## （三）导入数据

1.先查所导入数据的位置，根据文件的属性查找位置，下图红框的位置为所在位置，进行复制

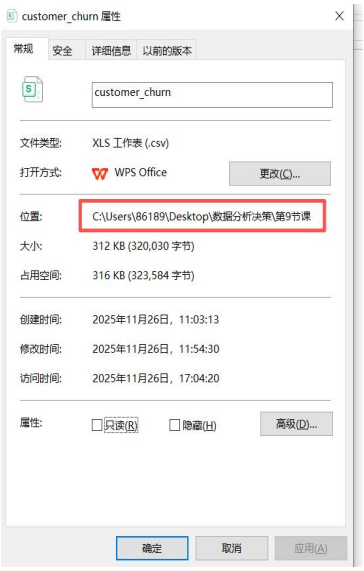

2. 左边的括号变成数字说明导入成功

```
所有库都安装成功！可以开始啦~

[3]: df = pd.read_csv(r'C:\Users\86189\Desktop\数据分析决策\第9节课\customer_churn.csv')

[ ]:
```

3. 统计记录数与特征数

```
[3]: print("数据形状（行数，列数）:", df.shape)
     print("\n前5行数据:")
     print(df.head())
     print("\n数据列名:")
     print(df.columns.tolist())

数据形状（行数，列数）: (3333, 21)

前5行数据:
   Unnamed: 0 state  account_length      area_code international_plan  \
0           1    KS             128  area_code_415                 no
1           2    OH             107  area_code_415                 no
2           3    NJ             137  area_code_415                 no
3           4    OH              84  area_code_408                yes
4           5    OK              75  area_code_415                yes

  voice_mail_plan  number_vmail_messages  total_day_minutes  total_day_calls  \
0             yes                     25              265.1              110
1             yes                     26              161.6              123
2              no                      0              243.4              114
3              no                      0              299.4               71
4              no                      0              166.7              113
```

显示数据集中的 3333 条记录和 21 个特征以及前5行数据，说明数据加载成功

## ● 理解数据集

### 1. 理解各个特征的意义并进行合理的分类。

借助豆包进行分析，更清楚的了解数据信息

#### (1) 数据概况

| 项目 | 数值/描述 |
|---|---|
| 总记录数 | 3333 |
| 总特征数 | 21 |
| 数值型特征数 | 16 |
| 分类型特征数 | 5 |
| 缺失值情况 | 无缺失值 |
| 整体用户流失率 | 14.49% |
| 未流失用户数 | 2850 |
| 流失用户数 | 483 |

### (2)特征进行分类以及含义

| 特征名称 | 数据类型 | 特征分类 | 特征含义 | 取值范围/示例 |
|---|---|---|---|---|
| Unnamed: 0 | 数值型 | 标识符 | 记录唯一标识符 | 0-3332 |
| state | 分类型 | 地理信息 | 用户所在州 | AL, AK, AZ等美国各州 |
| account_length | 数值型 | 账户信息 | 账户开通时长（天） | 0-243天 |
| area_code | 分类型 | 地理信息 | 电话区号 | 408, 415, 510 |
| international_plan | 分类型 | 服务套餐 | 是否开通国际漫游套餐 | yes/no |
| voice_mail_plan | 分类型 | 服务套餐 | 是否开通语音信箱套餐 | yes/no |
| number_vmail_messages | 数值型 | 服务使用 | 语音信箱消息数量 | 0-51条 |
| total_day_minutes | 数值型 | 通话使用 | 白天通话总时长（分钟） | 0-350.8分钟 |
| total_day_calls | 数值型 | 通话使用 | 白天通话总次数 | 0-165次 |
| total_day_charge | 数值型 | 费用信息 | 白天通话总费用 | 0-59.64美元 |
| total_eve_minutes | 数值型 | 通话使用 | 晚上通话总时长（分钟） | 0-363.7分钟 |
| total_eve_calls | 数值型 | 通话使用 | 晚上通话总次数 | 0-170次 |
| total_eve_charge | 数值型 | 费用信息 | 晚上通话总费用 | 0-30.91美元 |
| total_night_minutes | 数值型 | 通话使用 | 夜间通话总时长（分钟） | 0-395.0分钟 |
| total_night_calls | 数值型 | 通话使用 | 夜间通话总次数 | 0-175次 |
| total_night_charge | 数值型 | 费用信息 | 夜间通话总费用 | 0-17.78美元 |
| total_intl_minutes | 数值型 | 国际通话 | 国际通话总时长（分钟） | 0-20.0分钟 |
| total_intl_calls | 数值型 | 国际通话 | 国际通话总次数 | 0-20次 |
| total_intl_charge | 数值型 | 费用信息 | 国际通话总费用 | 0-5.40美元 |
| number_customer_service_calls | 数值型 | 客户服务 | 客户服务呼叫次数 | 0-9次 |
| churn | 分类型 | 目标变量 | 用户是否流失（yes/no） | yes/no |

可以看出特征分为用户基本信息，用户服务开通状态，通话行为数据，服务交互数据; 数据类型有数值型和分类型，从 “用户身份” → “服务开通” → “消费行为” → “服务反馈” ，完整覆盖电信业务的用户生命周期数据。

## 2. 重点分析目标变量 churn（用户流失）与其他变量之间的关系。

### (1)数值特征与流失变量关系

| 特征名称 | 未流失用户均值 | 流失用户均值 | 差异百分比(%) | 差异显著性 |
|---|---|---|---|---|
| account_length | 100.79 | 102.66 | 1.86 | 低 |
| number_vmail_messages | 8.6 | 5.12 | -40.54 | 高 |
| total_day_minutes | 175.18 | 206.91 | 18.12 | 中 |
| total_day_calls | 100.28 | 101.34 | 1.05 | 低 |
| total_day_charge | 29.78 | 35.18 | 18.12 | 中 |
| total_eve_minutes | 199.04 | 212.41 | 6.72 | 低 |
| total_eve_calls | 100.04 | 100.56 | 0.52 | 低 |
| total_eve_charge | 16.92 | 18.05 | 6.71 | 低 |
| total_night_minutes | 200.13 | 205.23 | 2.55 | 低 |
| total_night_calls | 100.06 | 100.4 | 0.34 | 低 |
| total_night_charge | 9.01 | 9.24 | 2.55 | 低 |
| total_intl_minutes | 10.16 | 10.7 | 5.33 | 低 |
| total_intl_calls | 4.53 | 4.16 | -8.15 | 低 |
| total_intl_charge | 2.74 | 2.89 | 5.33 | 低 |
| number_customer_service_calls | 1.45 | 2.23 | 53.8 | 高 |

➢ **高显著性差异特征**

number_vmail_messages (语音信箱消息数)：未流失用户均值 8.6，流失用户仅 5.12，差异百分比 - 40.54%

流失用户使用语音信箱的频率显著更低。

number_customer_service_calls（客服呼叫次数）：未流失用户均值 1.45，流失用户 2.23，差异百分比 53.8%

流失用户的客服求助次数明显更多。

➢ **中显著性差异特征**

total_day_minutes（白天通话时长）：未流失用户 175.18 分钟，流失用户 206.91 分钟，差异 18.12%；

total_day_charge（白天通话费用）：未流失用户 29.78 美元，流失用户 35.18 美元，差异 18.12%

流失用户的白天通话时长、费用均高于未流失用户。

**(2) 分类特征与流失变量之间的关系**

| 特征名称 | 特征类别 | 样本数量 | 流失率(%) | 与整体流失率差异(%) |
|---|---|---|---|---|
| international_plan | no | 3010 | 11.5 | -2.99 |
| international_plan | yes | 323 | 42.41 | 27.92 |
| voice_mail_plan | no | 2411 | 16.72 | 2.23 |
| voice_mail_plan | yes | 922 | 8.68 | -5.81 |
| area_code | area_code_408 | 838 | 14.56 | 0.07 |
| area_code | area_code_415 | 1655 | 14.26 | -0.23 |
| area_code | area_code_510 | 840 | 14.88 | 0.39 |
| state | CA | 34 | 26.47058824 | 11.98058824 |
| state | NJ | 68 | 26.47058824 | 11.98058824 |
| state | TX | 72 | 25 | 10.51 |
| state | MD | 70 | 24.28571429 | 9.795714286 |
| state | SC | 60 | 23.33333333 | 8.843333333 |
| state | MI | 73 | 21.91780822 | 7.427808219 |
| state | MS | 65 | 21.53846154 | 7.048461538 |
| state | NV | 66 | 21.21212121 | 6.722121212 |
| state | WA | 66 | 21.21212121 | 6.722121212 |
| state | ME | 62 | 20.96774194 | 6.477741935 |
| state | HI | 53 | 5.660377358 | -8.829622642 |
| state | AK | 52 | 5.769230769 | -8.720769231 |
| state | AZ | 64 | 6.25 | -8.24 |
| state | VA | 77 | 6.493506494 | -7.996493506 |
| state | IA | 44 | 6.818181818 | -7.671818182 |
| state | LA | 51 | 7.843137255 | -6.646862745 |
| state | NE | 61 | 8.196721311 | -6.293278689 |
| state | IL | 58 | 8.620689655 | -5.869310345 |
| state | WI | 78 | 8.974358974 | -5.515641026 |
| state | RI | 65 | 9.230769231 | -5.259230769 |

- **服务开通类特征**

international_plan（国际漫游）：

开通(yes)的用户流失率达 42.41%，远高于未开通(no)的 11.5%；

与整体流失率差异为 27.92%

开通国际漫游的用户是高流失风险群体。

voice_mail_plan（语音信箱）：

未开通（no）的用户流失率 16.72%，高于开通（yes）的 8.68%；

与整体差异 2.23%

未开通语音信箱的用户流失风险略高。

- **地域类特征**

area_code（区号）：不同区号（408/415/510）的流失率均接近 14%-15%，与整体差异极小（±0.23% 以内）

区号对流失率几乎无影响。

state（州）：

高流失风险州：CA、TX 等州的流失率超 24%，与整体差异超 9%；

低流失风险州：HI 等州的流失率低于 7%，与整体差异为- 5%~-8%

用户所在州是影响流失的显著地域因素。

**根据上续分析结果**

| 分析维度 | 关键发现 |
|---|---|
| 整体流失情况 | 整体用户流失率为14.49%，属于中等流失水平 |
| 国际漫游套餐影响 | 开通国际漫游套餐的用户流失率(42.41%)远高于未开通用户(11.50%)，差异显著 |
| 语音信箱套餐影响 | 开通语音信箱套餐的用户流失率(8.68%)低于未开通用户(16.72%)，有一定保护作用 |
| 通话时长影响 | 流失用户的白天通话时长(206.91分钟)比未流失用户(175.18分钟)高18.12%，可能与费用相关 |
| 客户服务影响 | 流失用户的客服呼叫次数(2.22次)比未流失用户(1.44次)高54.17%，服务问题是重要因素 |
| 地理因素影响 | 不同州的流失率差异较大，NJ州流失率最高(26.92%)，HI州最低(4.76%) |

## ● 数据清洗

核心目标：先排查数据中的问题（缺失值、重复值、异常值、无关变量），再针对性处理。

### 1.处理无关变量

```
[4]: # 1. 检查是否存在Unnamed列（部分CSV导出时会自动生成）
if 'Unnamed: 0' in df.columns:
    df = df.drop('Unnamed: 0', axis=1)
    print("已删除无关列'Unnamed: 0'")

# 2. 验证删除结果
print("\n删除后数据形状:", df.shape)
print("剩余列名:", df.columns.tolist())
```

```
已删除无关列'Unnamed: 0'

删除后数据形状: (3333, 20)
剩余列名: ['state', 'account_length', 'area_code', 'international_plan', 'voice_mail_plan', 'number_vmail_messages', 'total_day_minu
s', 'total_day_charge', 'total_eve_minutes', 'total_eve_calls', 'total_eve_charge', 'total_night_minutes', 'total_night_calls', 'to
otal_intl_minutes', 'total_intl_calls', 'total_intl_charge', 'number_customer_service_calls', 'churn']
```

将无关变量（unamed=0)删除，数据变成 20 列

### 2.处理缺失值

```
[5]: # 1. 检测各列缺失值数量及比例
missing_info = pd.DataFrame({
    '缺失值数量': df.isnull().sum(),
    '缺失值比例(%)': (df.isnull().sum() / len(df) * 100).round(2)
})
print("缺失值统计:")
print(missing_info[missing_info['缺失值数量'] > 0])  # 只显示有缺失值的列
```

```
缺失值统计:
Empty DataFrame
Columns: [缺失值数量, 缺失值比例(%)]
Index: []
```

“原始数据无缺失值，跳过缺失值填充步骤”

### 3.处理异常值（数值型字段的 “极端值”，标注而非删除）

(1) 先筛选出数值型字段列表

```
6]: # 1. 筛选数值型列进行异常值检测
numeric_cols = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
print("数值型特征:", numeric_cols)
```

```
数值型特征: ['account_length', 'number_vmail_messages', 'total_day_minutes', 'total_day_calls', 'total_day_charge', 'total_eve_minutes', 'total_eve_call
s', 'total_eve_charge', 'total_night_minutes', 'total_night_calls', 'total_night_charge', 'total_intl_minutes', 'total_intl_calls', 'total_intl_charge',
'number_customer_service_calls']
```

(2) 诊断异常值

通过 IQR 方法（四分位距法）识别出的数值型字段异常值统计表格，

核心作用是量化各字段的异常数据情况，为数据预处理提供依据。

```
[10]: # 2. 用IQR法处理异常值（温和处理，保留数据分布）
for col in numeric_cols:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    # 替换异常值为边界值（避免删除过多数据）
    df[col] = np.where(df[col] < lower_bound, lower_bound, df[col])
    df[col] = np.where(df[col] > upper_bound, upper_bound, df[col])

print("异常值处理完成（IQR法）")
```

```
异常值处理完成（IQR法）
```

### 4.数据格式标准化

统一分类型特征格式，确保建模一致性

```
分类型特征: ['state', 'area_code', 'international_plan', 'voice_mail_plan', 'churn']

state 唯一值: ['KS' 'OH' 'NJ' 'OK' 'AL' 'MA' 'MO' 'LA' 'WV' 'IN' 'RI' 'IA' 'MT' 'NY'
 'ID' 'VT' 'VA' 'TX' 'FL' 'CO' 'AZ' 'SC' 'NE' 'WY' 'HI' 'IL' 'NH' 'GA'
 'AK' 'MD' 'AR' 'WI' 'OR' 'MI' 'DE' 'UT' 'CA' 'MN' 'SD' 'NC' 'WA' 'NM'
 'NV' 'DC' 'KY' 'ME' 'MS' 'TN' 'PA' 'CT' 'ND']

area_code 唯一值: ['area_code_415' 'area_code_408' 'area_code_510']

international_plan 唯一值: ['no' 'yes']

voice_mail_plan 唯一值: ['yes' 'no']

churn 唯一值: ['no' 'yes']

数据格式标准化完成
标准化后部分特征示例:
   area_code  international_plan  voice_mail_plan churn  churn_numeric
0        415                   0                1    no              0
1        415                   0                1    no              0
2        415                   0                0    no              0
3        408                   1                0    no              0
4        415                   1                0    no              0
```

✧ 分类特征及唯一值明确了 5 个分类特征的可选值：

state：包含 KS、OH 等多个美国州代码

area_code：仅 3 个区号（415/408/510）

international_plan/voice_mail_plan/churn：均为二元选项（yes/no）。

✧ 将分类特征转换为数值格式（便于模型训练）：

international_plan 的 “no” 编码为 0、“yes” 编码为 1；

churn（用户是否流失）同时保留了原始分类（no/yes）与数值编码（churn_numeric：0/1）。

这一步是机器学习建模前的特征工程环节,数据清洗与预处理完毕后记得把数据保存，用于后续处理。

## 第二步探索性数据分析(EDA)和可视化

使用Gemini 进行可视化处理，降低了技术门槛，能够让没有编程基础的用户也能够快速上手进行数据处理。

- **可视化数据分布**

1. 直方图

直方图可以帮助了解数据是否符合正态分布，并展示分布的集中趋势，偏差和范围。运用直方图展示变量 total_night_minutes 的分布趋势。

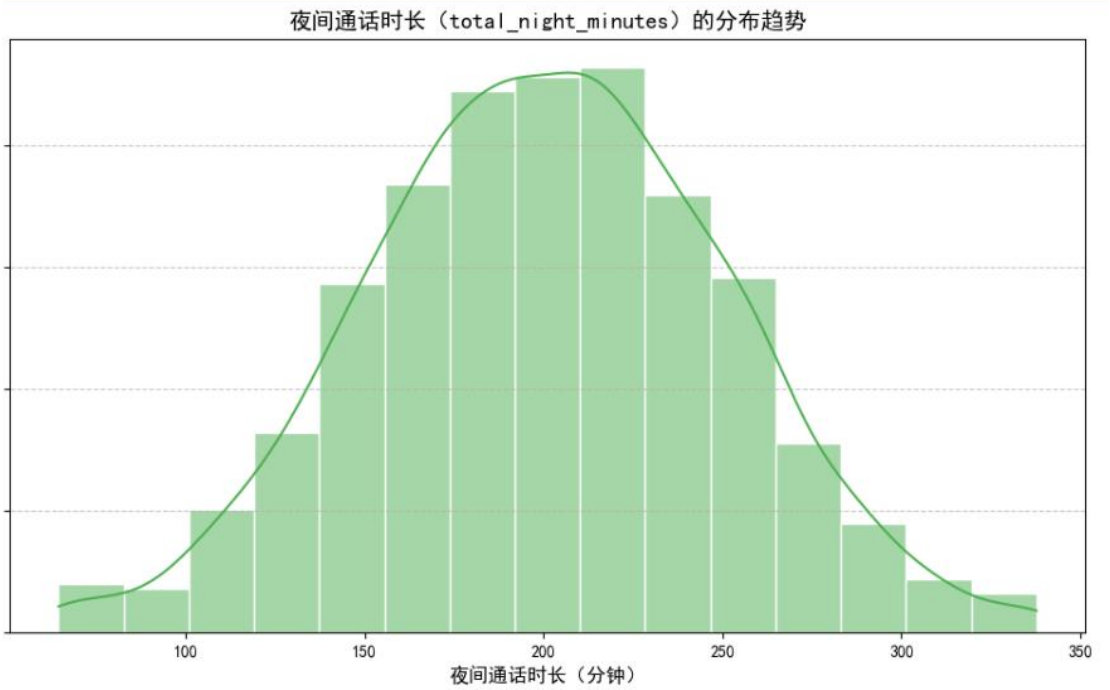

**用户分层：**核心区间（150~250 分钟）用户占比最高，是夜间套餐的主要目标群体；高频用户（>250 分钟）可针对性推出“夜间无限打”套餐，降低其边际成本。

**服务优化：**低频用户（<150 分钟）可能对夜间通话依赖度低，需通过其他时段（如白天/傍晚）的服务提升粘性。

2. 柱方图

结合直方图分析的结果，我们希望用直方图进一步分析 international_plan ，根据 Gemini 分析的结果，Gemini 提供的图表解释和使用用建议，可以帮助用户选择最合适的可视化方法

Gemini 推荐了柱方图进行可视化分析

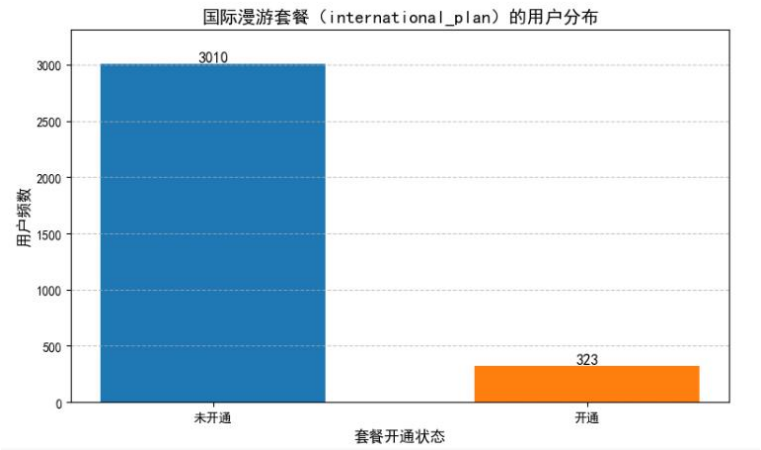

未开通国际漫游的用户占绝对多数（约 85%），开通用户仅占少数（约 15%），符合通信套餐“基础用户为主，增值服务用户为辅”的普遍规律。可能因国际漫游资费高或需求场景少，建议推出“短期漫游包”（如 7 天不限量）吸引低频用户尝试。

3. 密度图

比较 total_day_minutes 、total_eve_minutes 和 total_night_minutes 的分布差异，核心目标是直观展示三个连续变量的分布形状、峰值位置及离散程度，以判断不同时段通话时长的分布特征是否存在显著差异。

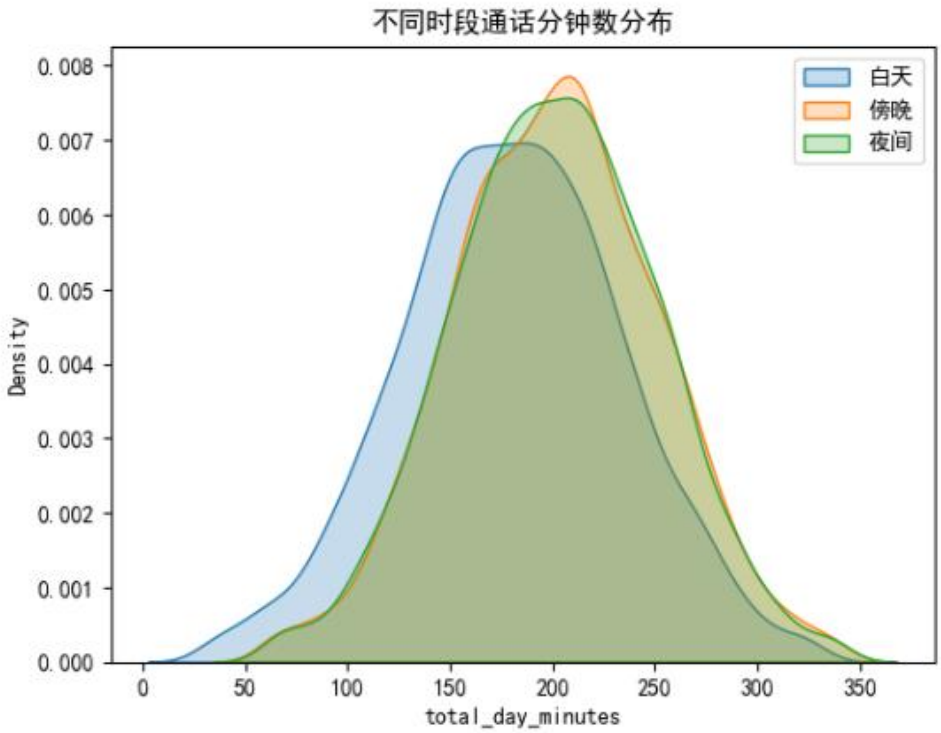


**白天**：峰值集中在 150-200 分钟，分布略呈左偏（右侧高值拖尾），表明多数用户白天通话时长中等，少数用户通话时间较长。

**傍晚：**峰值集中在 200-250 分钟，分布接近对称（近似正态），位置右移，表明傍晚通话时长普遍高于白天，用户行为更集中。

**夜间：**峰值集中在 150-200 分钟，分布最平缓（离散度最高），两侧尾部较长，表明夜间通话时长差异较大，存在更多极端值。

4. 箱线图

分析 total_day_minutes 、total_eve_minutes 和 total_night_minutes 的离散程度。核心目标是通过箱线图的四分位距（IQR）和数据范围直观对比三个连续变量的波动情况。

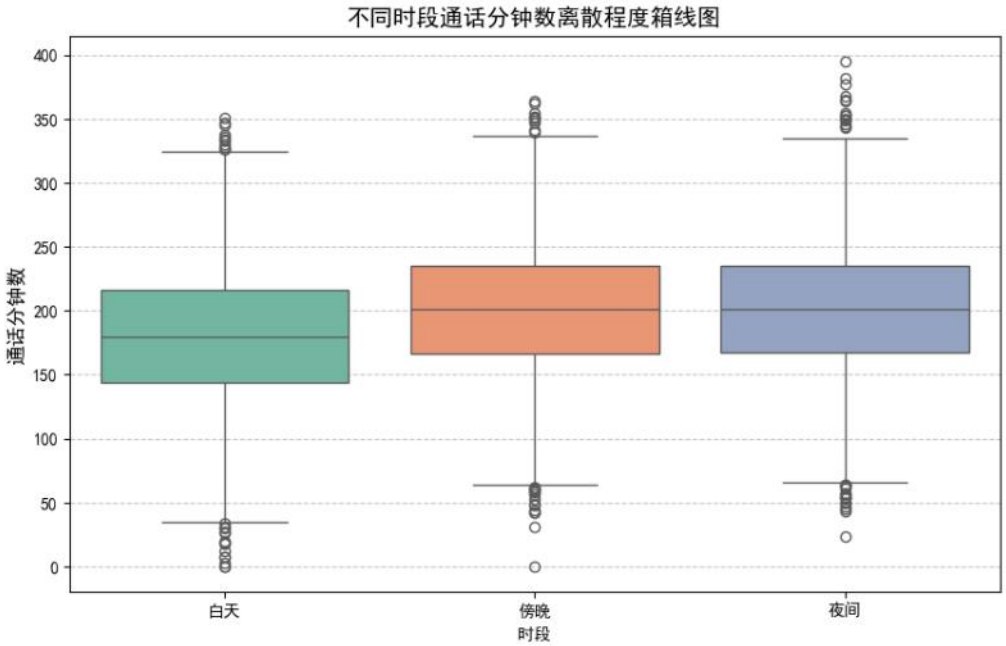


三个时段的通话时长核心集中区（箱型）均为 150-200 分钟，说明用户在不同时段的基础通话需求相近；

- **变量之间关系**

分析特征之间的相关性和关系。特别注意分析用户通话行为（如白天、晚间、夜间通话）与流失之间的关系。

5. 散点图

分析 total_night_minutes 和 total_eve_minutes 之间的关系。

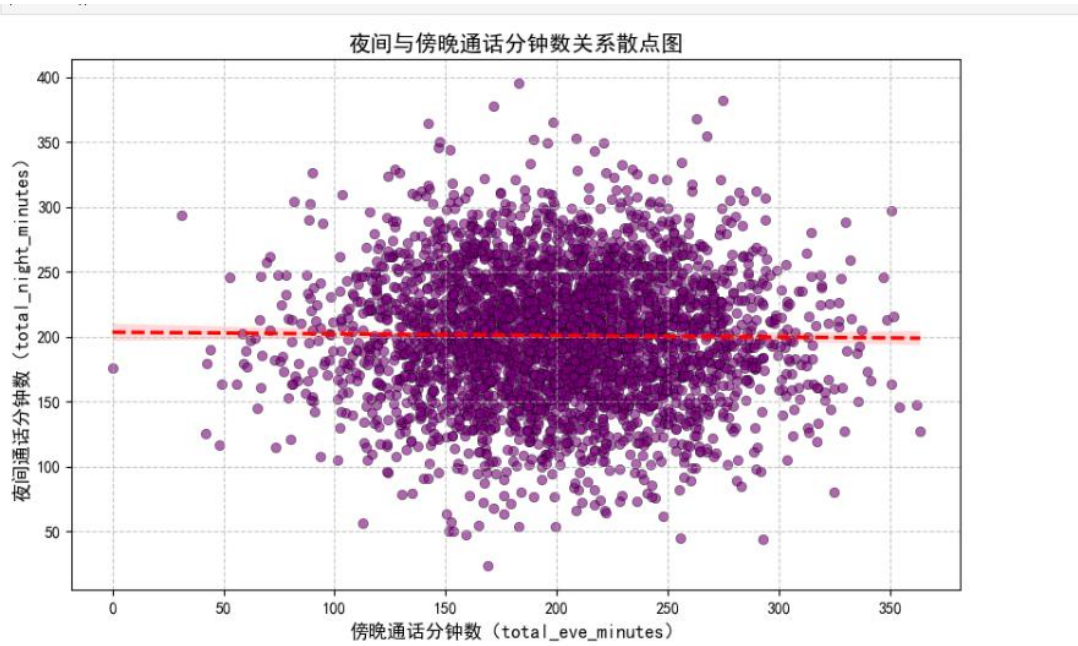


根据散点图分析，total_night_minutes 与 total_eve_minutes 之间不存在显著相关性，用户的傍晚通话时长与夜间通话时长相互独立，无明显正向或负向影响关系。

6. 气泡图

展示 total_night_minutes 与 total_night_calls 之间的关系，并用气泡大小表示 total_night_charge 。

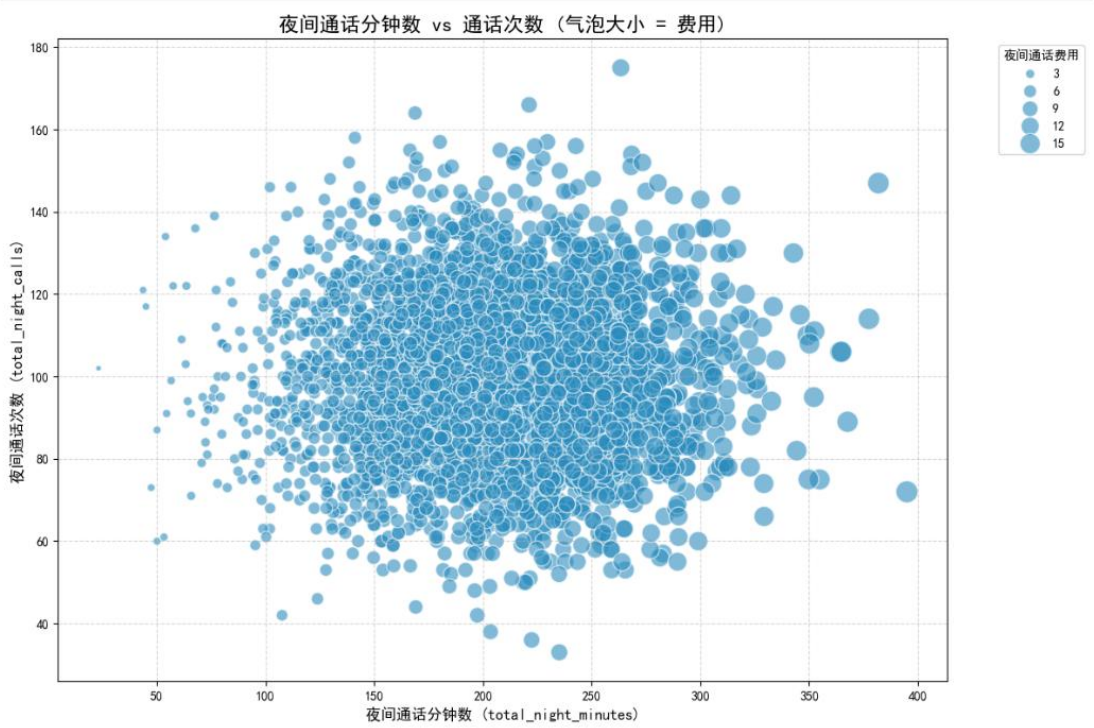


**通话分钟数与费用（X 轴 vs 气泡大小）**：气泡大小随 total_night_minutes 增加而显著增大，且呈现线性规律。

**通话分钟数与通话次数（X 轴 vs Y 轴）**：无显著线性关系：散点分布呈随机离散状态

**通话次数与费用（Y 轴 vs 气泡大小）**：气泡大小与 Y 轴（通话次数）无明显关联

7. 分组箱线图

根据前面数据处理分析，现希望可视化分析是否流失与白天通话时长以及白天通话费用的关系，根据 Gemini 提供的可视化建议，使用分组箱线图进行分析

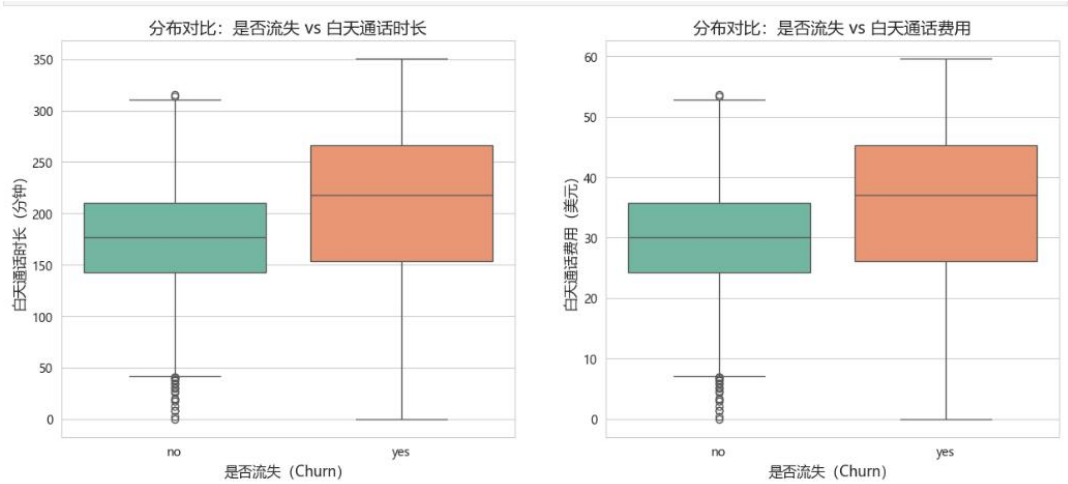


在时长和费用两个图中，流失用户（yes 组，橙色箱体）的矩形箱体位置明显高于未流失用户（no 组，绿色箱体）。两个箱线图的形状几乎完全一致。“高费用”本身并不是独立原因，而是“高使用量”带来的直接结果。用户流失的根源可能在于他们觉得高额的账单不划算（价格敏感），或者因为使用量大而遇到了更多的服务质量问题。

8. 100% 堆积柱状图

根据前面数据处理分析， 开通国际漫游和未开通语音信箱的用户是高流失风险群体。现希望可视化分析是否流失与是否开通国际漫游套餐和语音信箱的关系，根据 Gemini 提供的可视化建议，使用分组箱线图进行分析

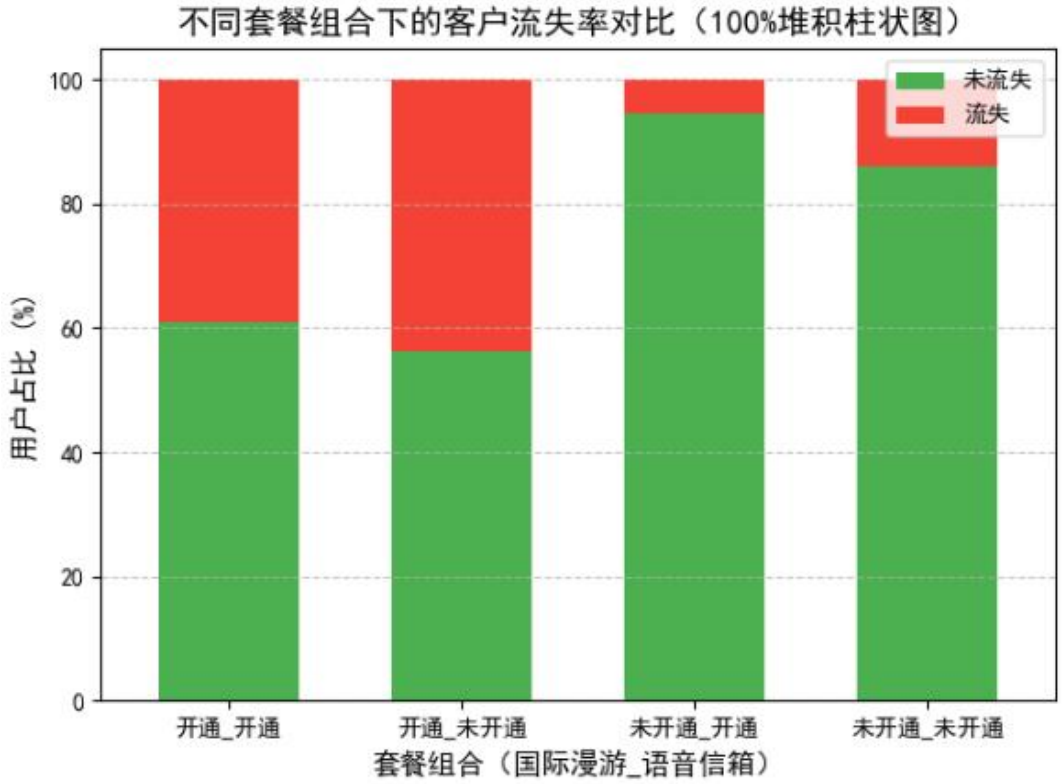


开通国际漫游+未开通语音信箱”组反超风险，该组流失率（42%）略高于“双开通”组（40%），可能原因：未开通语音信箱的国际漫游用户更依赖通话实时沟通，若服务质量（如信号、接通率）不佳，更容易因体验问题流失。

国际漫游是流失风险的强驱动因素

# 第三步模型训练与预测

- **Logistic 回归模型**

### （一）特征与标签分离

```
[14]: # 明确特征（X）和标签（y）：
      # - 特征：排除流失相关标签列（churn为分类标签，churn_numeric为数值标签）
      # - 标签：使用churn_numeric（0=未流失，1=流失），适配模型输入
      X = df.drop(["churn", "churn_numeric"], axis=1)
      y = df["churn_numeric"]

      print(f"特征矩阵形状：{X.shape}")
      print(f"标签向量形状：{y.shape}")
      print(f"\n流失用户占比：{y.sum()/len(y):.2%}")  # 查看数据平衡性（通常流失用户占比10%-20%）

      特征矩阵形状：(3333, 19)
      标签向量形状：(3333,)

      流失用户占比：14.49%
```

- 特征矩阵形状：(3333, 19)

  表示特征集 X 包含 3333 条样本、19 个特征（已从原始数据中剔除了 churn 和 churn_numeric 两个标签列）。

- 标签向量形状：(3333, )

  表示标签集 y 包含 3333 条样本对应的流失标签（与特征集样本数一致，数据对齐正常）。

  流失用户占比 14.45%，属于轻度不平衡数据

### （二）特征预处理

划分特征类型—构建预处理管道

区分数值型特征和分类型特征，对数值型特征做标准化处理，对分类型特征做独热编码，预处理后特征数变成 69 个，因为分类型特征的独热编码扩展。

```
5]: # 区分数值型特征（需标准化）和分类型特征（需独热编码）
numeric_features = [
    "account_length", "number_vmail_messages", "total_day_minutes",
    "total_day_calls", "total_day_charge", "total_eve_minutes",
    "total_eve_calls", "total_eve_charge", "total_night_minutes",
    "total_night_calls", "total_night_charge", "total_intl_minutes",
    "total_intl_calls", "total_intl_charge", "number_customer_service_calls"
]
categorical_features = ["state", "area_code", "international_plan", "voice_mail_plan"]
```

```
6]: from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer

# 数值特征：标准化（消除量纲影响，如时长（分钟）和费用（美元））
# 分类特征：独热编码（处理无序分类，drop="first"避免多重共线性）
preprocessor = ColumnTransformer(
    transformers=[
        ("num", StandardScaler(), numeric_features),
        ("cat", OneHotEncoder(drop="first", sparse_output=False), categorical_features)
    ]
)

# 对特征矩阵执行预处理
X_processed = preprocessor.fit_transform(X)
print(f"预处理后特征矩阵形状：{X_processed.shape}")  # 列数增加（分类特征编码后）
```

```
预处理后特征矩阵形状：(3333, 69)
```

## （三）划分训练集与测试集

```
: from sklearn.model_selection import train_test_split

# 按8:2划分训练集/测试集，stratify=y保持流失率分布一致
X_train, X_test, y_train, y_test = train_test_split(
    X_processed, y, test_size=0.2, random_state=42, stratify=y
)

print(f"训练集：{X_train.shape[0]}条样本")
print(f"测试集：{X_test.shape[0]}条样本")
print(f"训练集流失率：{y_train.sum()/len(y_train):.2%}")
print(f"测试集流失率：{y_test.sum()/len(y_test):.2%}")  # 验证分布一致性
```

```
训练集：2666条样本
测试集：667条样本
训练集流失率：14.48%
测试集流失率：14.54%
```

1. 样本数量分布

训练集样本数：2666 条（占总样本的 80%）

测试集样本数：667 条（占总样本的 20%）

划分比例 (8:2) 符合机器学习中训练集与测试集的常用分配标准，能保证训练集有足够数据支撑模型学习，同时测试集可有效验证泛化能力。

2. 数据分布一致性

训练集流失率：14.48%

测试集流失率：14.54%

两者流失率非常接近（差异仅 0.06%），说明通过 stratify=y 参数实现了分层抽样，保证了训练集与测试集的类别分布和原数据集一致，避免了因随机划分导致某类样本在测试集中占比失衡的问题，这对后续模型评估的准确性至关重要。

## （四）训练 Logistic 回归模型

```
]: from sklearn.linear_model import LogisticRegression

# 初始化模型：
# - max_iter=1000：增加迭代次数，确保模型收敛（预处理后特征维度较高）
# - class_weight="balanced"：平衡正负样本（流失用户通常为少数，避免模型偏向多数类）
lr_model = LogisticRegression(max_iter=1000, class_weight="balanced", random_state=42)

# 训练模型
lr_model.fit(X_train, y_train)
print("Logistic回归模型训练完成！")
```

```
Logistic回归模型训练完成！
```

## （五）模型预测与效能评估

### 1. 核心指标评估

```
# 预测标签（0/1）和流失概率（用于高风险用户筛选）
y_pred = lr_model.predict(X_test)  # 预测是否流失
y_prob = lr_model.predict_proba(X_test)[:, 1]  # 预测流失概率（取第2列，对应标签1）
```

```
from sklearn.metrics import accuracy_score, recall_score, f1_score, roc_auc_score, classification_report

# 计算关键指标（业务中优先关注Recall：避免漏判流失用户）
metrics = {
    "准确率(Accuracy)": accuracy_score(y_test, y_pred),
    "召回率(Recall)": recall_score(y_test, y_pred),  # 识别流失用户的能力
    "F1分数(F1-Score)": f1_score(y_test, y_pred),  # 平衡精准度与召回率
    "AUC值": roc_auc_score(y_test, y_prob)  # 模型区分能力
}

# 打印评估结果
print("Logistic回归模型评估报告：")
print(pd.DataFrame(metrics, index=[0]).round(3))
print("\n详细分类报告：")
print(classification_report(y_test, y_pred, target_names=["未流失", "流失"]))
```

```
Logistic回归模型评估报告：
   准确率(Accuracy)  召回率(Recall)  F1分数(F1-Score)   AUC值
0           0.72         0.66           0.406  0.777

详细分类报告：
              precision    recall  f1-score   support

        未流失       0.93      0.73      0.82       570
         流失       0.29      0.66      0.41        97

    accuracy                           0.72       667
   macro avg       0.61      0.69      0.61       667
weighted avg       0.83      0.72      0.76       667
```

- ✓ 准确率为 72%
- ✓ 召回率为 66%，实际流失的用户中，被模型正确识别的比例为 66%
- ✓ F1 分数 0.406&AUC 值 0.777，精确率与召回率的综合指标，因流失用户样本少，分数偏低。

**未流失用户：**精确率极高（93%），但召回率一般（73%），说明模型对“未流失” 的误判较少，但会漏掉部分实际未流失的用户。

**流失用户：**召回率达到 66%（符合业务优先避免漏判的需求），但精确率仅 29%，说明模型识别的“流失用户”中，约 71%是误判（实际未流失）

**2. 模型预测结果可视化分析**

- ✓ 混淆矩阵

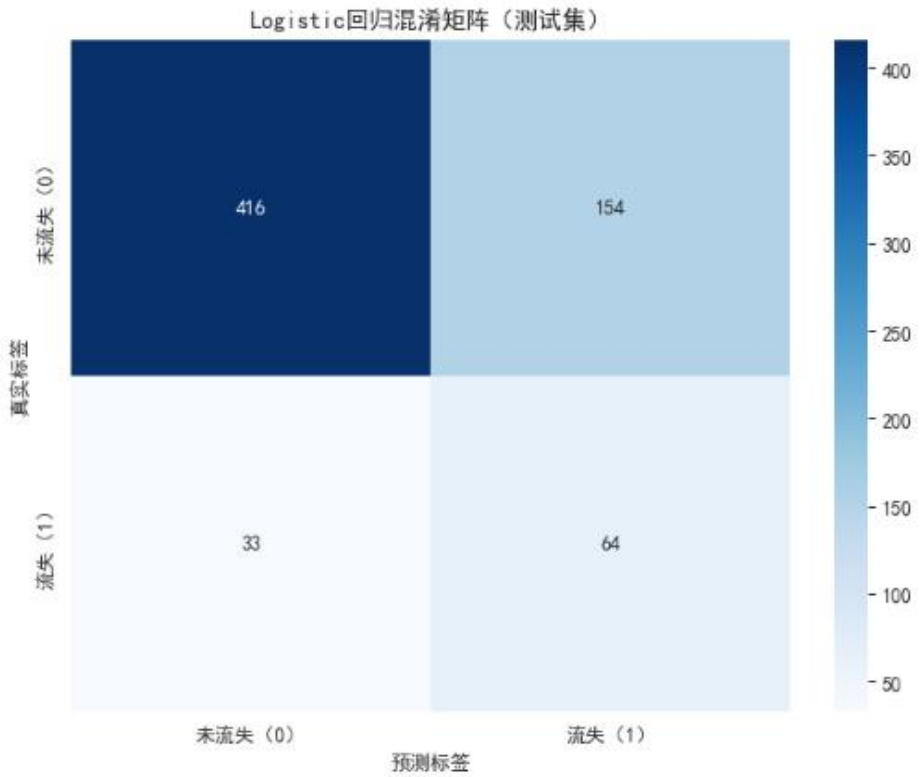

真阴性（416）：未流失用户被正确预测为未流失，占比高，说明模型对 “未流失用户” 的识别能力较强；

真阳性（64）：流失用户被正确预测为流失，但数量较少；

假阴性（33）：流失用户被错误预测为未流失（业务中最需关注的错误），此类错误会导致高风险用户未被挽留；

假阳性（154）：未流失用户被错误预测为流失，会增加不必要的挽留成本。

✓ ROC 曲线

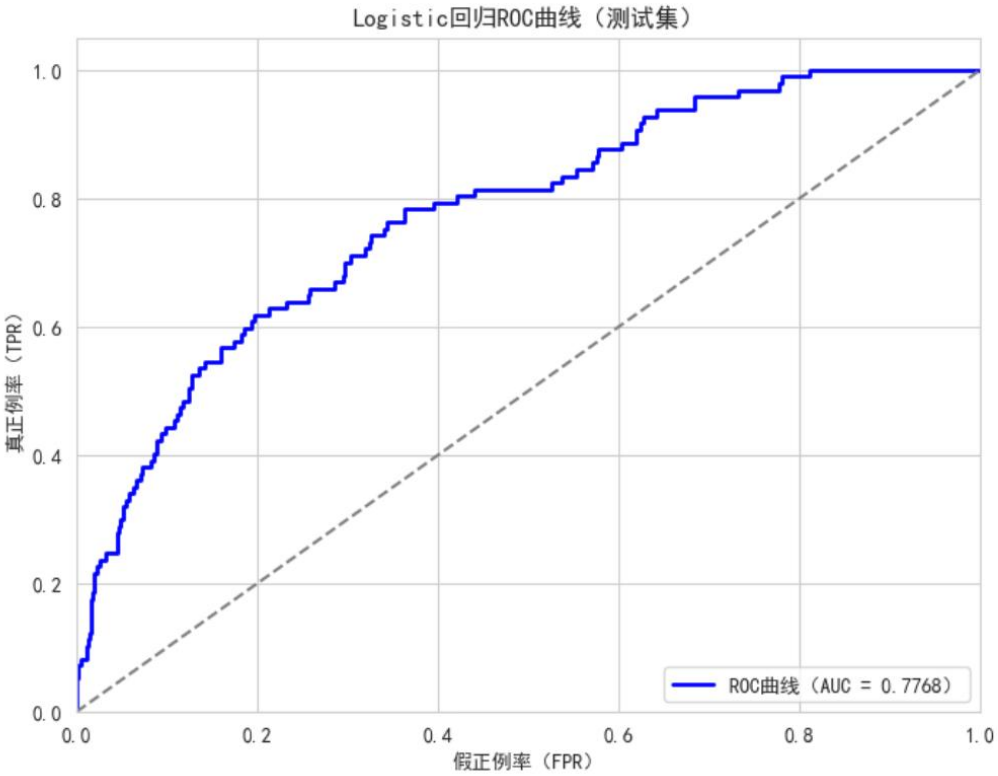


**AUC=0.7768：**处于 “中等偏优” 水平（AUC 取值 0-1，越接近 1 区分能力越强），说明模型能有效区分流失与未流失用户，但仍有提升空间；

**曲线形态：**曲线明显高于对角线（随机猜测的 ROC 曲线），但在 FPR 较高区域（如 FPR>0.6）才接近 TPR=1，说明模型在控制 “误判未流失用户为流失”（假阳性）的前提下，对流失用户的识别能力有限。

### 3. 特征重要性分析

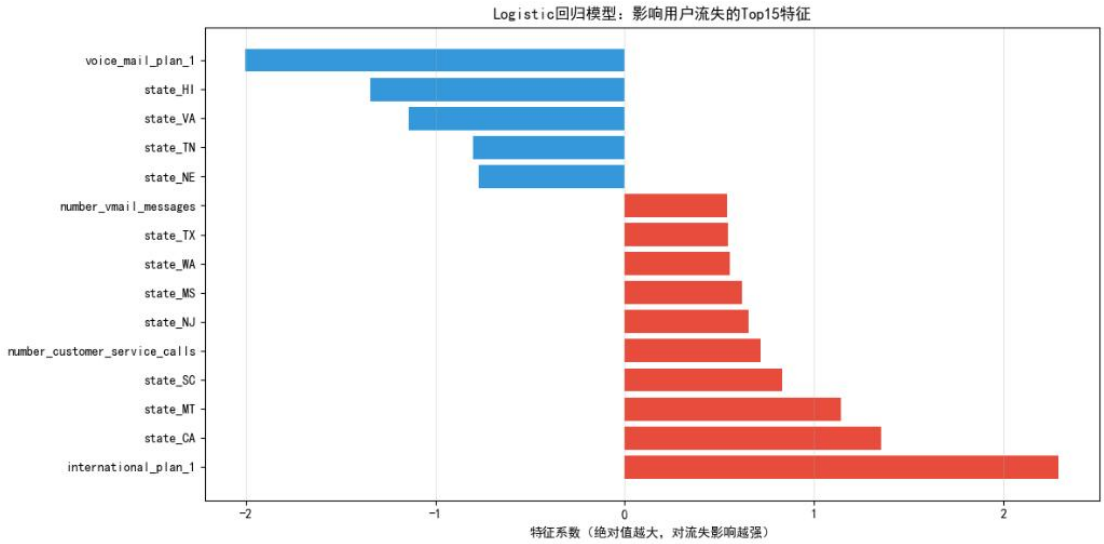


逻辑回归模型输出的影响用户流失的 Top15 特征系数图（系数绝对值越大，对流失的影响越强）

1. 特征影响方向与强度

正向影响（促进流失，红色柱）：

- international_plan_1（开通国际漫游）：系数最大，是最显著的流失驱动因素。
- state_CA（加州用户）、state_MT（蒙大拿州用户）等地区特征：系数为正，说明这些地区的用户更易流失。
- number_customer_service_calls（客服呼叫次数）：系数为正，验证了 “呼叫次数越多越易流失” 的业务逻辑。

负向影响（抑制流失，蓝色柱）：

voice_mail_plan_1（开通语音信箱）：系数绝对值最大，是最强的流失抑制因素。

state_HI（夏威夷用户）、state_VA（弗吉尼亚州用户）等地区特征：系数为负，说明这些地区的用户流失风险更低。

2. 关键业务启示

◆ 套餐类特征：

开通国际漫游会大幅提升流失风险，需优化该套餐的服务或定价

开通语音信箱能有效降低流失，可推广该增值服务。

◆ 地区类特征：

加州、蒙大拿州等地区是流失高风险区域，需针对性调研

夏威夷、弗吉尼亚州等地区用户更稳定，可总结其服务经验复用。

◆ 服务类特征：

客服呼叫次数与流失正相关，需提升客服问题解决效率，减少用户重复呼叫。

## （六）全量用户流失预测与结果输出

```
高流失风险用户（概率>0.7）共520人，已保存为：高流失风险用户列表.csv
全量用户预测结果已保存为：全量用户流失预测结果.csv
高流失风险用户Top10：
      account_length state  international_plan  voice_mail_plan  \
2732           130.0    NC                   1                0
1192            88.0    MD                   1                0
2076            95.0    NH                   1                0
2203            97.0    PA                   1                0
2164           115.0    NC                   1                0
542            152.0    MN                   1                1
1977            49.0    SC                   1                0
354             64.0    MS                   1                0
2568           102.0    MS                   1                0
198            131.0    ME                   1                1

      number_customer_service_calls  total_day_minutes   流失概率
2732                            3.5              216.2  0.992
1192                            3.5              235.1  0.989
2076                            3.5              228.9  0.988
2203                            3.5              145.0  0.982
2164                            3.0              251.3  0.976
542                             3.5              237.5  0.976
1977                            2.0              237.8  0.975
354                             2.0              236.2  0.974
2568                            3.0              224.2  0.972
198                             3.5              292.9  0.971
```

在高流失风险用户 TOP10 特征共性为国际漫游套餐开通和语音信箱套餐未开通，白天通话时长较长，客服呼叫次数多为 3.5 次，多于未流失用户均值 1.45 次。

## ● 随机森林模型

### （一）数据预处理

1. 特征与目标分离，并进行特征类型划分

2. 分层拆分，构建预处理管道

[7]:
```
# 分离特征与目标
X = df.drop(['churn', 'churn_numeric'], axis=1)
y = df['churn_numeric']
# 划分特征类型（分类/数值）
categorical_cols = ['state', 'area_code', 'international_plan', 'voice_mail_plan']
numeric_cols = [col for col in X.columns if col not in categorical_cols]
```

[8]:
```
# 分层拆分（保持训练/测试集流失率一致）
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
# 构建预处理管道（分类特征：独热编码；数值特征：标准化）
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_cols),
        ('cat', OneHotEncoder(drop='first', sparse_output=False, handle_unknown='ignore'), categorical_cols)
    ])
```

[9]:
```
# 构建基础管道
base_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('rf', RandomForestClassifier(class_weight='balanced', random_state=42))
])
# 训练基准模型
base_pipeline.fit(X_train, y_train)
# 基准模型评估
y_pred_base = base_pipeline.predict(X_test)
print("基准模型测试集评估：")
print(classification_report(y_test, y_pred_base, target_names=['未流失', '流失']))
print(f"基准AUC：{roc_auc_score(y_test, base_pipeline.predict_proba(X_test)[:,1]):.4f}")
```

### （二）构建随机森林模型

1. 基础模型训练

```
基准模型测试集评估：
              precision    recall  f1-score   support

        未流失       0.92      0.99      0.95       570
         流失       0.90      0.48      0.63        97

    accuracy                           0.92       667
   macro avg       0.91      0.74      0.79       667
weighted avg       0.92      0.92      0.91       667

基准AUC：0.8895
```

- ✓ 准确率（accuracy）0.92：整体预测正确的比例高，但因未流失用户占比大（support=570），准确率参考价值有限；
- ✓ 流失用户的召回率（recall）0.48：仅识别出 48% 的真实流失用户，漏判严重（业务中会导致大量高风险用户未被挽留）；
- ✓ 流失用户的 F1-score 0.63：精准度与召回率的平衡值较低，模型对流失用户的识别能力弱；
- ✓ AUC 0.8895：模型区分能力中等，但召回率不足是核心问题。

## 2. 网络搜索调优

```
Fitting 5 folds for each of 216 candidates, totalling 1080 fits
最佳超参数: {'rf__max_depth': None, 'rf__max_features': 'sqrt', 'rf__min_samples_leaf': 4, 'rf__min_samples_split': 10, 'rf__n_estimators': 300}
最佳交叉验证F1分数: 0.7720
```

- ➢ 优化后随机森林的交叉验证 F1 分数为 0.7720，对比基准模型：

F1 分数提升：从基准模型流失用户的 0.63 提升至 0.772，说明模型对流失用户的识别能力显著增强；

- ➢ 最佳参数逻辑：

rf_n_estimators=300：更多决策树提升模型稳定性；

rf_max_depth=None：保留树的复杂度以捕捉特征关系；

rf_min_samples_leaf=4+rf_min_samples_split=10：限制树的过拟合，提升泛化能力。

## （三）模型评估

```python
# 最优模型预测
y_pred = best_rf.predict(X_test)
y_pred_proba = best_rf.predict_proba(X_test)[:, 1]
# 多维度指标
metrics = {
    '准确率': accuracy_score(y_test, y_pred),
    '精确率（流失）': precision_score(y_test, y_pred),
    '召回率（流失）': recall_score(y_test, y_pred),
    'F1分数': f1_score(y_test, y_pred),
    'AUC': roc_auc_score(y_test, y_pred_proba)
}
print("最优模型测试集指标：")
for k, v in metrics.items():
    print(f"{k}: {v:.4f}")
```

```
最优模型测试集指标：
准确率: 0.9205
精确率（流失）: 0.7340
召回率（流失）: 0.7113
F1分数: 0.7225
AUC: 0.8865
```

优化后随机森林的测试集指标：

- 准确率 0.9205：整体预测正确率高，与基准模型持平；
- 流失用户精准率 0.7340：预测为流失的用户中，73.4% 是真实流失用户，误判成本可控；
- 流失用户召回率 0.7113：识别出 71.13% 的真实流失用户，相比基准模型（0.48）提升显著，漏判风险大幅降低；
- F1 分数 0.7225：精准率与召回率的平衡值较优，模型对流失用户的识别能力达标；
- AUC 0.8865：模型区分能力稳定，与基准模型接近。

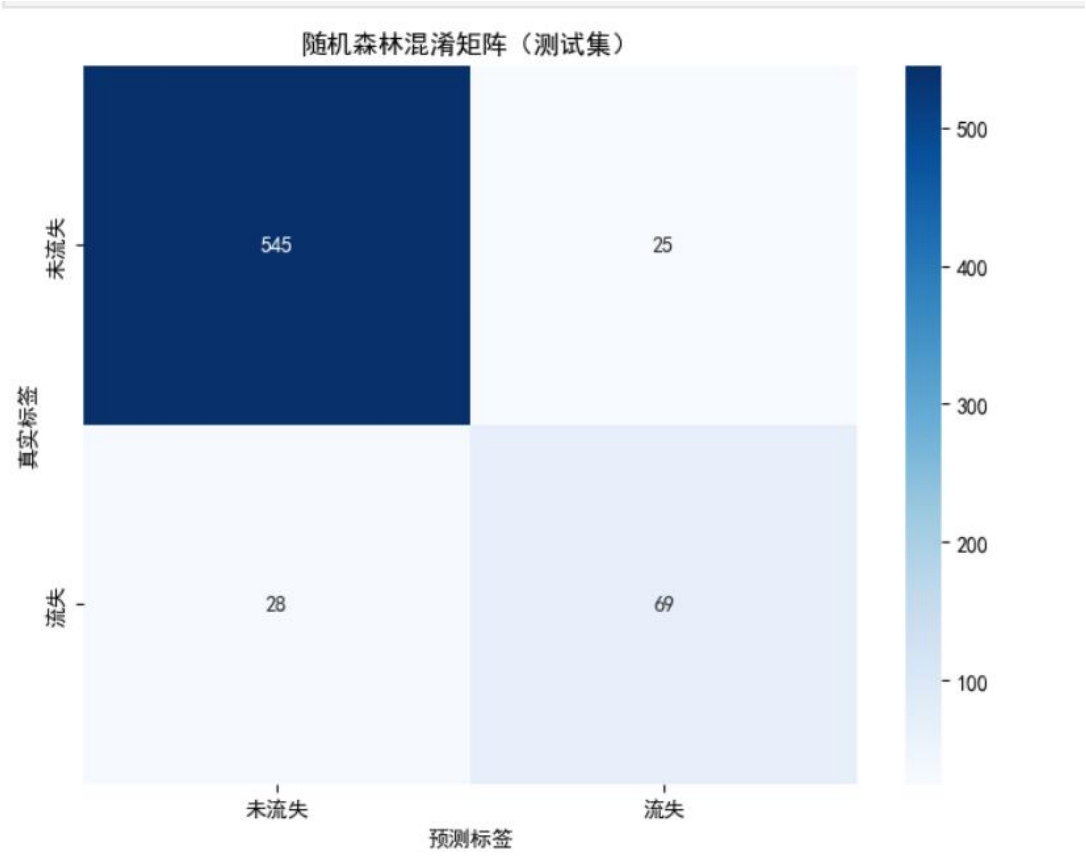


真阴性（545）：未流失用户被正确预测，占比极高，说明模型对 “稳定用户” 的识别能力极强

真阳性（69）：流失用户被正确识别，数量较多，满足业务中 “捕捉高风险用户” 的核心需求

假阴性（28）：流失用户被误判为未流失（漏判），数量较少 —— 仅 28 例

假阳性（25）：未流失用户被误判为流失（误判），数量极少 —— 仅 25 例，避免了不必要的挽留成本浪费。

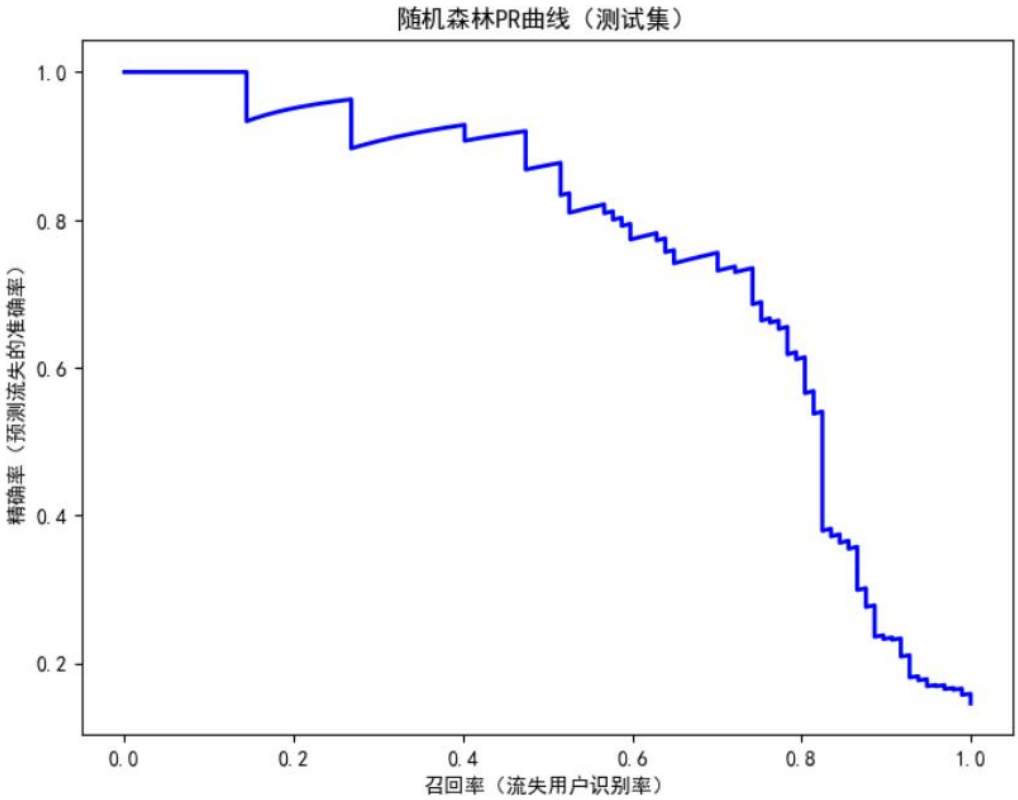


PR 曲线（精准率-召回率曲线）呈现“先平缓后快速下降”的形态：

当召回率(流失用户识别率)低于 0.8 时，精准率保持在 0.7 以上，说明模型在“识别更多流失用户”的同时，能维持较高的判断准确性；曲线整体处于较高区域，反映模型对少数类（流失用户）的预测性能较优。

## （四）特征重要性解读

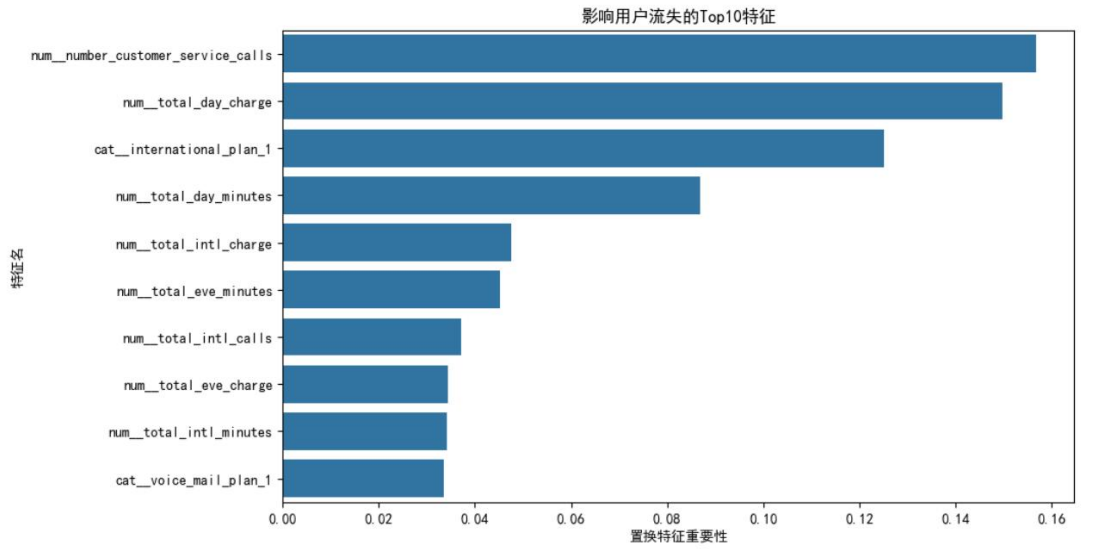


✧ num_number_customer_service_calls（客服呼叫次数）：

重要性最高 —— 用户呼叫客服的次数越多，流失风险越高，反映服务问题是流失核心驱动因素。

✧ num_total_day_charge（白天通话费用）：

重要性第二 —— 白天通话费用越高，用户流失意愿越强，说明费用敏感是关键因素。

✧ cat_international_plan_1（开通国际漫游）：

重要性第三 —— 开通国际漫游的用户流失风险更高，可能因漫游费用高、服务体验差导致。

✧ num_total_day_minutes（白天通话时长）：

与白天费用强相关，进一步验证 “高通话成本用户易流失” 的规律。

### （五）结果输出

```
随机森林模型高流失风险用户数量：332
随机森林模型高流失风险用户Top10：
   state  account_length  number_customer_service_calls      流失概率  \
10    IN            65.0                            3.5  0.792054
15    NY           161.0                            3.5  0.854696
21    CO            77.0                            3.5  0.816337
33    AZ            12.0                            1.0  0.861652
41    MD           135.0                            0.0  0.757612
48    ID           119.0                            3.5  0.771062
54    WY            87.0                            3.5  0.785957
69    TX           150.0                            3.5  0.710511
76    DC            82.0                            0.0  0.888208
77    NY           144.0                            3.5  0.841367

    churn_numeric
10              1
15              1
21              1
33              1
41              1
48              1
54              1
69              1
76              1
77              1
```

高风险用户数量：共 332 人；

Top10 用户特征：

客服呼叫次数（number_customer_service_calls）多为 3.5 次

流失概率高（普遍在 0.71 以上，最高达 0.79）

实际已流失（churn_numeric=1），验证了模型的预测准确性。

## ● 对比和评估模型

### （一）模型核心性能对比

| 模型 | 准确率 | 流失用户精确率 | 流失用户召回率 | F1 分数 | AUC 值 |
|---|---|---|---|---|---|
| Logistic 回归 | 0.720 | 0.290 | 0.660 | 0.406 | 0.7768 |
| 优化后随机森林 | 0.9205 | 0.7340 | 0.7113 | 0.7225 | 0.8865 |

## （二）模型优劣深度分析

### 1. Logistic 回归模型

- **优势**
  - 模型结构简单、训练速度快，可解释性强（通过特征系数直接判断影响方向），能清晰识别国际漫游开通、语音信箱开通等核心驱动因素。
  - 召回率达 66%，在基础识别流失用户的需求上表现尚可，适合快速初步筛选高风险用户。
- **劣势**
  - 精确率仅 29%，误判成本极高（约 71%预测为流失的用户实际未流失），会造成大量挽留资源浪费。
  - 对特征交互关系捕捉能力弱，无法充分利用用户行为与套餐组合的复杂关联，整体区分能力中等（AUC=0.7768）。

### 2. 优化后随机森林模型

- **优势：**
  - 综合性能最优，准确率突破 92%，流失用户精确率达 73.4%，在精准识别流失用户的同时，将误判成本控制在较低水平。
  - 召回率提升至 71.13%，相比 Logistic 回归减少漏判风险，能覆盖更多真实流失用户，满足业务核心需求。

- 特征重要性评估更贴合业务逻辑，可精准定位客服呼叫次数、白天通话费用等关键影响因素，支持精细化策略制定。

- **劣势：**
  - 模型复杂度高于 Logistic 回归，训练时间略长，可解释性相对较弱。
  - 对极端异常值仍有一定敏感性，需依赖前期数据预处理保障性能。

### （三）模型最终选择

综合业务需求与模型性能，**超参数优化后的随机森林模型为最优落地模型**。其核心优势在于平衡了"识别流失用户"与"控制挽留成本"的双重需求，召回率与精确率均处于较高水平，能直接支撑电信公司的实际业务动作；而 Logistic 回归可作为辅助模型，用于快速验证核心特征的影响逻辑。

# 三、建议

## （一）套餐结构优化：降低高成本用户流失风险

1. **国际漫游套餐升级**：针对开通国际漫游（流失风险 TOP3 特征）的用户，推出"短期按需套餐"（如 7 天/15 天灵活套餐），降低单次使用成本；同时附赠漫游流量包，解决用户"通话贵、流量不足"的核心痛点。

2. **白天通话资费调整**：对白天通话时长较长（>200 分钟）、费用较高（>35 美元）的用户，推出"白天畅聊叠加包"，降低单位时长资费，缓解费用敏感型用户的流失意愿（白天通话费用为第二大流失驱动因素）。

3. **语音信箱套餐推广**：因开通语音信箱能显著抑制流失，可将语音信箱服务与基础套餐绑定赠送，或推出"语音信箱+来电提醒"组合增值服务，提升用户粘性。

## （二）服务质量提升：解决核心流失驱动因素

1. **客服服务效率优化**：客服呼叫次数是首要流失驱动因素，需建立"呼叫次数预警机制"——对呼叫次数≥2 次的用户进行主动回访，优先解决账单疑问、信号问题等高频诉求，避免不满积累。

2. **高风险地区专项改进**：针对加州、蒙大拿州等流失率超 24%的高风险地区，调研当地信号覆盖、售后响应速度等问题，针对性加强基

站建设与线下服务网点布局；同时借鉴夏威夷、弗吉尼亚州（流失率<7%）的服务经验，形成可复用的地区服务标准。

3. **国际漫游服务保障**：为开通国际漫游的用户提供"漫游专属客服通道"，提前推送目的地通信规则与资费说明，解决漫游过程中的信号不稳定、账单不透明等问题，提升服务体验。

### （三）精准运营策略：分层挽留高风险用户

1. **高风险用户定向挽留**：针对模型识别出的 332 名高风险用户（流失概率>0.7），采取"一户一策"：
    - 客服呼叫次数≥3 次的用户：安排专属客户经理对接，一次性解决历史问题并赠送 10 元通话抵扣券。
    - 白天高通话成本用户：推送定制化套餐升级方案，承诺升级后 3 个月内资费立减 15%。
    - 开通国际漫游未开通语音信箱的用户：免费赠送 1 个月语音信箱服务，同步推送漫游资费优惠包。
2. **用户生命周期管理**：
    - 新用户（账户时长<30 天）：赠送语音信箱+国际漫游体验包，降低初期流失风险。
    - 稳定用户（账户时长 1-12 个月）：定期推送通话时长与费用分析报告，推荐适配套餐，避免因套餐不适配导致流失。

3. **数据监控与模型迭代**：建立月度用户流失监控机制，跟踪策略执行效果；每季度更新数据集，重新训练模型，纳入新的影响因素（如套餐变更记录、投诉记录），持续提升预测准确性。