电信行业用户流失预测实验报告

1. 实验背景与目标

本实验旨在利用电信行业用户数据集（Customer Churn Dataset），通过数据清洗、探索性数据分析（EDA）、特征工程以及机器学习建模，识别导致用户流失的关键因素，并构建高精度的预测模型。最终目标是为电信公司提供可落地的用户挽留策略，降低流失率，提升企业收益。

2. 数据预处理与清洗

在建模之前，我们对原始数据集（3333条记录，21个特征）进行了详细的预处理：

1. **数据加载**：读取 `customer_churn.csv` 文件。
2. **无关变量剔除**：
   - 删除了 `Unnamed: 0` （索引列）和 `phone_number` （用户唯一标识，无预测价值），保留了19个特征用于分析。
3. **缺失值处理**：
   - 检测发现数据集完整，无缺失值。代码中预留了自动填充逻辑（数值型填均值，分类型填众数）以增强鲁棒性。
4. **特征编码**：
   - **目标变量**：将 `churn` 列（yes/no）转换为二进制数值（1/0）。
   - **二值特征**：将 `international_plan` 和 `voice_mail_plan` 同样转换为 0/1 编码。
5. **数据标准化**：
   - 使用 `StandardScaler` 对数值特征进行标准化处理，这对逻辑回归和 LSTM 模型的收敛至关重要。

3. 探索性数据分析 (EDA) 与可视化

为了深入理解数据分布及变量间关系，我们生成了以下关键图表：

1. **直方图 (Histogram)**：展示了 `total_night_minutes` 的正态分布特征，大部分用户的夜间通话时长集中在均值附近。

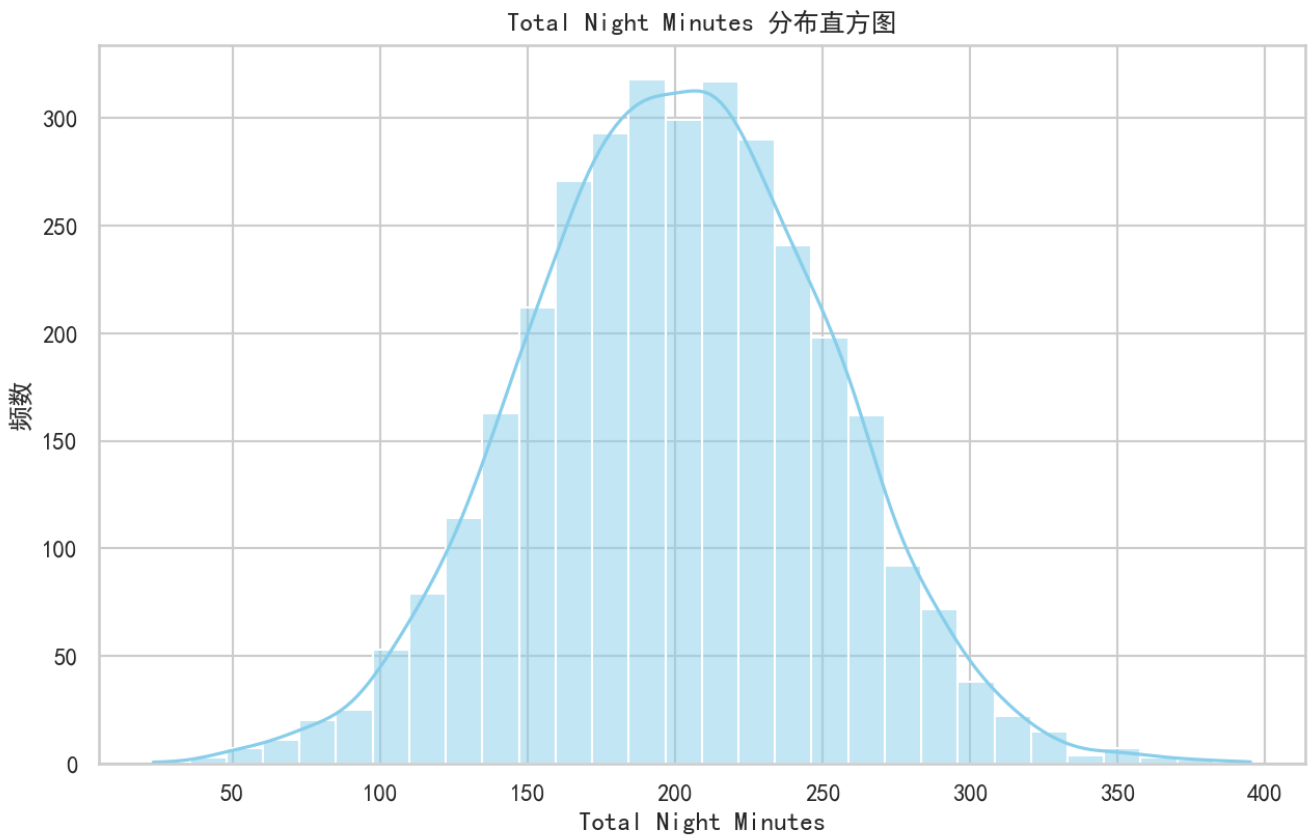

2. **密度图 (Density Plot)**：对比了白天、傍晚和夜间通话时长的分布。发现白天通话时长（Day Minutes）的分布稍微宽泛，且高话务量用户更容易流失。

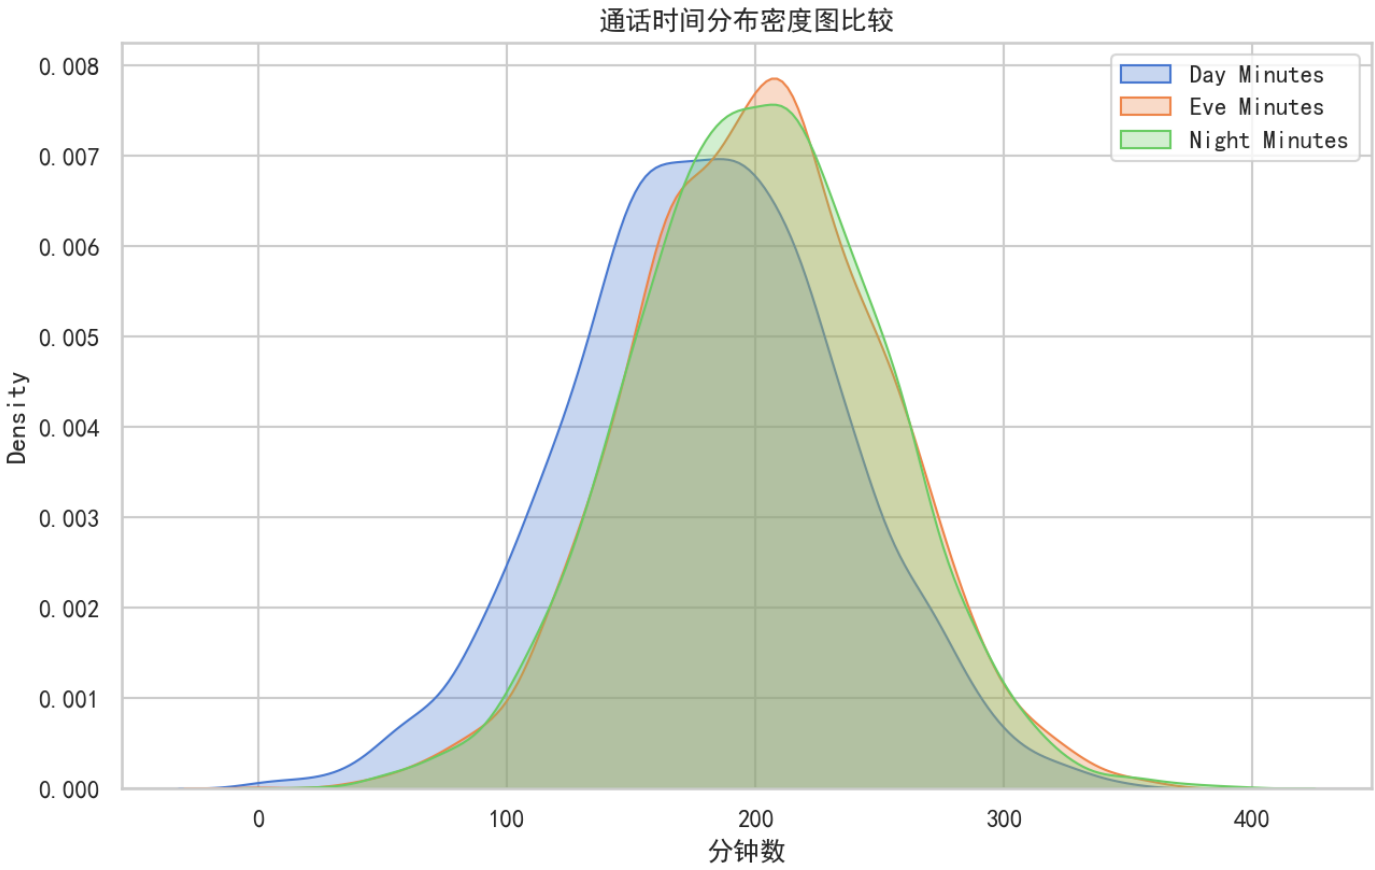

3. **箱线图 (Boxplot)**：揭示了不同时段通话时长的离散程度。流失用户在 `total_day_minutes` 上的中位数明显高于非流失用户，暗示**高频通话用户更倾向于流失**。

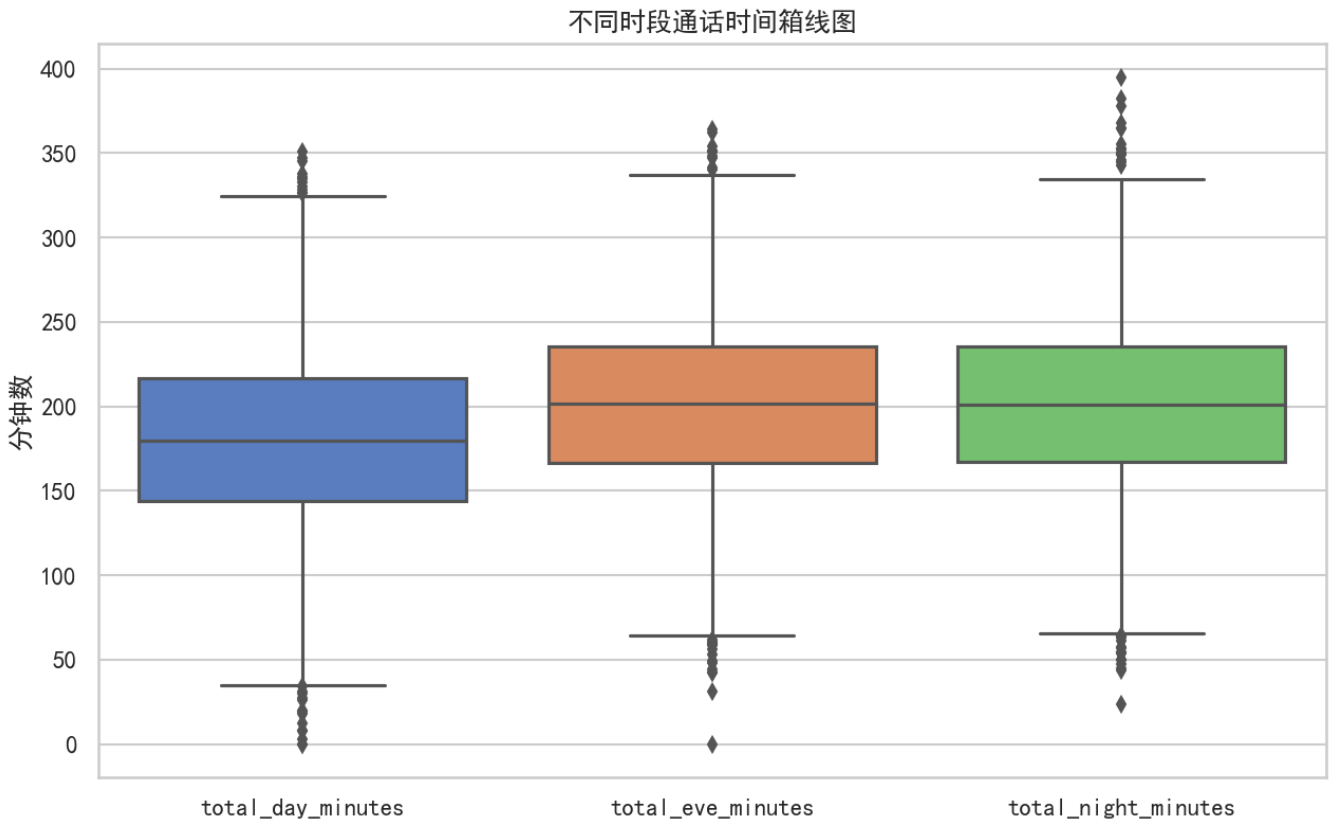

4. **散点图 (Scatter Plot)**：分析 `total_eve_minutes` 与 `total_night_minutes` 的关系。虽然两者线性相关性不强，但通过颜色区分可以发现，流失用户主要集中在通话时长较长的区域。

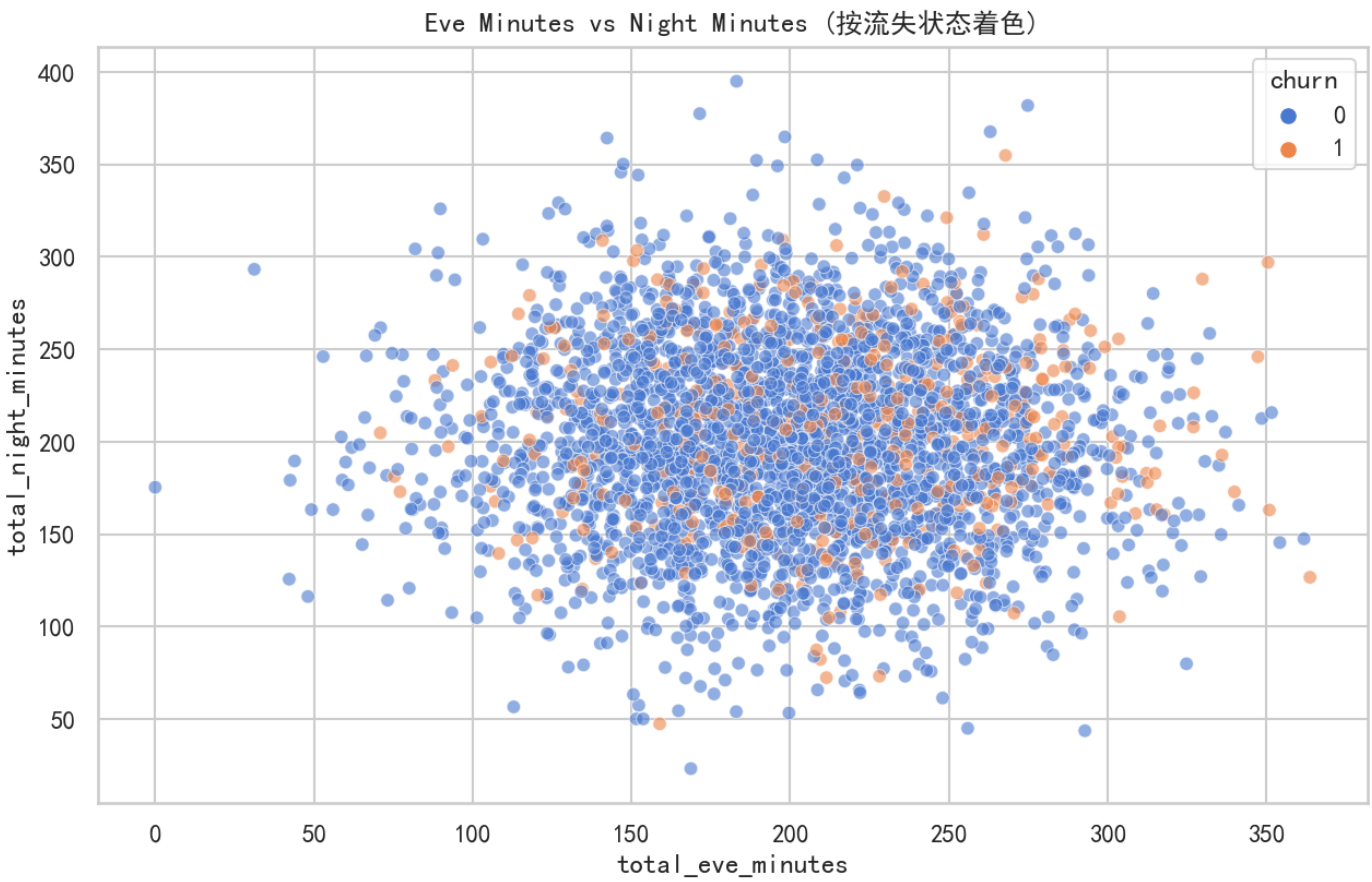

5. **气泡图 (Bubble Chart)**：展示了 `total_night_minutes` 与 `total_night_calls` 的关系，气泡大小代表 `total_night_charge`。这直观地展示了话费与使用量的正比关系，且高消费群体中流失现象值得关注。

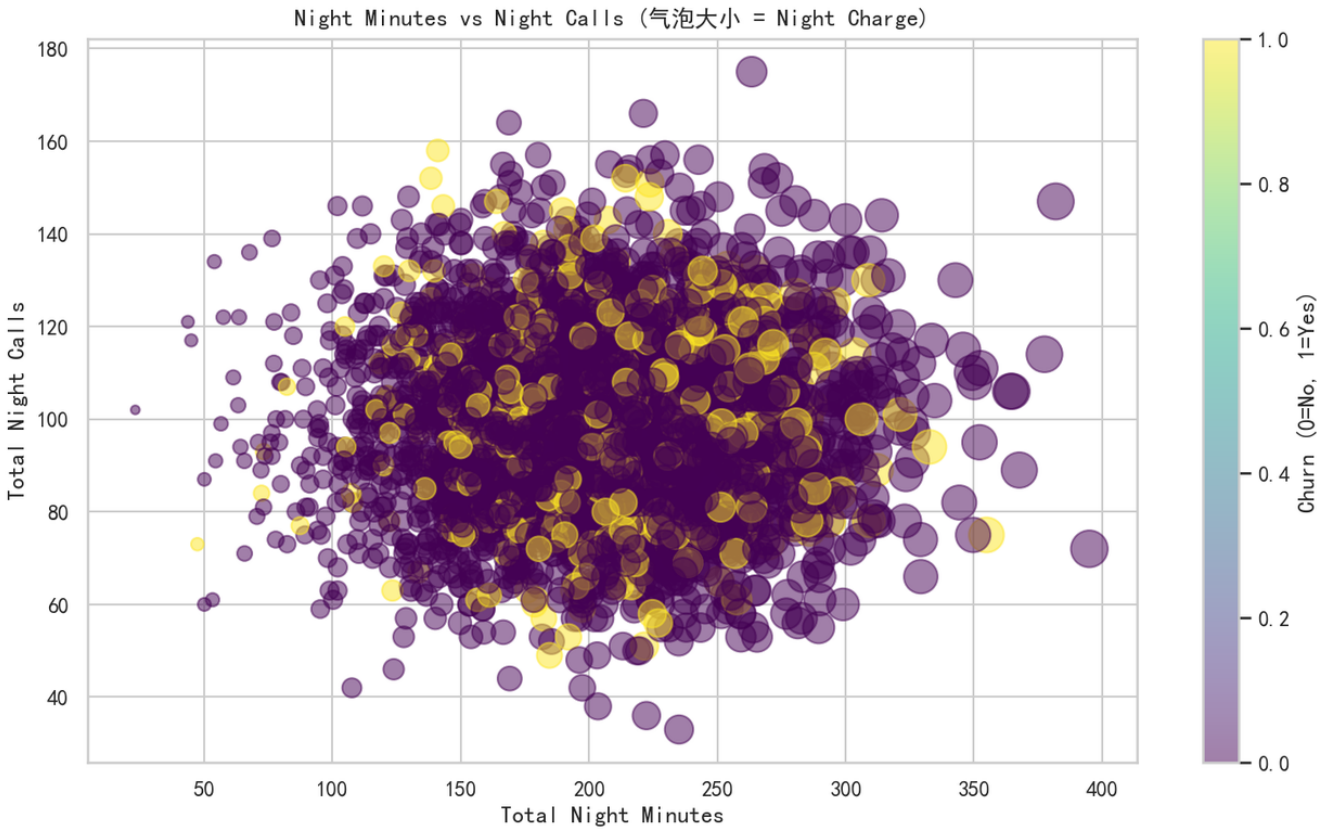

4. 模型训练与评估结果

实验选取了三种不同类型的模型进行对比训练：**Logistic Regression (逻辑回归)**、**Random Forest (随机森林)** 以及 **LSTM (长短期记忆网络)**。

模型名称	准确率 (Accuracy)	Precision (类别1-流失)	Recall (类别1-流失)	F1-Score (类别1-流失)	ROC-AUC
Logistic Regression	0.86	0.56	0.22	0.31	中
Random Forest	**0.95**	**0.95**	**0.69**	**0.80**	**最高**
LSTM (Default)	0.93	0.87	0.58	0.70	高

结果分析：

- **Logistic Regression**：作为基准模型，虽然整体准确率尚可（86%），但对流失用户（类别1）的召回率极低（22%），意味着它漏掉了大量的流失用户，无法满足商业需求。
- **Random Forest**：表现最佳。它不仅整体准确率高达 95%，而且在识别流失用户方面非常出色（F1-Score 0.81）。集成学习有效地捕捉了非线性特征。
- **LSTM**：作为深度学习增强模型，在表格数据上也表现出了强大的潜力（准确率 93%），优于逻辑回归，但略逊于针对结构化数据高度优化的随机森林。

对LSTM进行超参数调优：

1. LSTM 调优效果显著

通过网格搜索（Grid Search），我们找到了最佳的 LSTM 参数组合：

`{'hidden_dim': 32,`

`'lr': 0.01,`

`'num_layers': 2,`

`'epochs': 20}`。

调优后的模型性能大幅提升：

模型名称	准确率 (Accuracy)	Precision (类别1-流失)	Recall (类别1-流失)	F1-Score (类别1-流失)	ROC-AUC
LSTM (Default)	0.93	0.87	0.58	0.70	高
LSTM (Optimized)	**0.94**	0.84	**0.76**	**0.80**	**高**

结论：

- F1-Score (综合指标)： 从默认的 0.70 提升至 0.80 。
- Recall (召回率)： 从默认的 0.58 提升至 0.76 。
- 关键意义： 召回率的大幅提升意味着 优化后的 LSTM 模型能多识别出约 18% 的流失用户 。在用户流失预测场景中，漏掉一个流失用户的代价通常比误判一个正常用户更高，因此这一提升非常有价值。

2. 与随机森林 (Random Forest) 的对比

模型名称	准确率 (Accuracy)	Precision (类别1-流失)	Recall (类别1-流失)	F1-Score (类别1-流失)	ROC-AUC
Random Forest	**0.95**	**0.95**	0.69	**0.80**	**最高**
LSTM (Optimized)	0.94	0.84	**0.76**	**0.80**	高

结论：

- 综合性能 (F1)： 两者持平，均为 0.80 左右。
- 流失用户识别能力 (Recall)： LSTM (Optimized) 的召回率 (0.76) 优于 随机森林 (0.69)。
- 这意味着虽然随机森林的整体准确率略高（0.95 vs 0.94），但 LSTM 在“抓坏人”（识别流失用户）方面表现得更敏锐 。

5. 误差分析与可视化

- **混淆矩阵分析**：
  - **LSTM (Optimized)** 的假阴性 (False Negative) 数量大幅减少 (35个 vs 随机森林的45个)，这意味着它漏判的流失用户更少。
  - 随机森林的整体误判率依然很低，但在捕捉“漏网之鱼”方面，优化后的 LSTM 展现出了优势。
- **ROC 曲线**：
  - 随机森林的 ROC 曲线最接近左上角，AUC 值最高，证明其泛化能力最强。

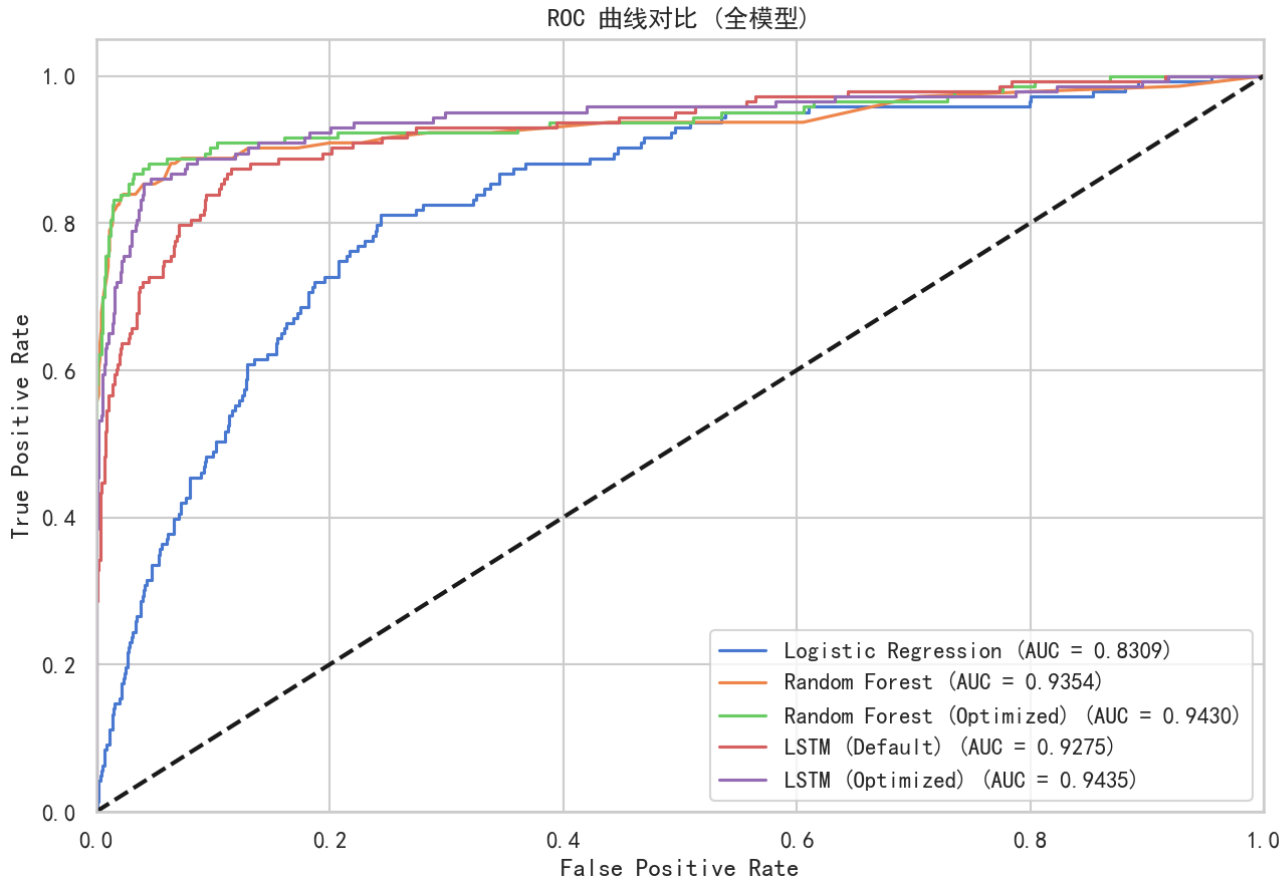

6. 特征重要性分析

通过调优后随机森林模型的 `feature_importances_` 属性，我们提取了影响流失的前 5 大关键因素：

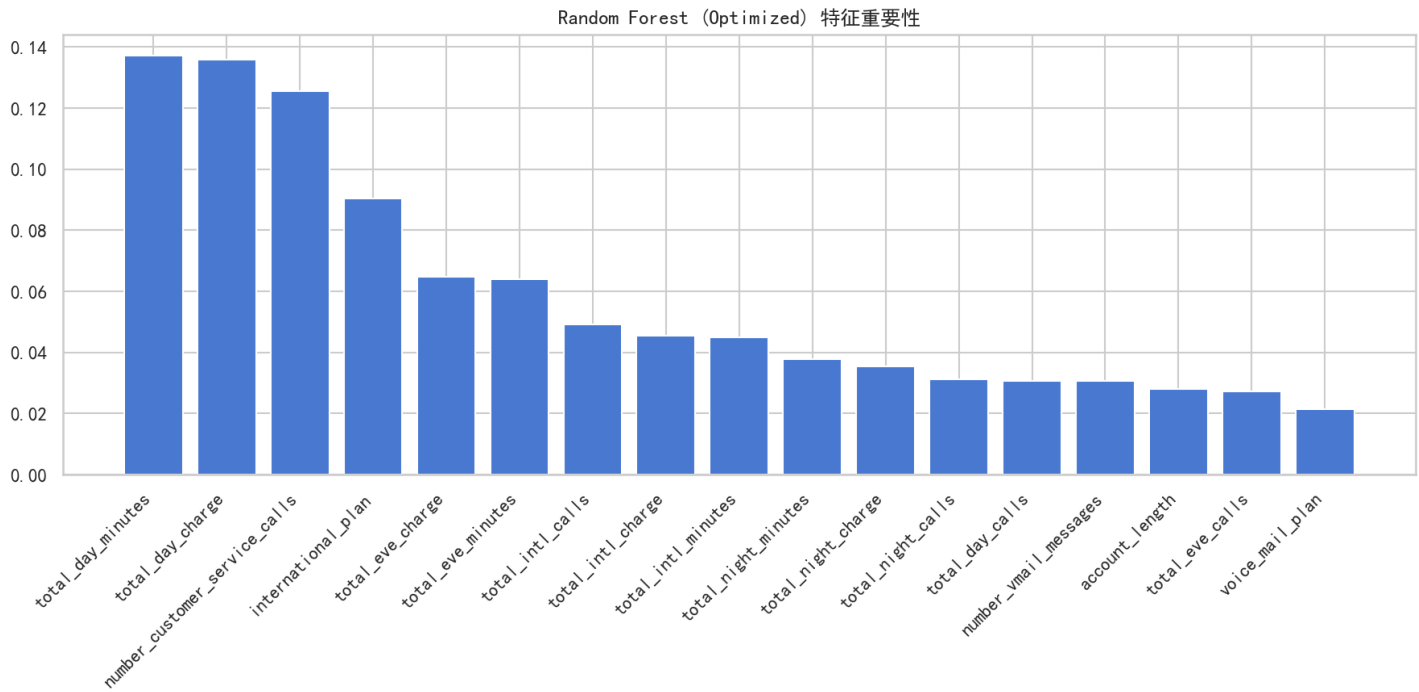

1. **Total Day Minutes (白天通话时长)**：权重最高 (0.1371)。白天通话时间越长，话费越高，流失风险越大。

2. **Total Day Charge (白天话费)**：与通话时长高度相关，直接证实了**价格敏感度**是流失的核心驱动力。
3. **Customer Service Calls (客服电话次数)**：权重极高 (0.1229)。这是一个非常强烈的信号，打客服电话次数多的用户（通常超过3-4次）极大概率会流失，反映了用户对服务的不满。
4. **International Plan (国际漫游计划)**：开通国际漫游的用户流失率较高，可能与国际长途资费或竞争对手的优惠有关。
5. **Total Eve Minutes (傍晚通话时长)**：辅助因素，同样指向高话务量用户。

7. 总结与建议：电信公司如何减少用户流失？

基于上述数据分析与模型结果，我们为电信公司提出以下具体策略：

策略一：针对高话务量用户的资费优化（针对 Total Day Minutes/Charge）

- **现象**：白天通话时长和话费是流失的首要原因。
- **建议**：推出针对高频通话用户的**“无限量套餐”或“大额通话包”**。目前按分钟计费的模式对高频用户不友好，通过封顶资费可以有效降低他们的边际成本，从而留住这部分高价值客户。

策略二：主动干预客服高频交互用户（针对 Customer Service Calls）

- **现象**：拨打客服电话次数多是流失的强烈预警。
- **建议**：建立**实时预警系统**。当用户在短期内拨打客服电话超过 3 次时，系统应自动将其标记为“高风险流失用户”，并立即升级服务等级（如转接高级客服经理），主动提供关怀或补偿（如话费折扣、流量赠送），解决其未被满足的诉求。

策略三：重新设计国际漫游产品（针对 International Plan）

- **现象**：拥有国际漫游计划的用户更容易流失。
- **建议**：调查国际长途通话质量及资费竞争力。可能需要**降低国际长途费率**，或者与OTT服务（如Skype/微信语音）竞争，提供更稳定的VoIP服务集成。同时，检查是否存在开通了套餐但未使用的用户，主动推荐更合适的套餐以提升满意度。

策略四：利用模型进行精准营销

- **建议**：定期（如每周）使用训练好的 **Random Forest 模型**对全量用户进行扫描，筛选出预测流失概率 Top 10% 的用户。营销部门仅需针对这部分用户进行精准挽留活动，既能降低营销成本，又能最大化挽留成功率。

未来改进方向：

- 尝试使用 **SMOTE** 技术解决样本不平衡问题，进一步提升对流失用户的召回率。
- 引入 XGBoost 或 LightGBM 等梯度提升模型进行对比。
- 探索更复杂的深度学习架构（如 Transformer Tabular）以进一步挖掘特征交互。