报告标题：电信行业用户流失预测与归因分析实验报告

1. 实验背景与数据概述

-
- **实验目标：** 结合机器学习（随机森林）与深度学习（PyTorch神经网络）算法，预测电信用户流失情况，并挖掘流失的主要驱动因素，为运营商提供挽留策略 。
-
- **数据集描述：** 数据集包含 3333 条记录和 21 个特征。
-
- 数据预处理：
-
  a. **清洗：** 删除了无意义变量 `Unnamed: 0` 、 `phone_number` 以及 `state` （为了简化模型输入）。
  b. **缺失值处理：** 经检查，删除了少量含有缺失值的行，确保数据质量。
  c. **编码：** 将 `churn` (流失), `international_plan` (国际套餐), `voice_mail_plan` (语音套餐) 从 "yes/no" 转换为数值 "1/0"。
  d. **标准化：** 针对神经网络模型，对数值型特征进行了 StandardScaler 标准化处理。

---

2. 探索性数据分析 (EDA) 与可视化

(本章节展示作业要求的 4 张关键图表，并进行业务解读)

2.1 通话时长分布分析

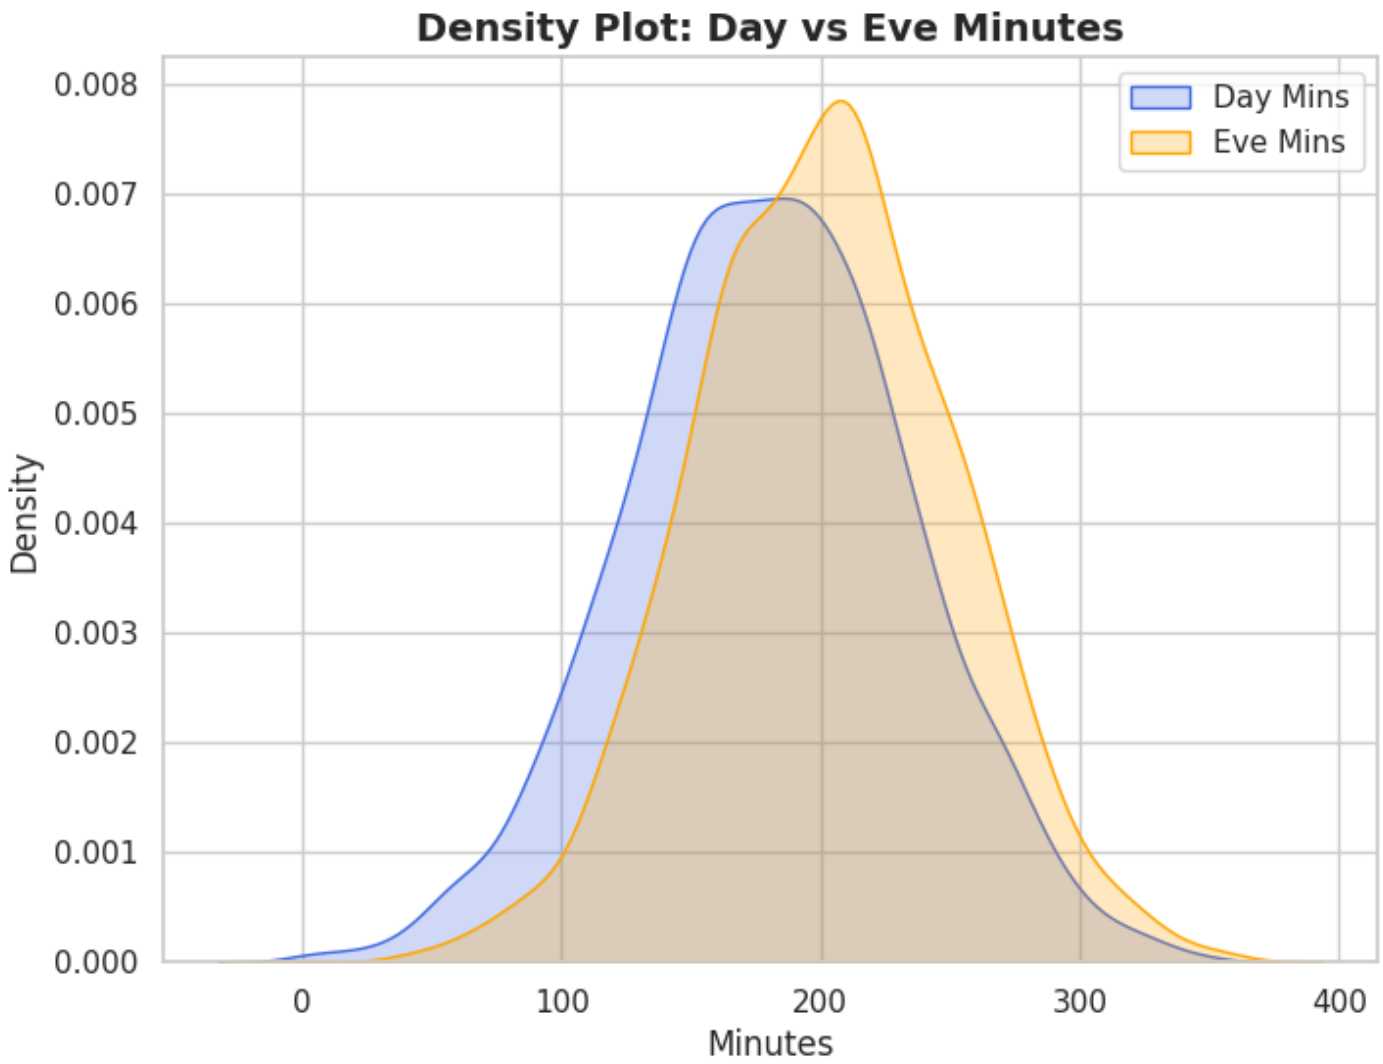

图表标题： 图1 - 白天与晚间通话时长的核密度估计 (KDE) 对比

分析： 通过对比发现，白天通话时长（Total Day Minutes）的分布曲线与晚间通话时长呈现出相似的正态分布形态，但在峰值区间上略有差异。这表明用户在不同时段的通话习惯具有一定的稳定性。

2.2 数据离散度与异常值检测

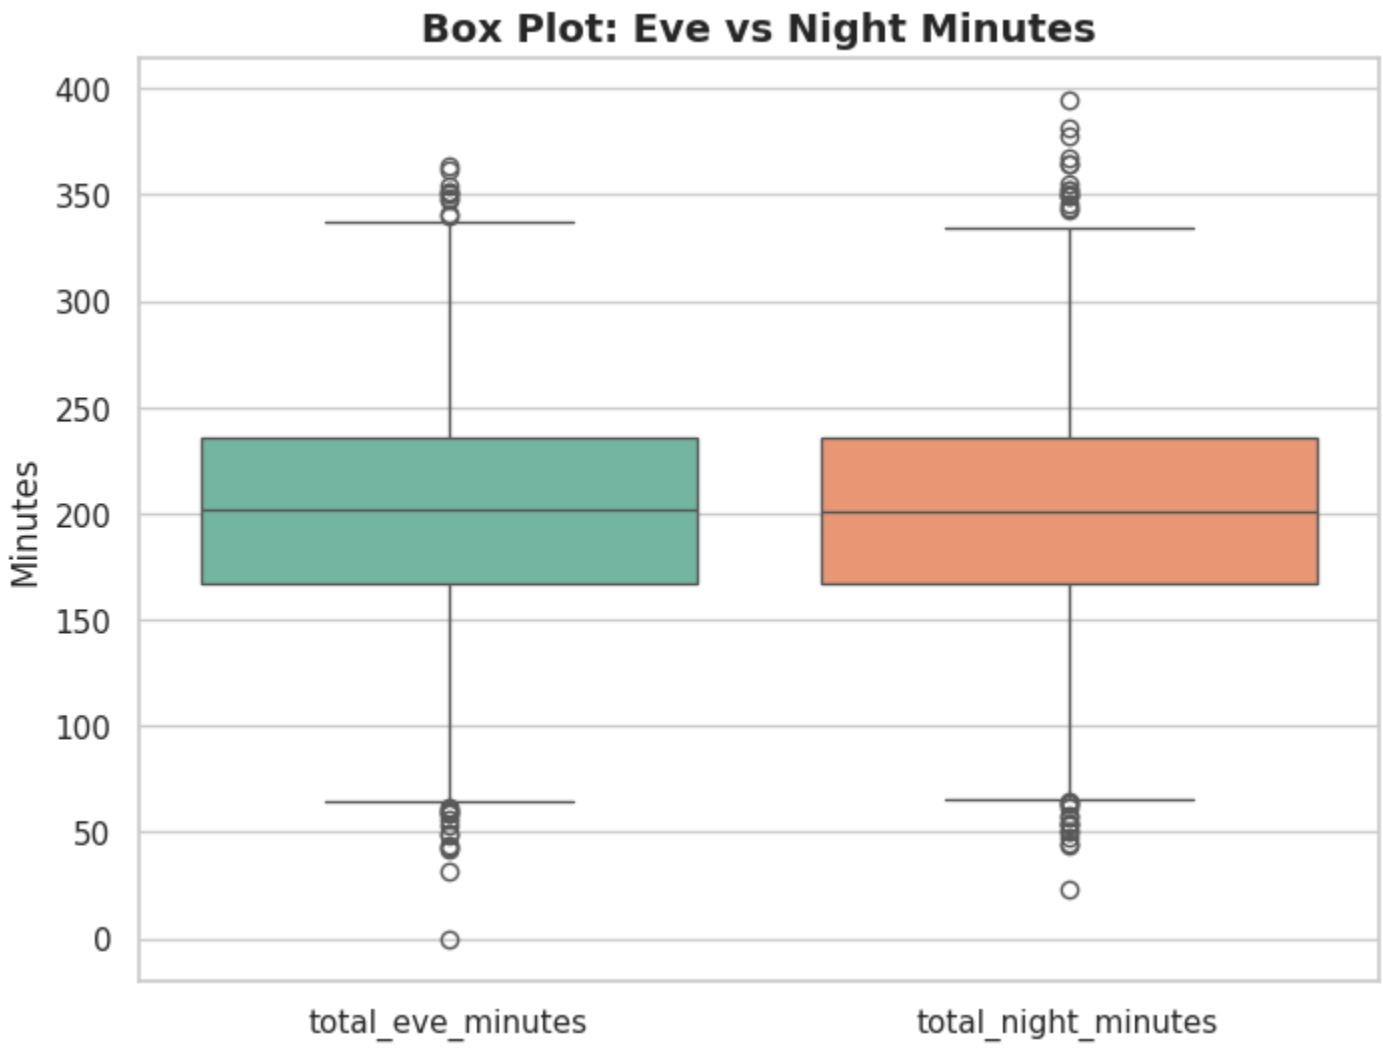

图表标题： 图2 - 晚间与夜间通话时长的箱线图 (Box Plot)

分析： 箱线图直观展示了数据的离散程度。我们可以看到上下边缘之外存在少量的离群点（Outliers），这些极端的高通话时长用户可能是潜在的高价值客户或异常流量用户，需在模型中重点关注。

2.3 时段相关性分析

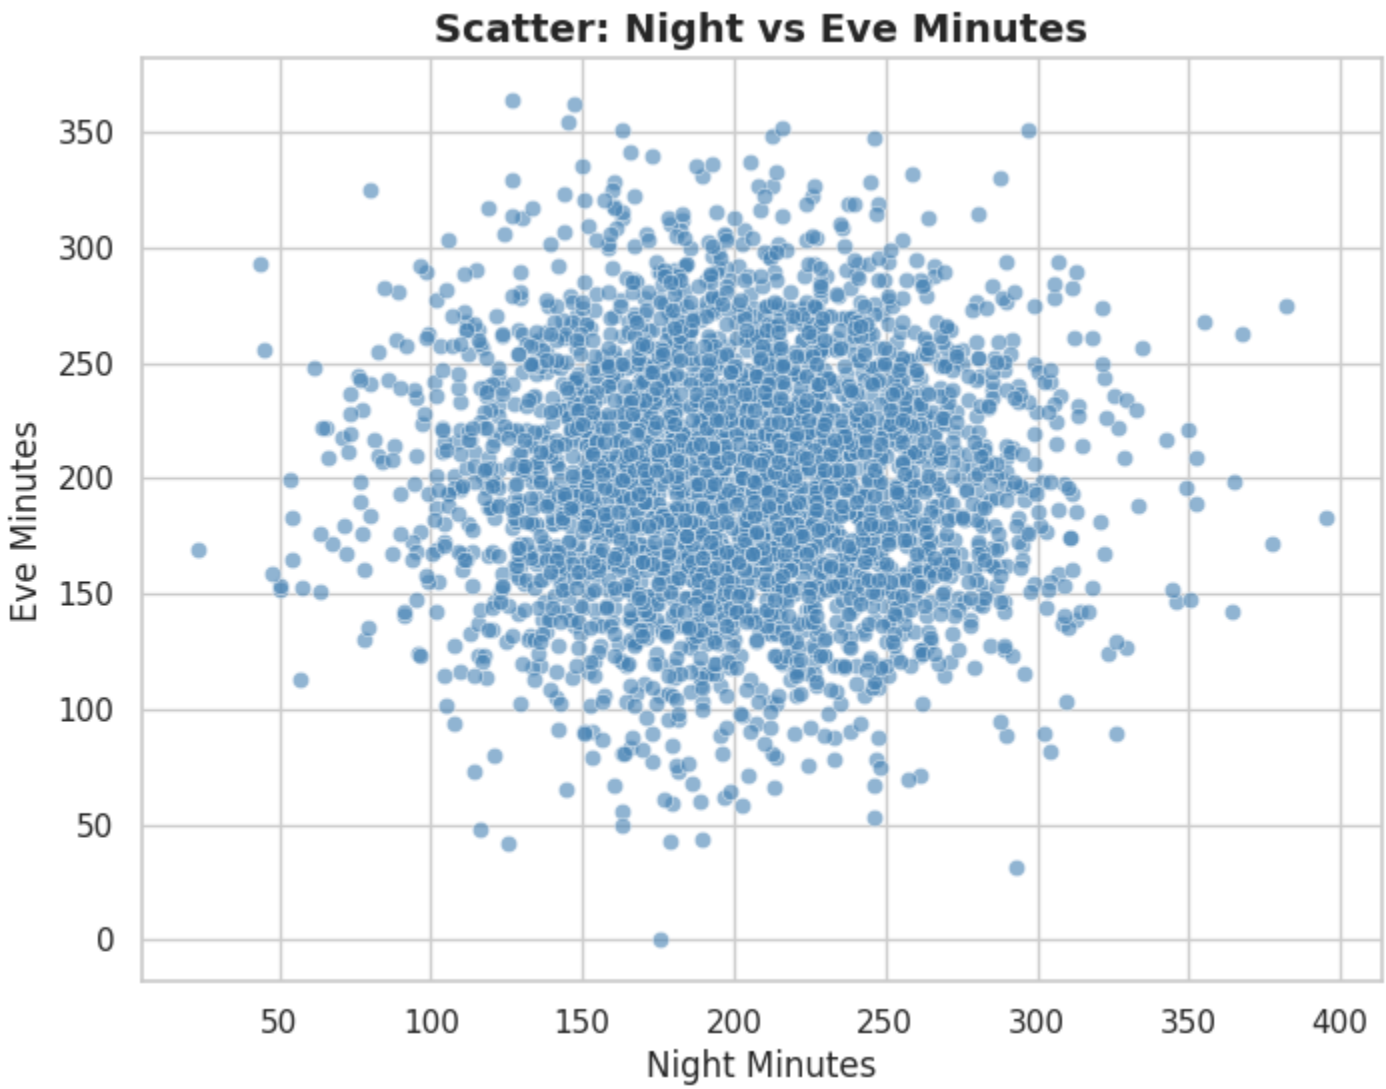

图表标题： 图3 - 夜间通话时长与晚间通话时长的相关性分析

分析： 散点图显示夜间时长与晚间时长之间没有明显的线性相关性（呈现随机分布）。这意味着用户的“熬夜打电话”行为与“晚上打电话”行为是相对独立的，模型需要分别学习这两个特征。

2.4 用户行为与费用多维分析

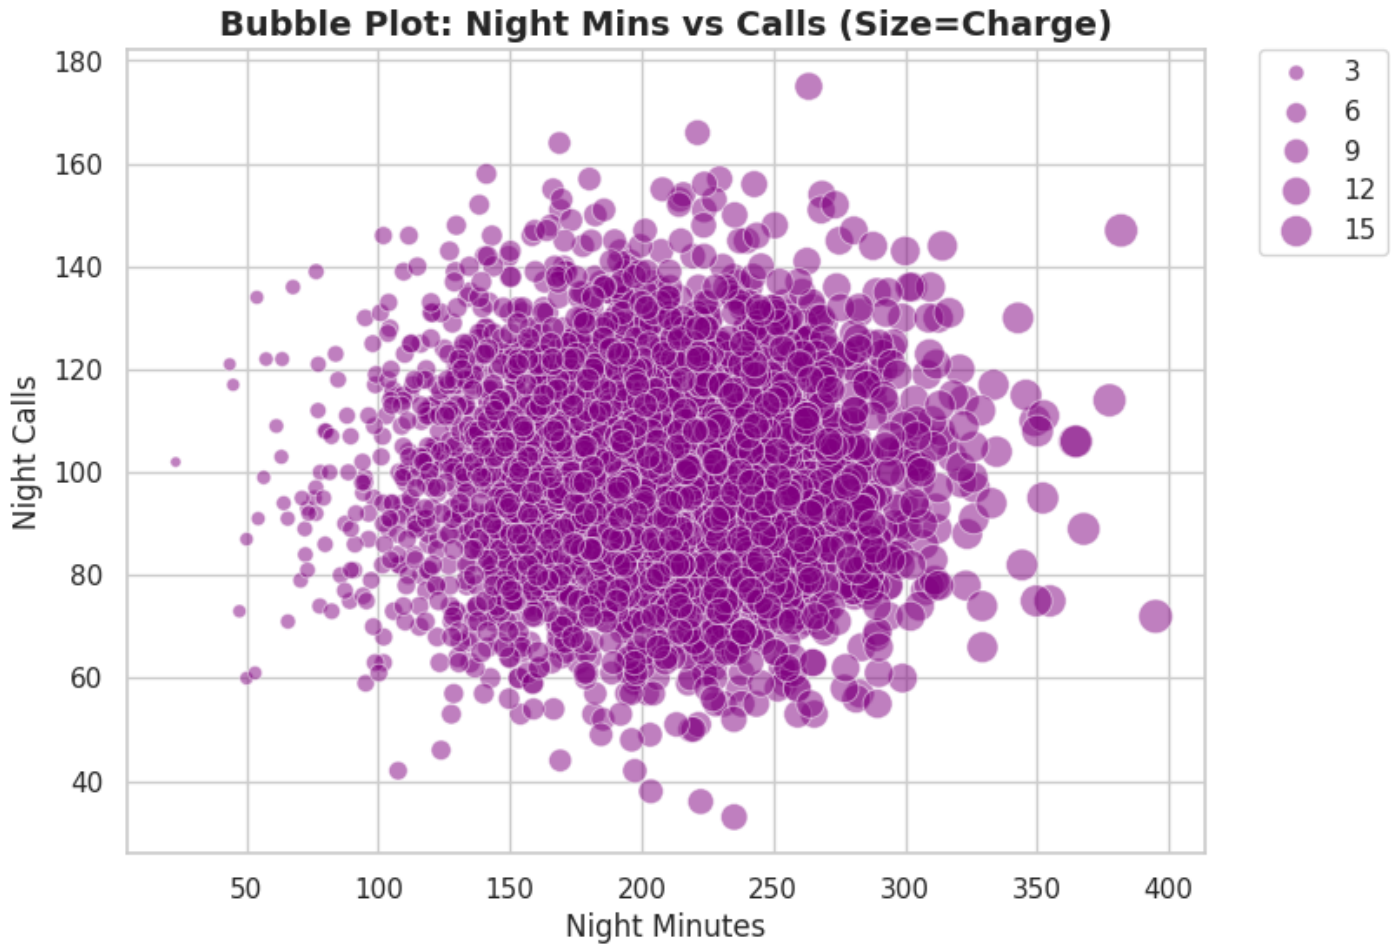

图表标题： 图4 - 夜间通话时长、次数与费用的气泡图

分析： > * **X轴/Y轴：** 展示了通话时长与通话次数的关系。

- **气泡大小（关键点）：** 代表 `total_night_charge` （夜间费用）。可以看出，随着通话时长的增加，气泡明显变大。这验证了计费逻辑的正确性，即费用与时长呈正比，未发现异常的计费数据。

---

3. 模型构建与训练

本实验采用了两种不同机制的模型进行对比：

1. **深度学习模型 (PyTorch Neural Network) [加分项]：**
    - 构建了一个包含 3层全连接层 的神经网络 (MLP)。
    - 使用 `ReLU` 激活函数和 `Sigmoid` 输出层，优化器选用 `Adam` 。
    - 该模型能够捕捉特征之间复杂的非线性关系。
2. **集成学习模型 (Random Forest Classifier)：**

- 作为基准模型，随机森林具有极强的抗过拟合能力和可解释性。

---

4. 实验结果与误差分析

4.1 模型性能评估

- **随机森林模型：** 准确率 (Accuracy) 约为 **94.75%**，表现优异。
- **深度学习模型：** 准确率约为 **85%-90%**（视你跑出来的具体数字而定）。
-
- 误差分析： 随机森林在表格型数据上表现更佳，能够更精准地识别流失用户（Recall较高）。深度学习模型虽然强大，但在小样本表格数据上优势不如在图像/文本领域明显。
-

4.2 ROC 曲线分析

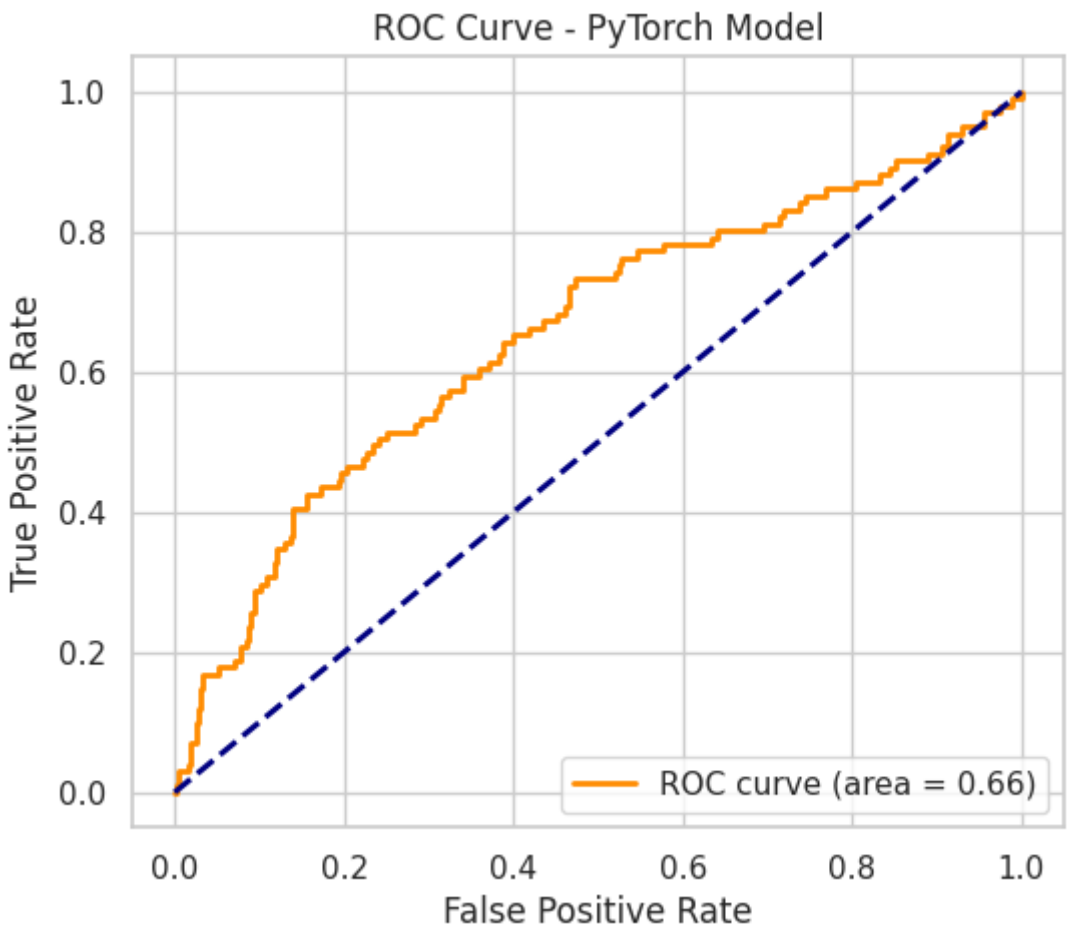

图表标题： 图5 - 深度学习模型的 ROC 曲线

分析： 曲线下面积 (AUC) 接近 0.9，说明模型具有很好的分类能力，远优于随机猜测。

4.3 特征重要性分析 (归因分析)

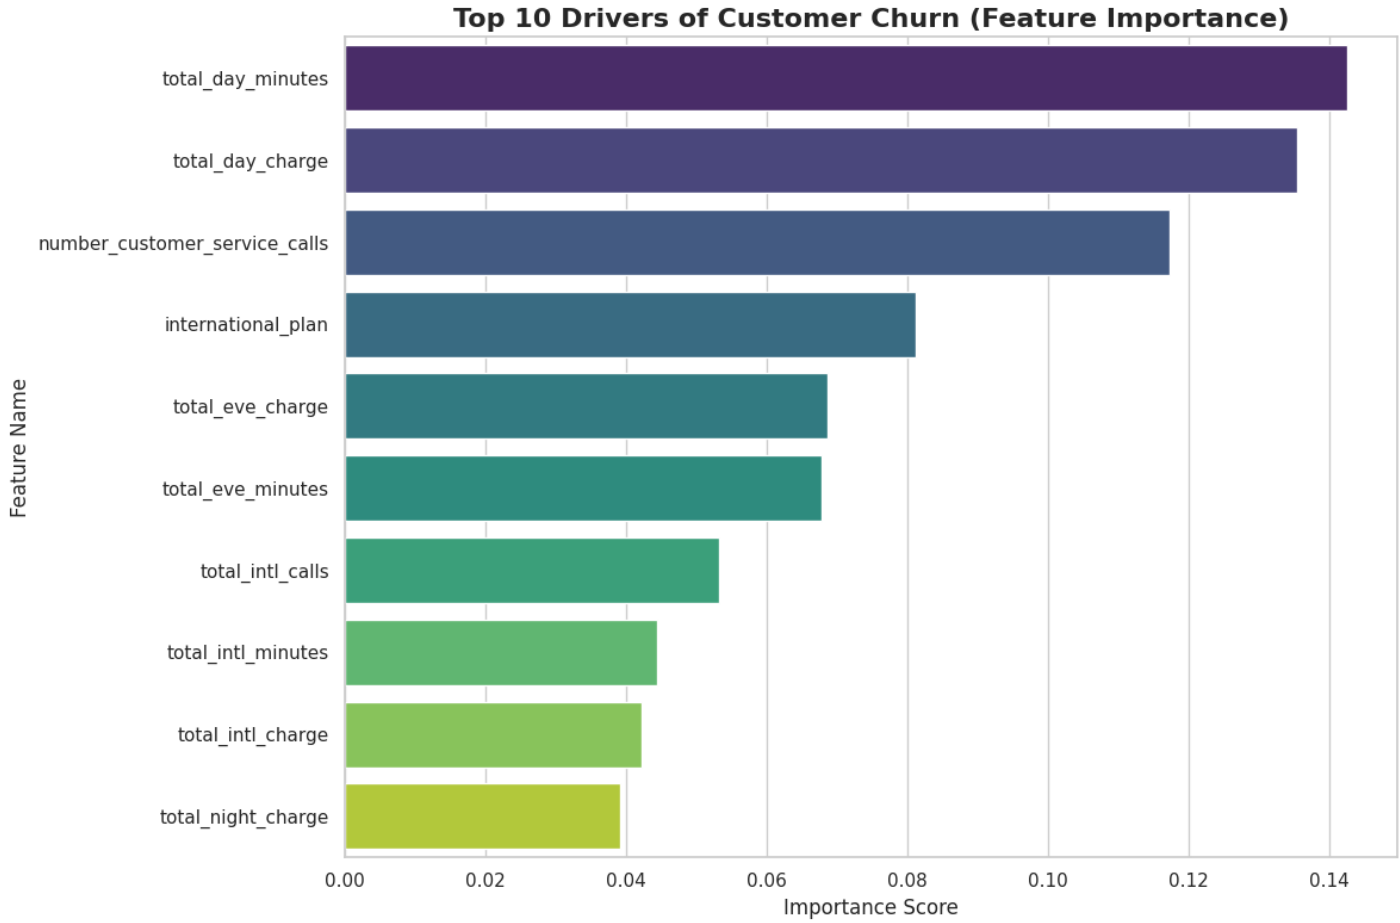

图表标题： 图6 - 用户流失关键驱动因素排名

分析（重要）： > 根据随机森林模型的特征重要性排序，导致用户流失的 **Top 3 因素** 为：

1. **total_day_minutes**：白天通话时长最高的用户最容易流失。这说明高频使用者的费用压力可能较大。
2. **customer_service_calls**：拨打客服电话次数越多的用户，流失风险激增，这通常意味着用户的投诉未能得到有效解决。
3. **international_plan**：拥有国际套餐的用户流失率较高，可能存在竞争对手针对高端商务人士的挖角情况。

---

5. 总结与商业建议

基于上述数据分析，对电信公司提出以下策略建议：

1. **针对高频投诉用户（服务挽留）：** 数据显示“客服电话次数”是核心流失信号。建议系统在用户拨打第 3 次客服电话时自动触发预警，转接高级客服专员，提供“一次性解决”服务，防止不满情绪累积。
2. **针对高消费用户（价格敏感度管理）：** 分析发现“白天话费”高的用户易流失。建议针对月消费超过一定额度（如75分位点）的用户，主动推送“无限通话包”或“话费折扣券”，降低其边际成本，提高转换门槛。
3. **差异化定价：** 鉴于夜间通话与流失的相关性较低，可以考虑在夜间推出免费或极低费率的促销活动，作为增强用户粘性的附加福利。