电信行业用户流失分析

1. 引言

本报告围绕电信用户流失（churn）展开，目标是通过数据理解、可视化与机器学习建模，识别影响流失的关键因素，并提出可操作的保留策略。

2. 核心技术栈

Pandas / Matplotlib / Seaborn / Scikit-learn（如环境允许加入 XGBoost）；中文字体渲染以提升报告可读性。

3. 数据理解

- 数据规模：3333 条记录，20 个特征；流失率约 0.145。
- 特征分类：
  - 身份与区域：`state`（州）、`account_length`（账户时长）、`area_code`（区号）。
  - 套餐信息：`international_plan`（国际套餐）、`voice_mail_plan`（语音信箱）。
  - 使用行为与费用：`total_day_*`、`total_eve_*`、`total_night_*`（分钟/通话次数/费用）。
  - 国际通话：`total_intl_minutes`、`total_intl_calls`、`total_intl_charge`
  - 服务交互：`number_customer_service_calls`（客服呼叫次数）。
- 目标变量：`churn`（1=流失，0=未流失）。

4. 数据处理步骤

- 删除无关索引列（如 `Unnamed:0`）。
- 类型规范与二值编码：`yes/no→1/0`；类别与数值列分离。
- 缺失与重复：
  - 缺失统计：{}。
  - 重复记录：0。
- 标准化：对线性与MLP模型的数值特征进行标准化。

5. 特征逐项解释

- `state`：用户所在州，用于区域差异分析与策略分层。

- `account_length`：账户存续时长，衡量关系稳定性。
- `area_code`：区号，反映区域电信资源与费用策略差异。
- `international_plan`：是否开通国际套餐，影响国际通话费用与行为。
- `voice_mail_plan`：是否开通语音信箱，反映用户对附加服务需求。
- `total_day_minutes/calls/charge`：白天通话强度、频次与费用。
- `total_eve_minutes/calls/charge`：晚间通话强度、频次与费用。
- `total_night_minutes/calls/charge`：夜间通话强度、频次与费用。
- `total_intl_minutes/calls/charge`：国际通话行为与费用强度。
- `number_customer_service_calls`：客服交互频次，反映问题密度与满意度风险。

6.探索性数据分析（EDA）

6.1 流失分布

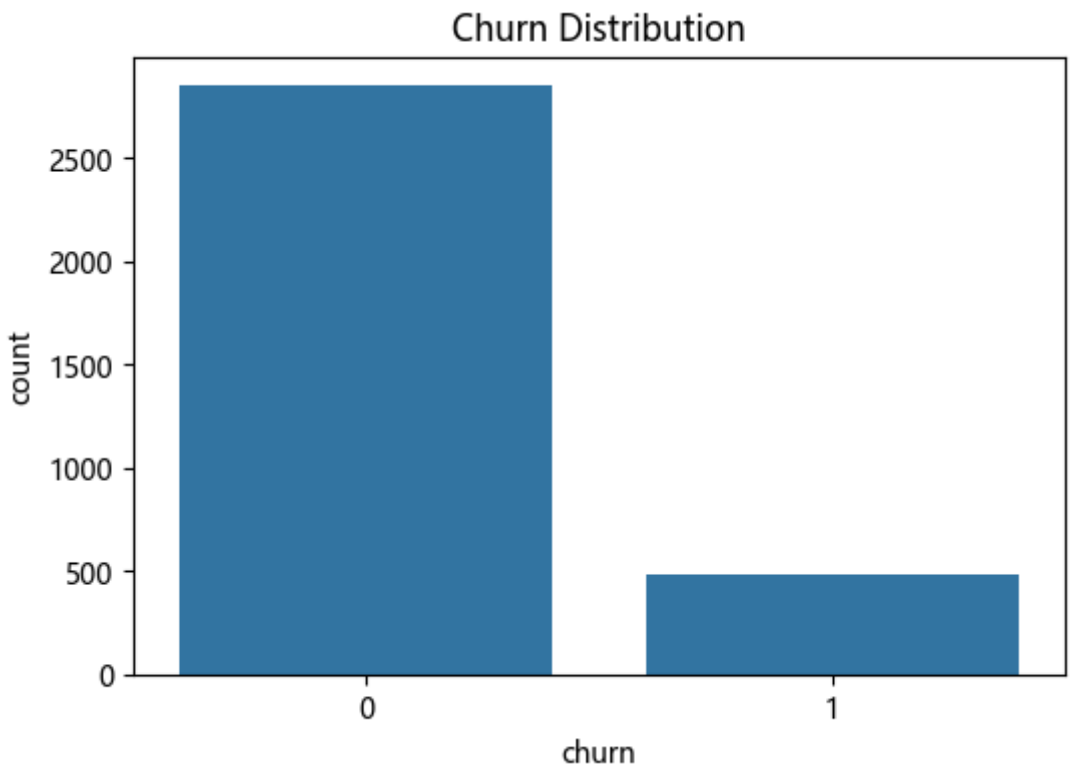

该图展示总体流失占比，便于评估类别不平衡程度与后续模型目标（提升召回或综合指标）。

6.2 各时段分钟分布

- 图2 白天分钟分布：

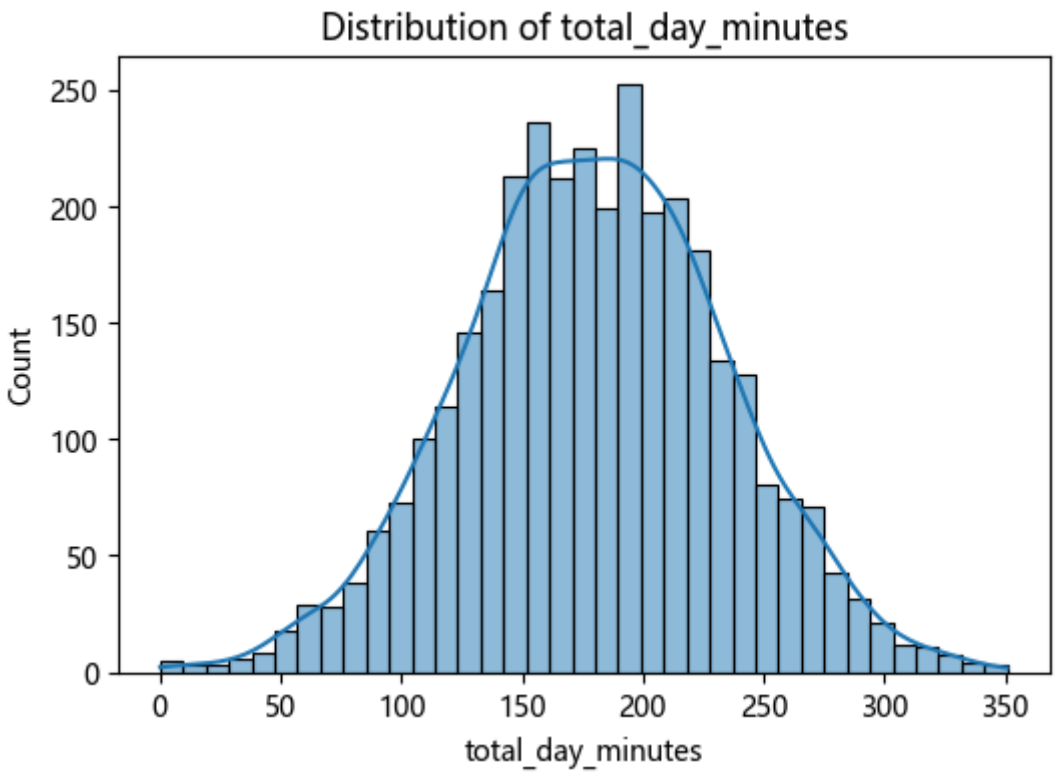

- 图3 晚间分钟分布：

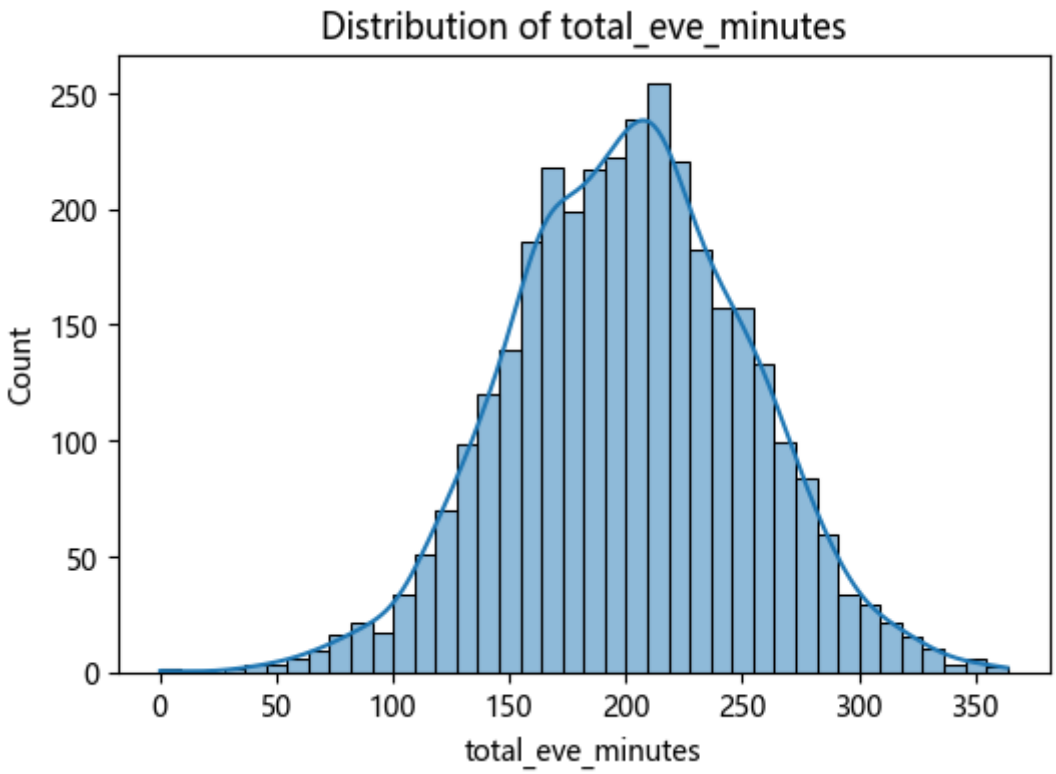

- 图4 夜间分钟分布：

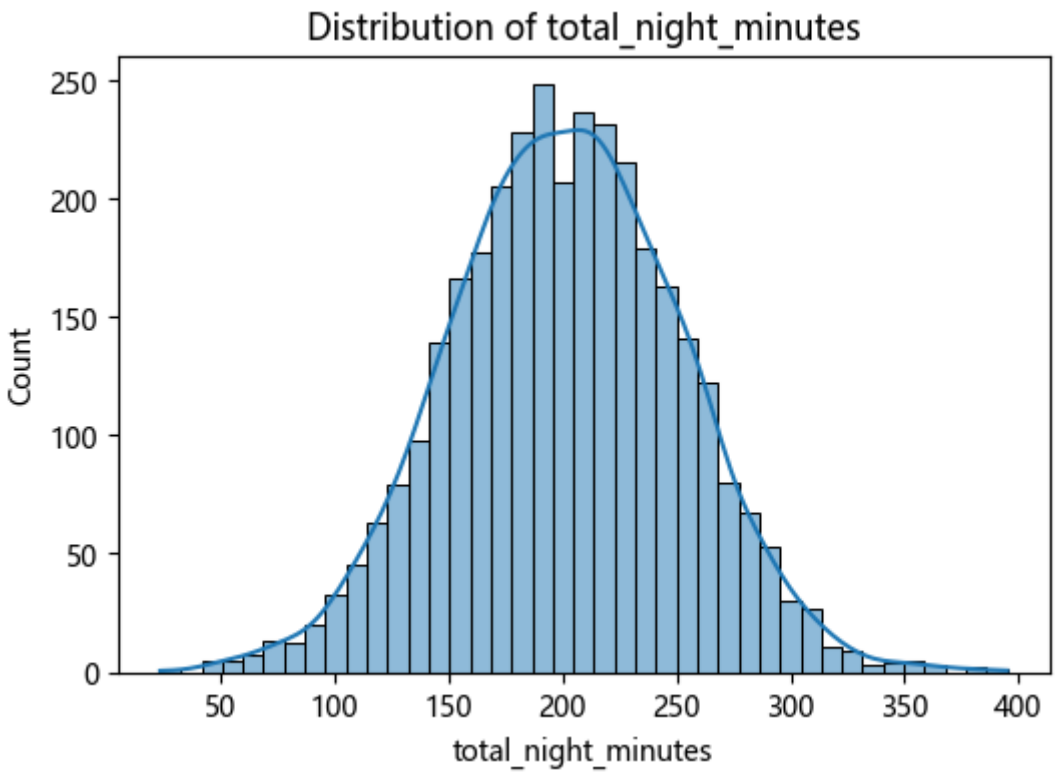

- 图5 国际分钟分布：

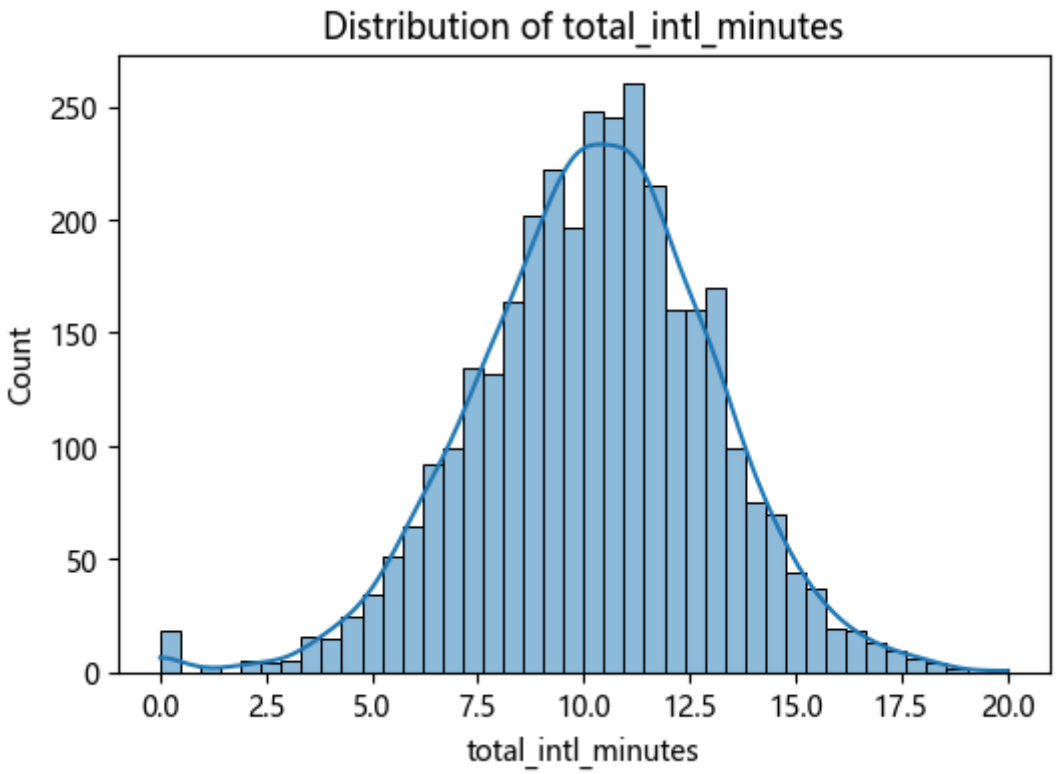

这些分布揭示不同时间段的使用行为差异，为按时段分层策略提供依据。

- 图6 直方图（夜间分钟分布趋势）：

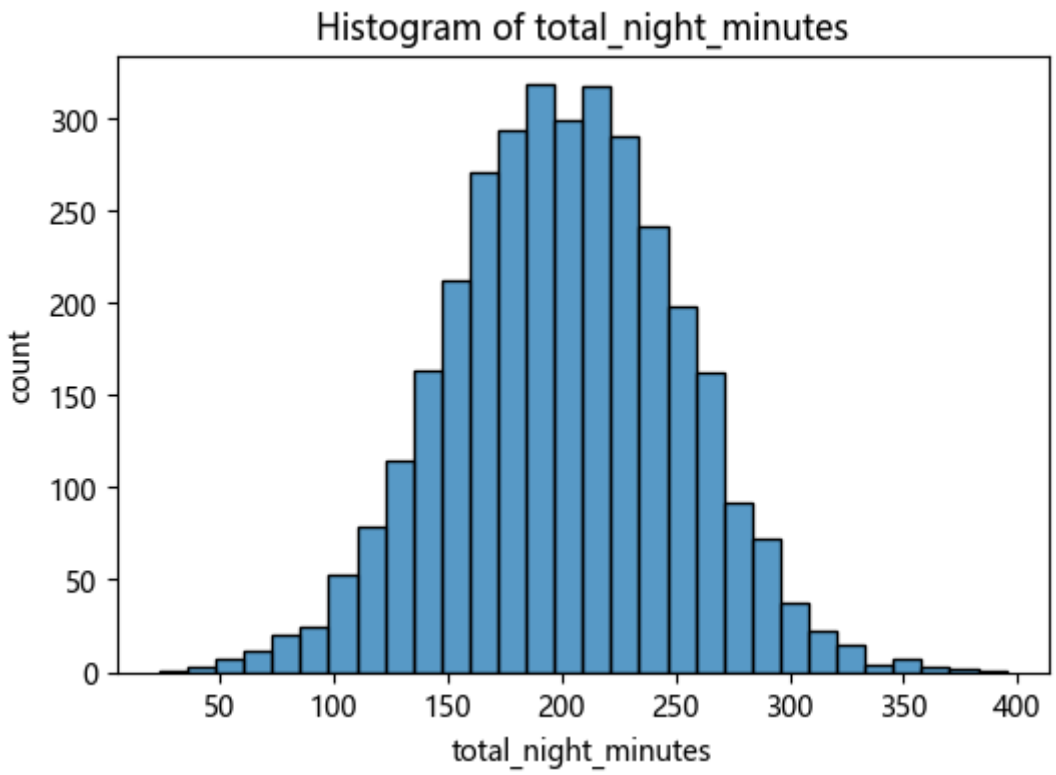

解释：用于观察 `total_night_minutes` 的集中区间与尾部情况，辅助判断异常值与分箱策略。

- 图7 密度图（白天/晚间/夜间分钟对比）：

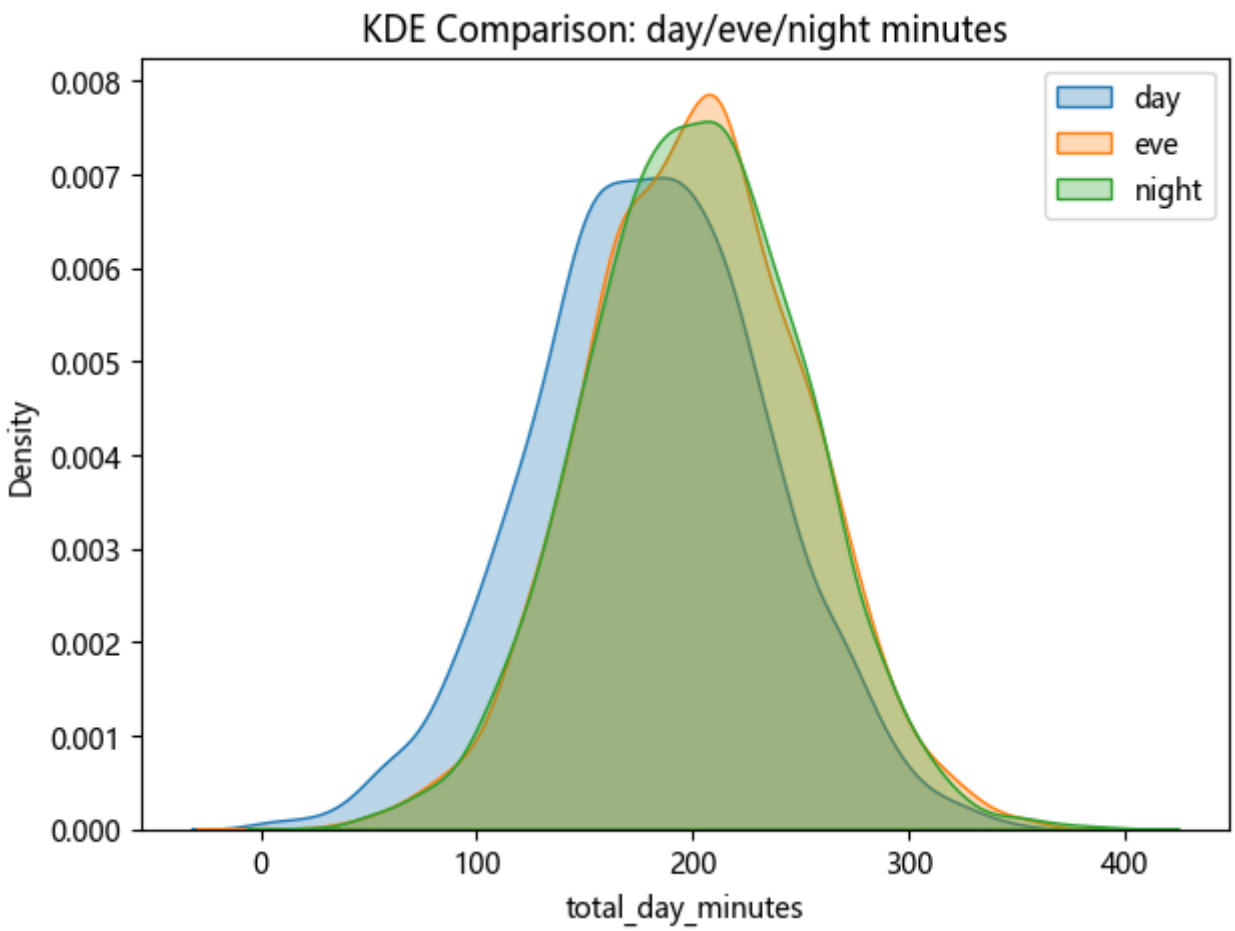

解释：比较三时段的整体分布差异，刻画峰值位置与分布宽窄，从而识别高强度使用时段。

- 图8 箱线图（三时段离散程度）：

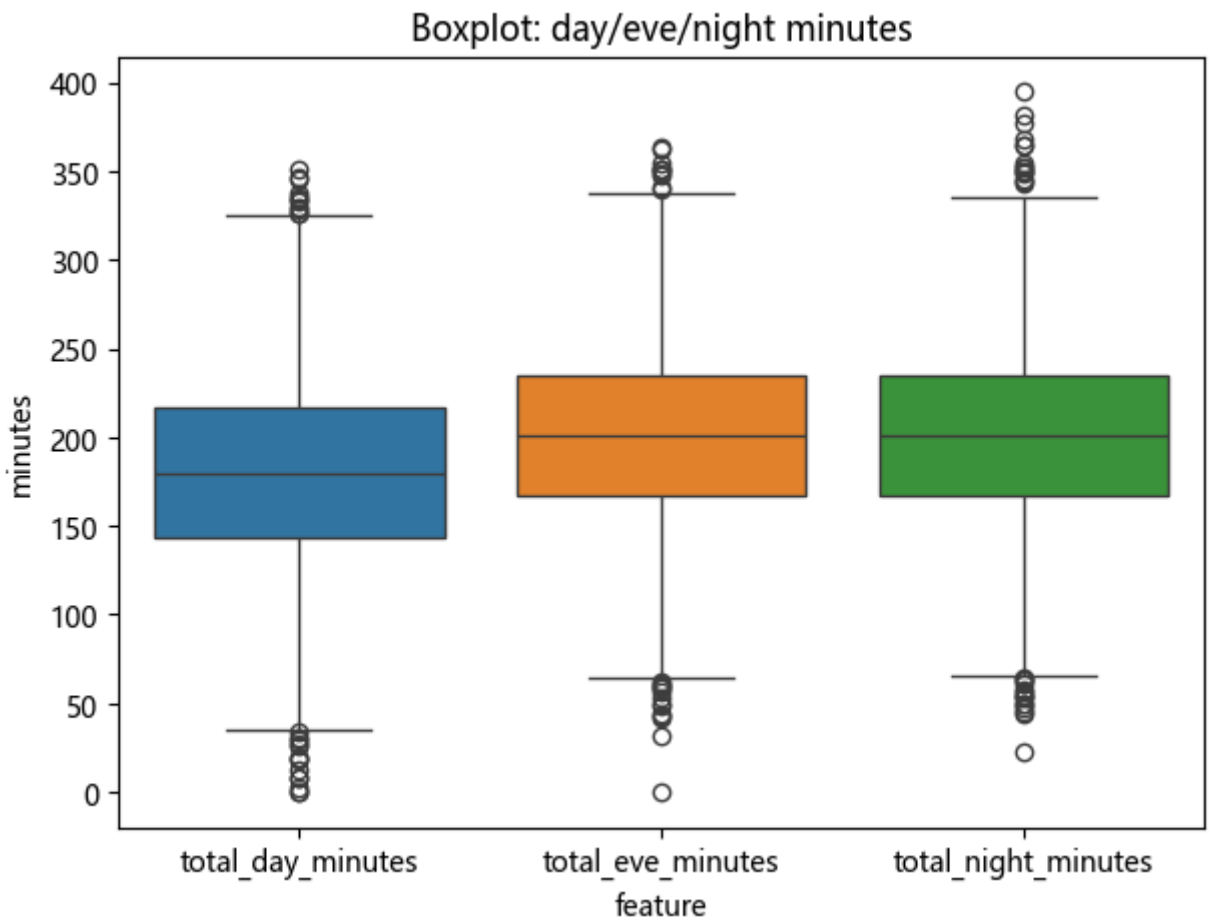

解释：展示 `total_day_minutes`、`total_eve_minutes`、`total_night_minutes` 的中位数、四分位与异常值，量化离散程度。

- 图9 散点图（夜间 vs 晚间分钟关系）：

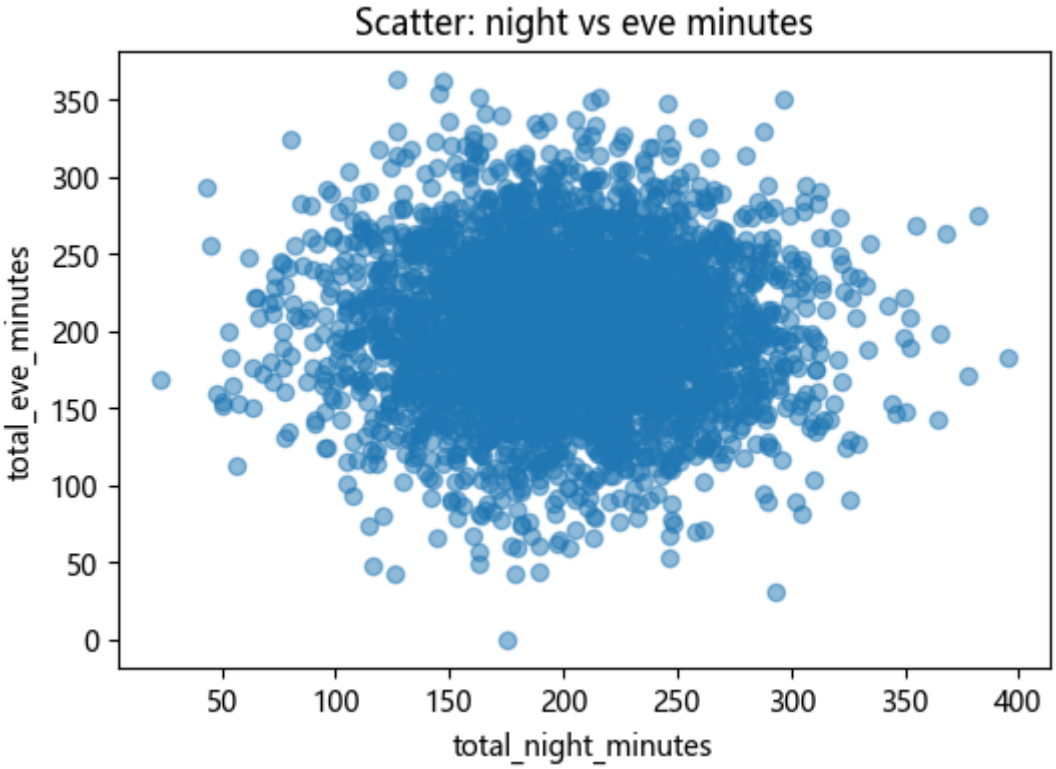

- 解释：检验两时段分钟之间的相关性与耦合程度，识别潜在多重共线性与人群聚类。

6.3 相关性热力图

- 图10 数值特征相关性：

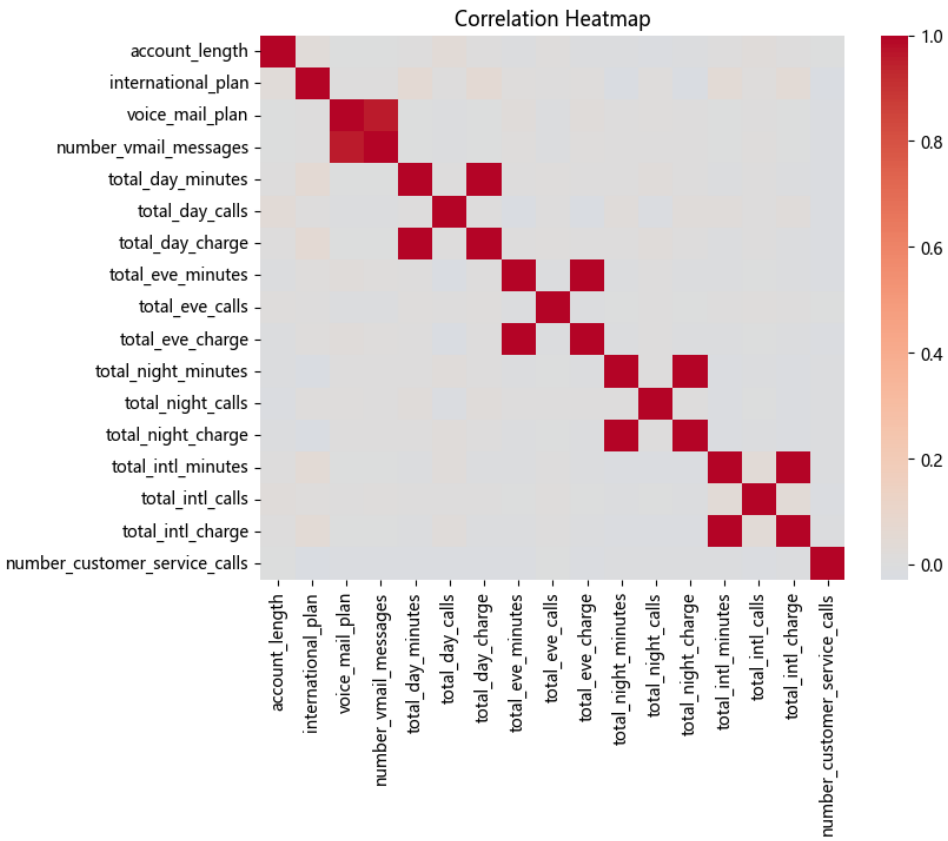

用于识别强相关特征与潜在多重共线性，为特征工程与模型选择提供参考。

6.4 分组流失对比

- 图11 按国际套餐的流失率：

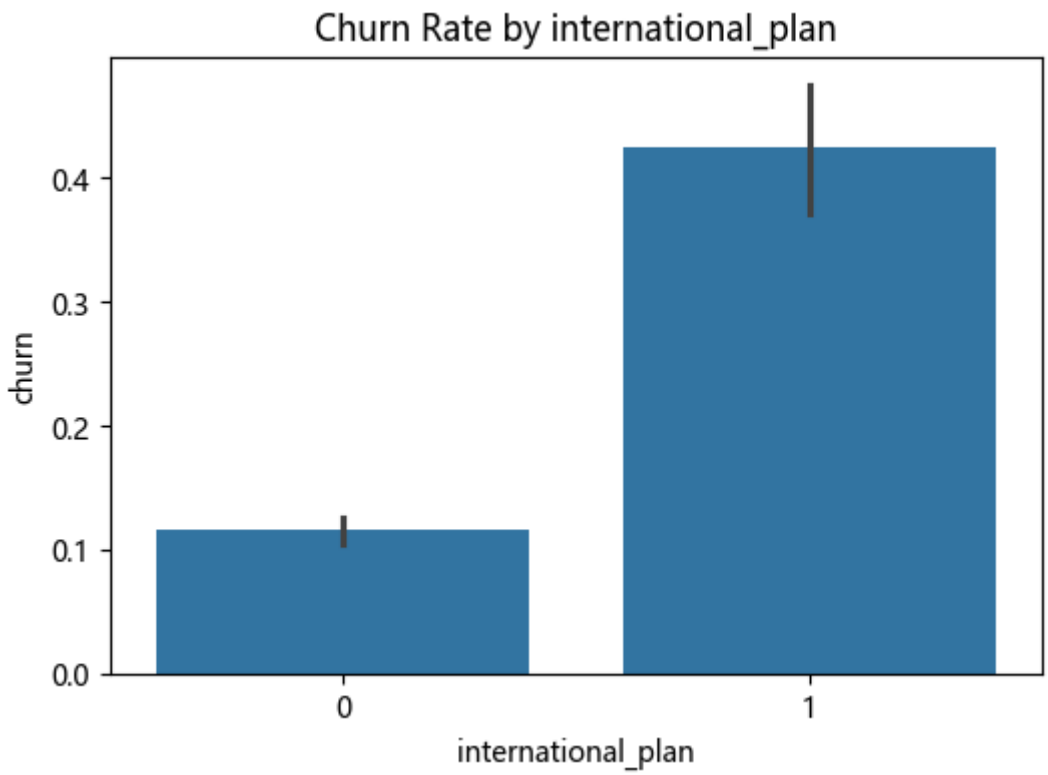

- 图12 按语音信箱的流失率：

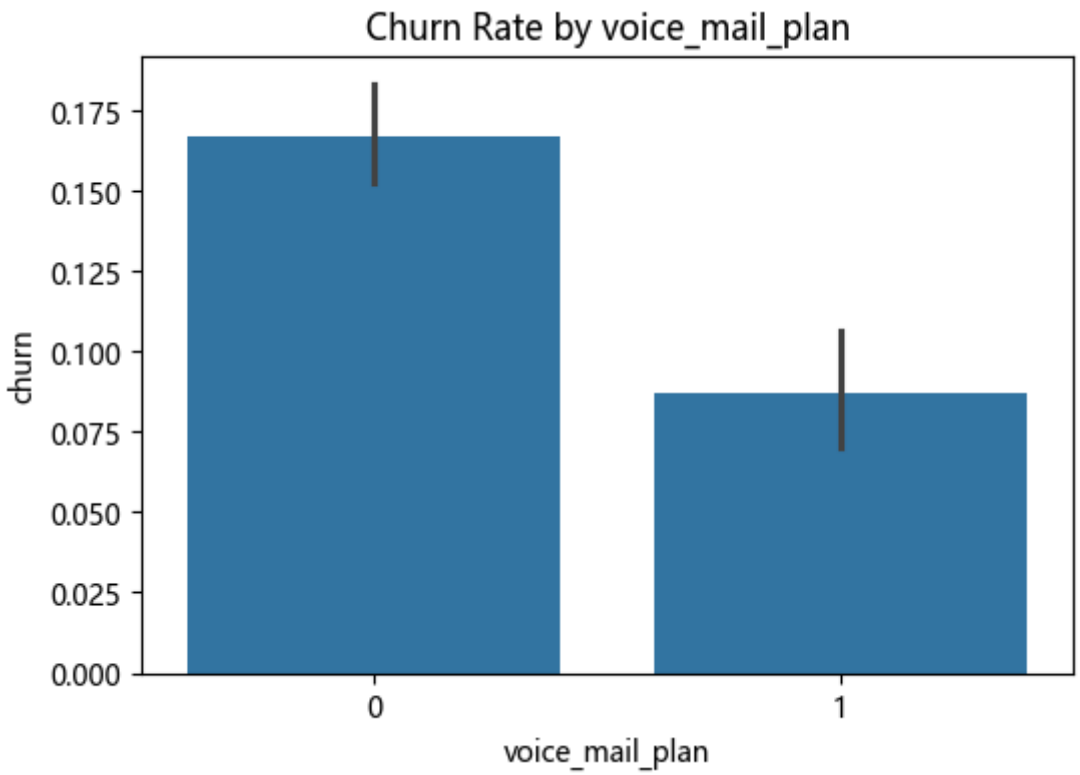

国际套餐与语音信箱对流失率的影响有显著差异，为产品与运营策略提供抓手。

6.5 气泡图（关系与强度）

- 图13 气泡图（夜间分钟×通话次数，气泡=夜间费用）：

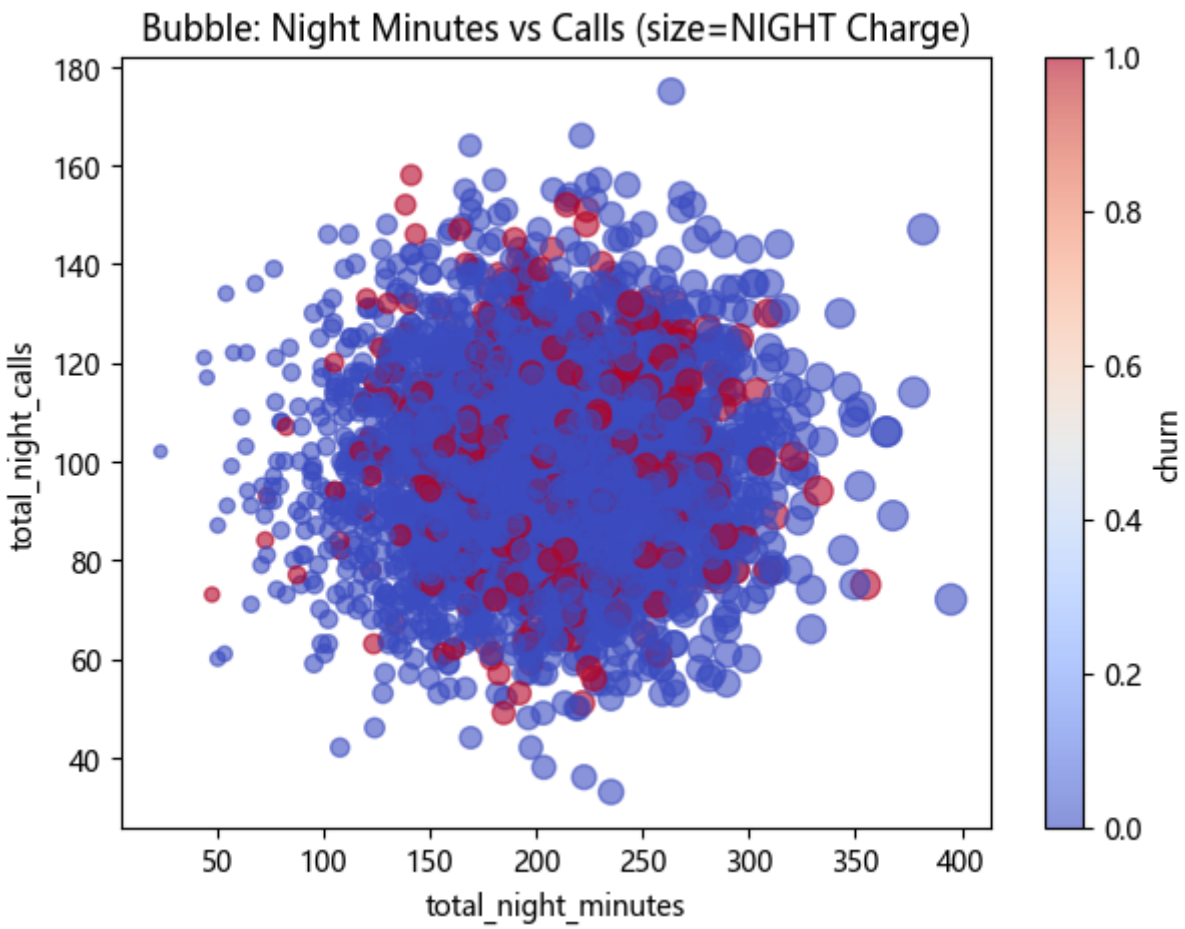

该图从强度与频次两个维度解读夜间行为与费用强度，对夜间优惠策略的制定具有指导意义。

7.模型训练与评估

- logreg: acc=0.861, precision=0.543, recall=0.258, f1=0.350, auc=0.8083197684933985
- rf: acc=0.930, precision=0.903, recall=0.577, f1=0.704, auc=0.8968439139084825
- mlp: acc=0.900, precision=0.697, recall=0.546, f1=0.613, auc=0.8713691445107614
- 混淆矩阵：

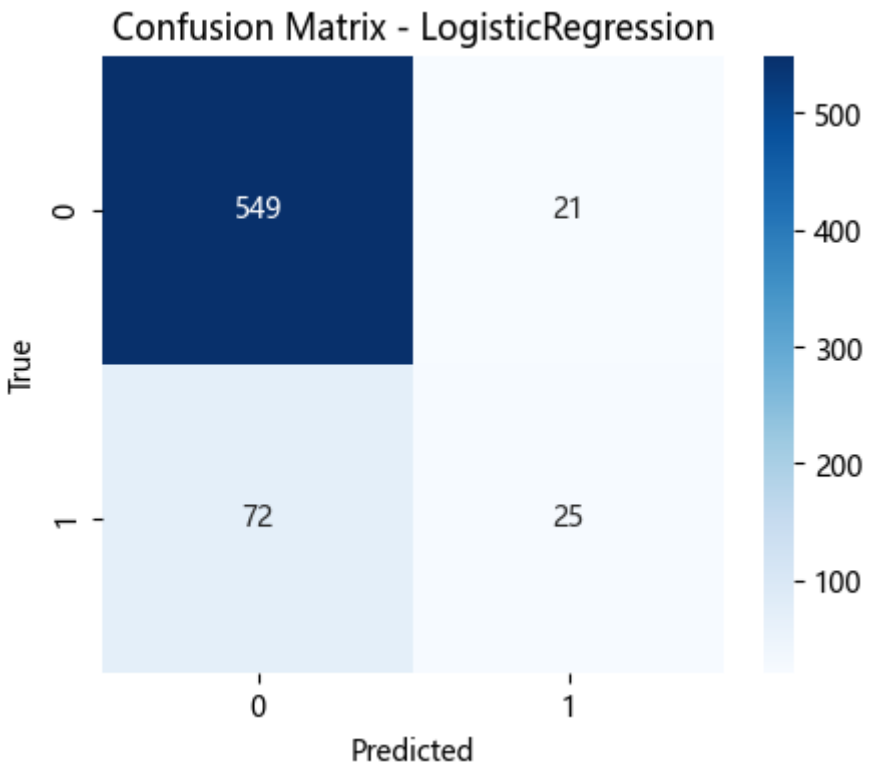
Confusion Matrix - LogisticRegression
549
21
72
25
True
0
1
Predicted
0
1
500
400
300
200
100

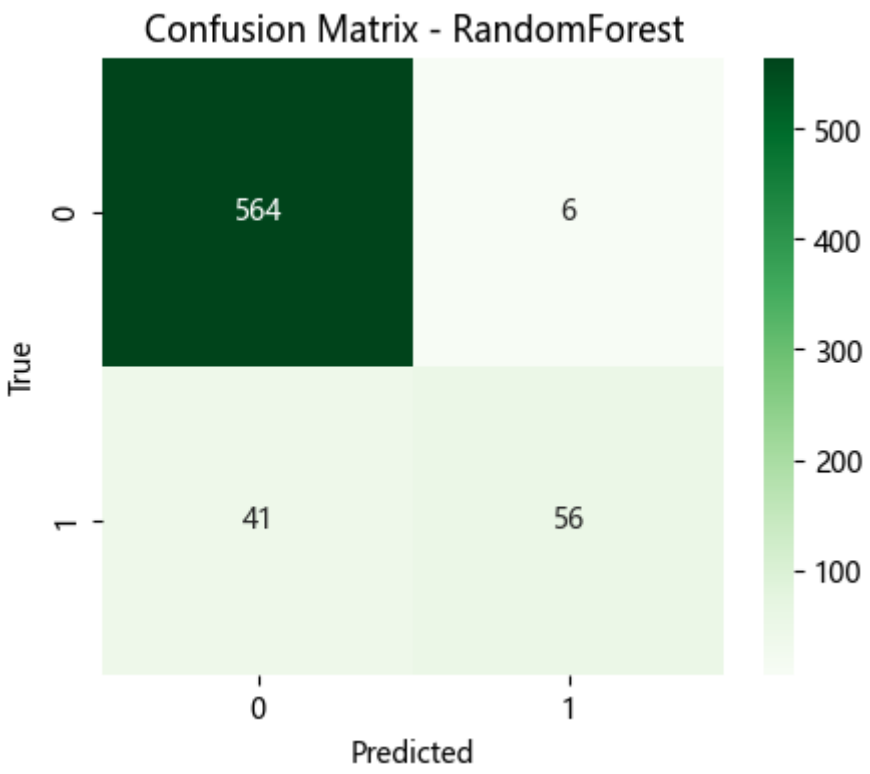
Confusion Matrix - RandomForest
564
6
41
56
True
0
1
Predicted
0
1
500
400
300
200
100

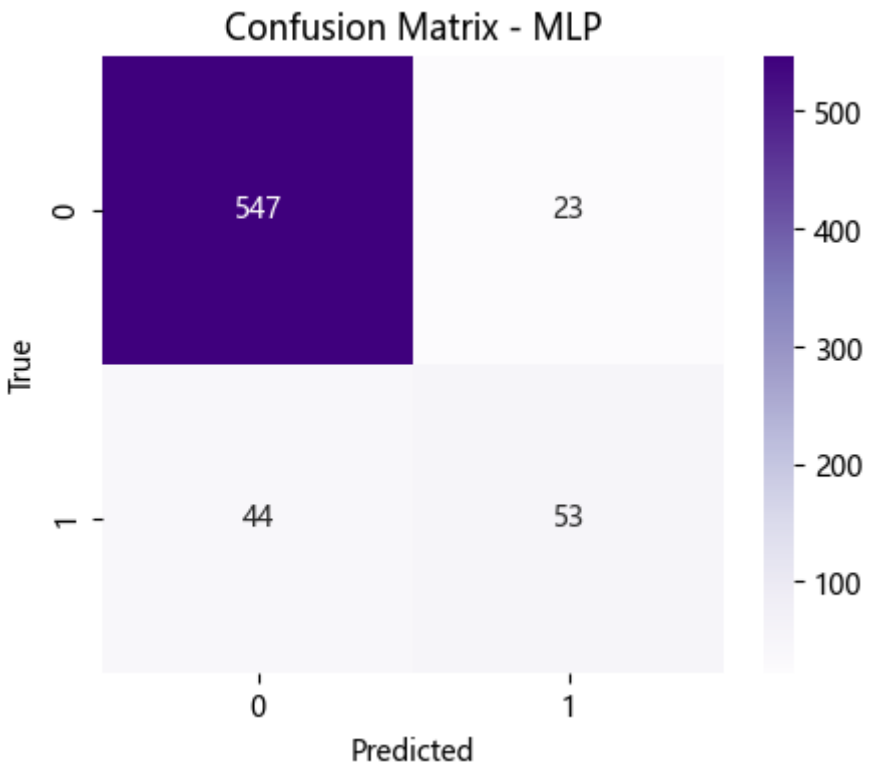
Confusion Matrix - MLP
547
23
44
53
True
0
1
Predicted
0
1
500
400
300
200
100

- ROC曲线：

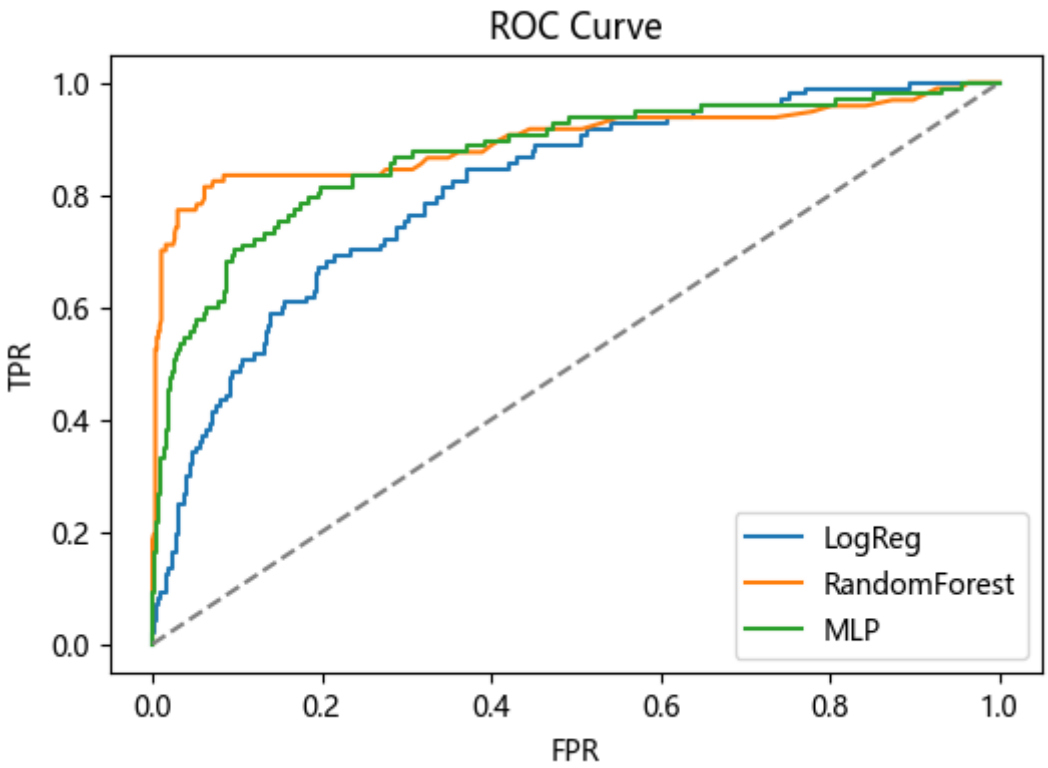
ROC Curve
TPR
FPR
0.0
0.2
0.4
0.6
0.8
1.0
LogReg
RandomForest
MLP

- PR曲线：

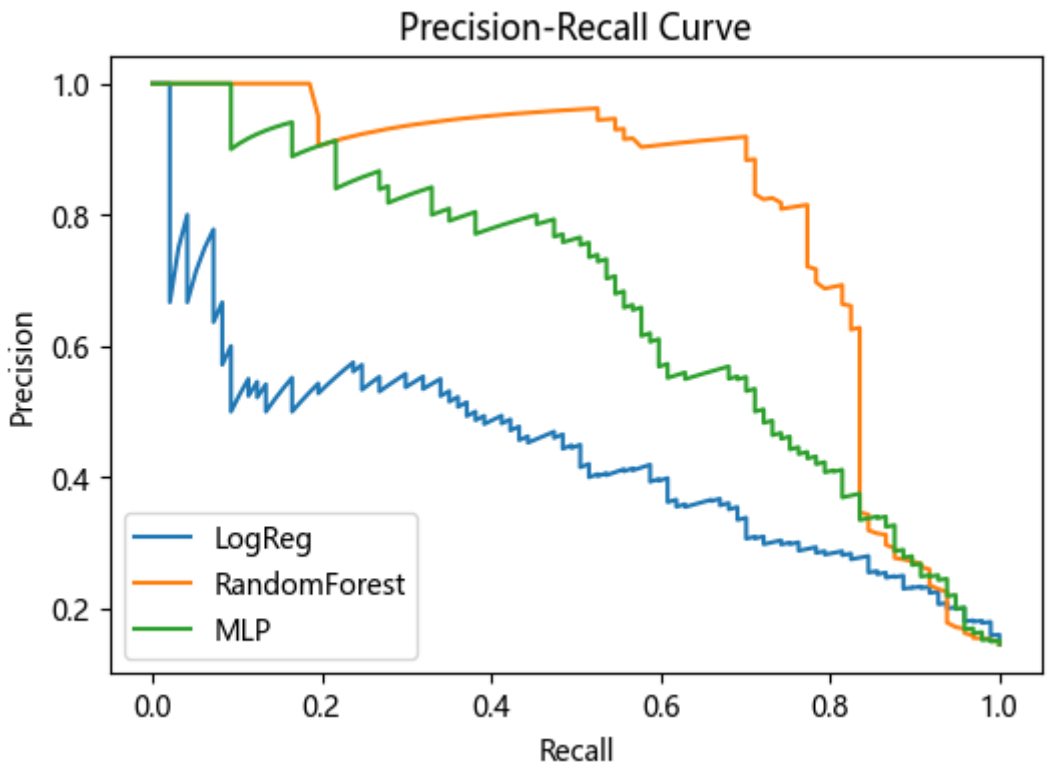

8.误差分析

- 从混淆矩阵与PR曲线看，RF与MLP的整体准确率较高，但对少数流失用户的召回仍可提升。
- 建议通过调节分类阈值提升召回，并尝试 class_weight/SMOTE 缓解类别不平衡。

9.改进方案

- 阈值调优；类别不平衡处理；构造特征交互与高阶特征；引入XGBoost与更深MLP；按套餐类型/客服呼叫分层建模。

10.结论与建议

关注国际套餐用户的留存策略，针对高夜间通话费用户提供夜间优惠。

对客服呼叫次数高的用户开展专项关怀与快速问题闭环。

建立持续监控与A/B测试机制，评估保留措施的实际效果。