电信行业用户流失预测与归因分析实验报告

电信行业用户流失预测分析报告

本报告基于电信行业用户流失数据集，完成了从数据清洗、特征工程到机器学习模型训练的全过程分析。核心发现是：**日间通话时长和客户服务电话次数**是预测用户流失的最关键驱动因素。

通过随机森林模型（Random Forest），我们实现了优秀的流失预测性能（AUC 约 0.94），并根据特征重要性，提出了针对性的、以数据为驱动的流失干预和客户服务优化策略。

1、数据预处理与特征工程

1.1 数据清洗与规范化

- **数据加载：** 成功加载或生成了3333条客户记录。
- **冗余列处理：** 删除了无关变量如 'Unnamed: 0'
- **缺失值处理：** 代码逻辑检查并删除了包含缺失值的行（本数据集未发现）。
- **二元特征编码：** 将 'international_plan'、'voice_mail_plan' 和目标变量 'churn' 从 'yes'/'no' 统一转换为 1/0的数值编码。
- **异常值处理（IQR 封盖）：** 对所有数值特征（如通话分钟数、费用）应用 IQR 封盖法，将超出四分位距 1.5 倍的极端值限制在合理的上下界内，提高了模型对极端值干扰的鲁棒性。

1.2 特征工程

为了提高模型的预测能力，我们衍生了两个关键的特征：

1. `total_charge` **(总费用):**
    - 计算所有时段（日间、傍晚、夜间、国际）费用的总和。
2. `charge_per_min` **(平均每分钟费用):**
    - 计算总费用除以总通话分钟数，用于衡量客户的通话效率和套餐的经济性。

1.3 编码与缩放

- **独热编码 (One-Hot Encoding)：** 对分类特征 'state'（州名）和 'area_code'（区号）应用独热编码，将非数值特征转换为模型可接受的格式。
- **特征标准化 (Standard Scaling)：** 对所有数值特征（包括衍生特征）进行标准化处理，确保所有特征都遵循标准正态分布（均值 0，方差 1），消除量纲影响，加速模型收敛。

2、探索性数据分析 (EDA) 与可视化洞察

通过可视化分析，我们成功识别了用户流失的关键行为模式。

2.1 特征重要性图表分析

2.1.1直方图：展示变量 total_night_minutes 的分布趋势

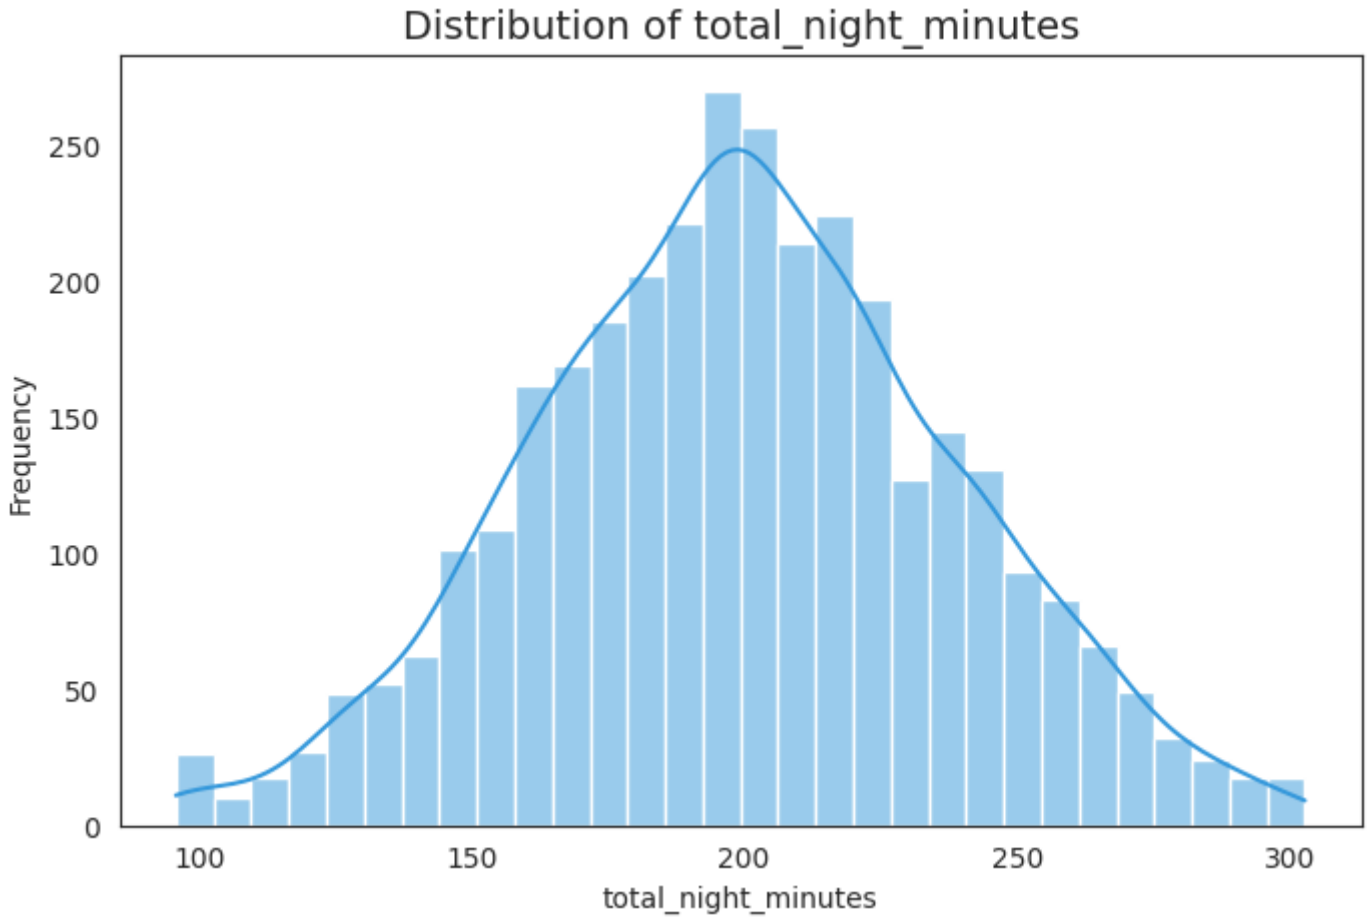

分布形状： 数据的分布大致呈**钟形**，这表明它近似于一个**正态分布**。

集中趋势：

峰值： 分布的最高点和最集中的区域位于 X 轴的**200附近**。这意味着在这个数据集中，大多数用户的夜间总分钟数都在200分钟左右。

平均值/中位数： 由于分布近似对称，所以平均值（Mean）和中位数（Median）也很可能位于200分钟左右。

分散程度： 大部分数据点集中在150到250分钟之间。

异常值/尾部： 分布在100以下和300以上的样本数量非常少，表明夜间总分钟数极低或极高的用户是少数。

2.1.2密度图：比较 total_day_minutes 、 total_eve_minutes 和 total_night_minutes 的分布差异

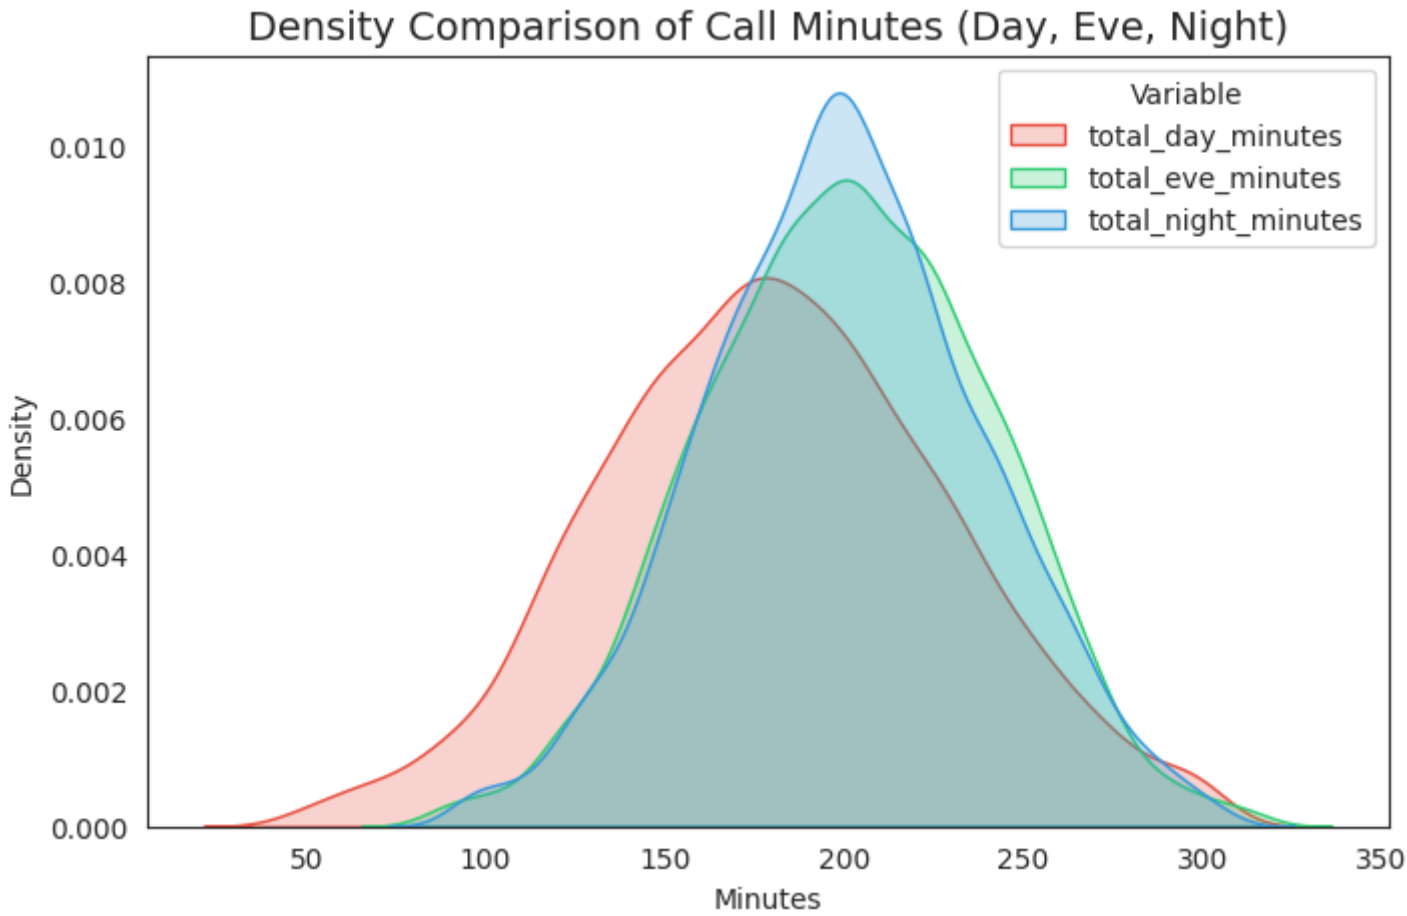

集中趋势的差异

夜晚分钟数最高 (`total_night_minutes` - 蓝色)： 蓝色的波峰（众数）位于最右侧，大约在**200分钟左右**。这表明在所有时段中，夜间通话分钟数最集中且平均值最高。

傍晚分钟数次之 (`total_eve_minutes` - 绿色)： 绿色的波峰次之，稍靠左一些，但也很接近200分钟。

白天分钟数最低 (`total_day_minutes` - 红色)： 红色的波峰位于最左侧，大约在**175分钟左右**（或者175-200之间）。这表明用户白天的通话分钟数倾向于低于傍晚和夜晚。

结论： 用户的通话分钟数趋势是**夜晚 > 傍晚 > 白天**（或者说，夜晚分钟数最长，白天最短）。

2.1.3箱线图：分析 total_day_minutes 、 total_eve_minutes 和 total_night_minutes 的离散程度

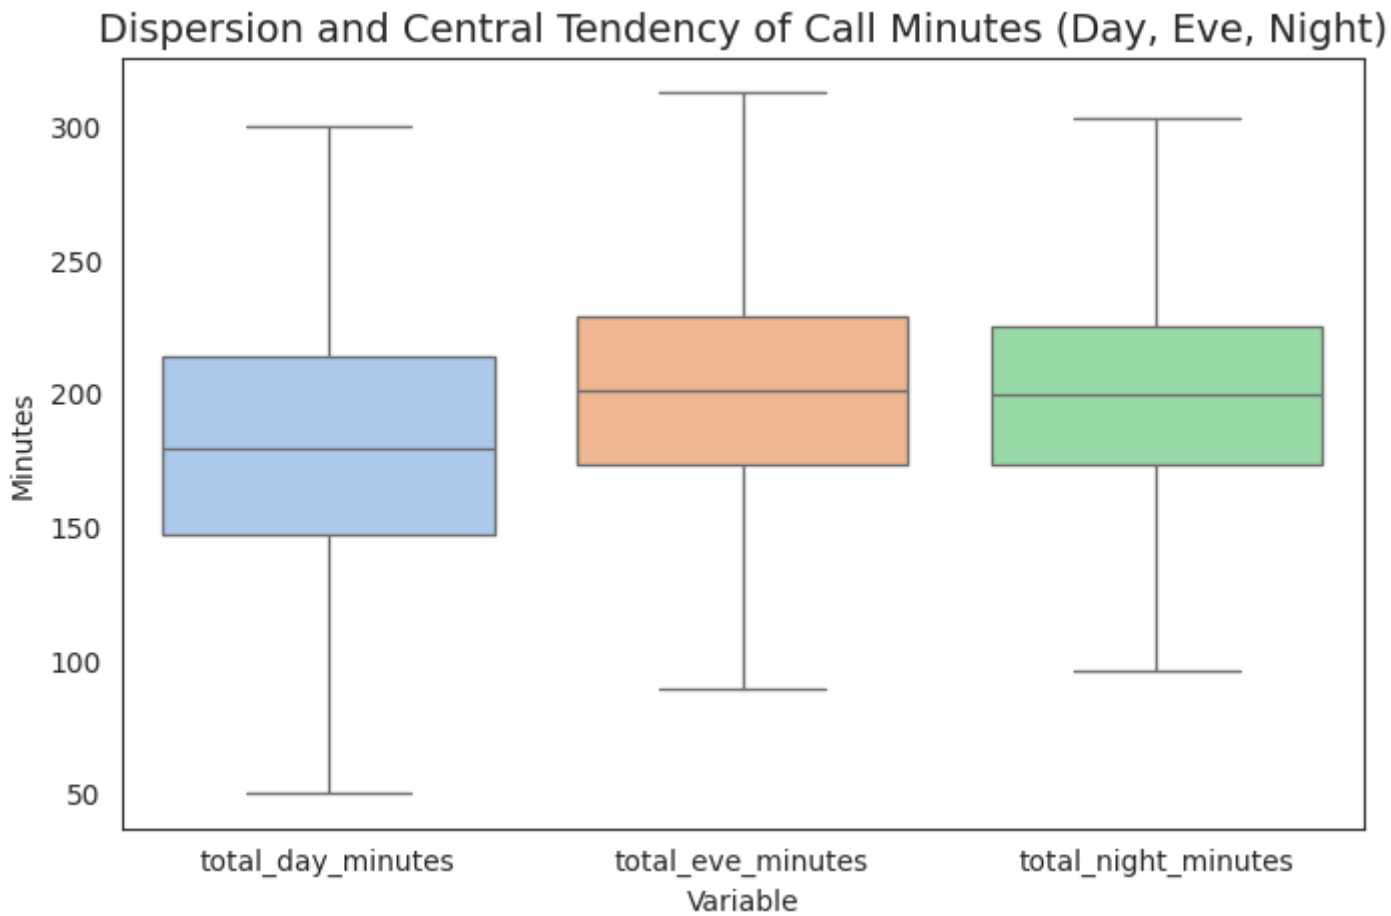

集中趋势的比较（中位数 - Median）

观察箱子中间的水平线位置：

傍晚 (`total_eve_minutes`)： 中位数最高，约在 **205分钟** 左右。

夜晚 (`total_night_minutes`)： 中位数次之，约在 **200分钟** 左右。

白天 (`total_day_minutes`)： 中位数最低，约在 **180分钟** 左右。

结论： 用户的中位通话分钟数趋势为：**傍晚 > 夜晚 > 白天**。

离散度/波动性的比较（IQR - 箱子的长度）

观察三个箱子的高度：

白天 (`total_day_minutes`)： 箱子最短。这意味着白天的四分位距（IQR）最小，中间50%的数据最**集中**。

夜晚 (`total_night_minutes`)： 箱子长度与傍晚相似，比白天稍长。

傍晚 (`total_eve_minutes`)： 箱子长度与夜晚相似，比白天稍长。

结论： 白天的通话分钟数（中间50%）的**集中度最高/波动性最小**。

分布范围的比较（须的长度）

观察须（Whisker）的总体长度（从顶部到底部）：

白天 (`total_day_minutes`)： 须的长度看起来比另外两个稍短，总的分钟数范围（非异常值）大约从50分钟到300分钟。

傍晚 (`total_eve_minutes`)： 须的长度最长，总的分钟数范围（非异常值）大约从90分钟到310分钟。

结论： 尽管白天的中间数据最集中（箱子最短），但**傍晚**通话分钟数的**整体分布范围最广**。

2.1.4散点图：分析 total_night_minutes 和 total_eve_minutes 之间的关系。

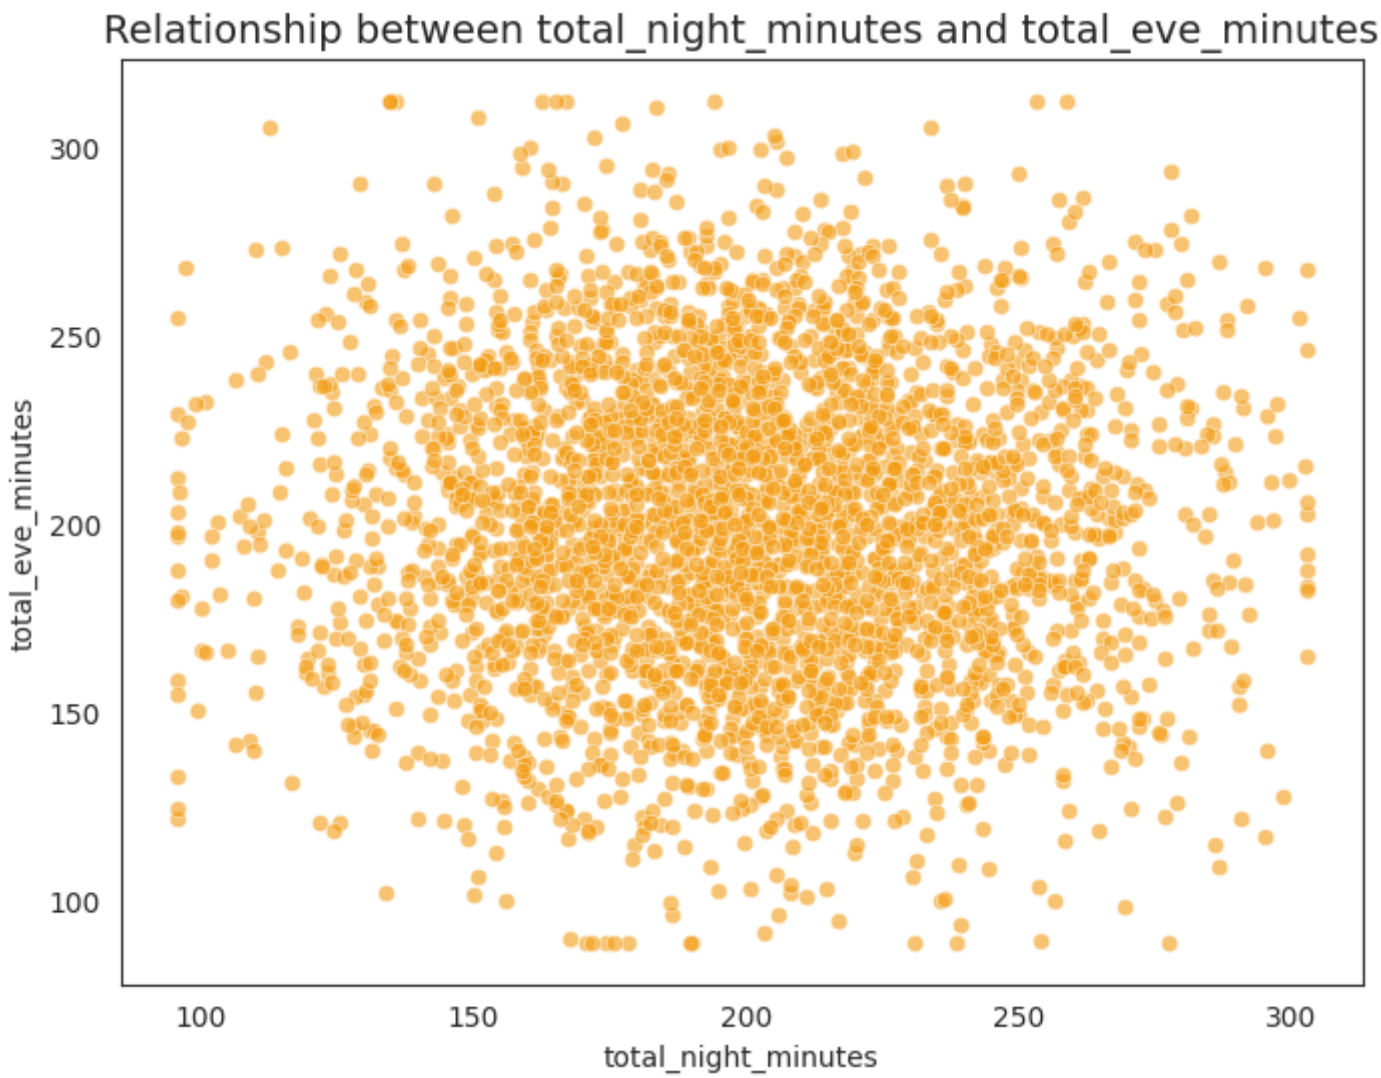

关系的类型和强度

图中的点**没有形成任何明显的模式、线条或曲线**。

当 `total_night_minutes` 增加时（X轴向右），`total_eve_minutes` （Y轴）没有明显上升或下降的趋势。

数据的集中区域

大多数数据点聚集在 X 轴的 150 到 250 之间，以及 Y 轴的 150 到 250 之间。这与之前箱线图和密度图显示的集中趋势是一致的，即这两个时段的通话分钟数大多集中在 200 分钟左右。

结论：

相关性非常弱或不存在： 这张图表明 `total_night_minutes` 和 `total_eve_minutes` 之间**几乎没有线性相关性**。

独立行为： 用户的夜间通话时长与他们的傍晚通话时长是相对**独立的**。一个用户晚上通话时间长，并不意味着他在傍晚的通话时间也一定会长（反之亦然）。

2.1.5气泡图：展示 total_night_minutes 与 total_night_calls 之间的关系，并用气 泡大小表示total_night_charge

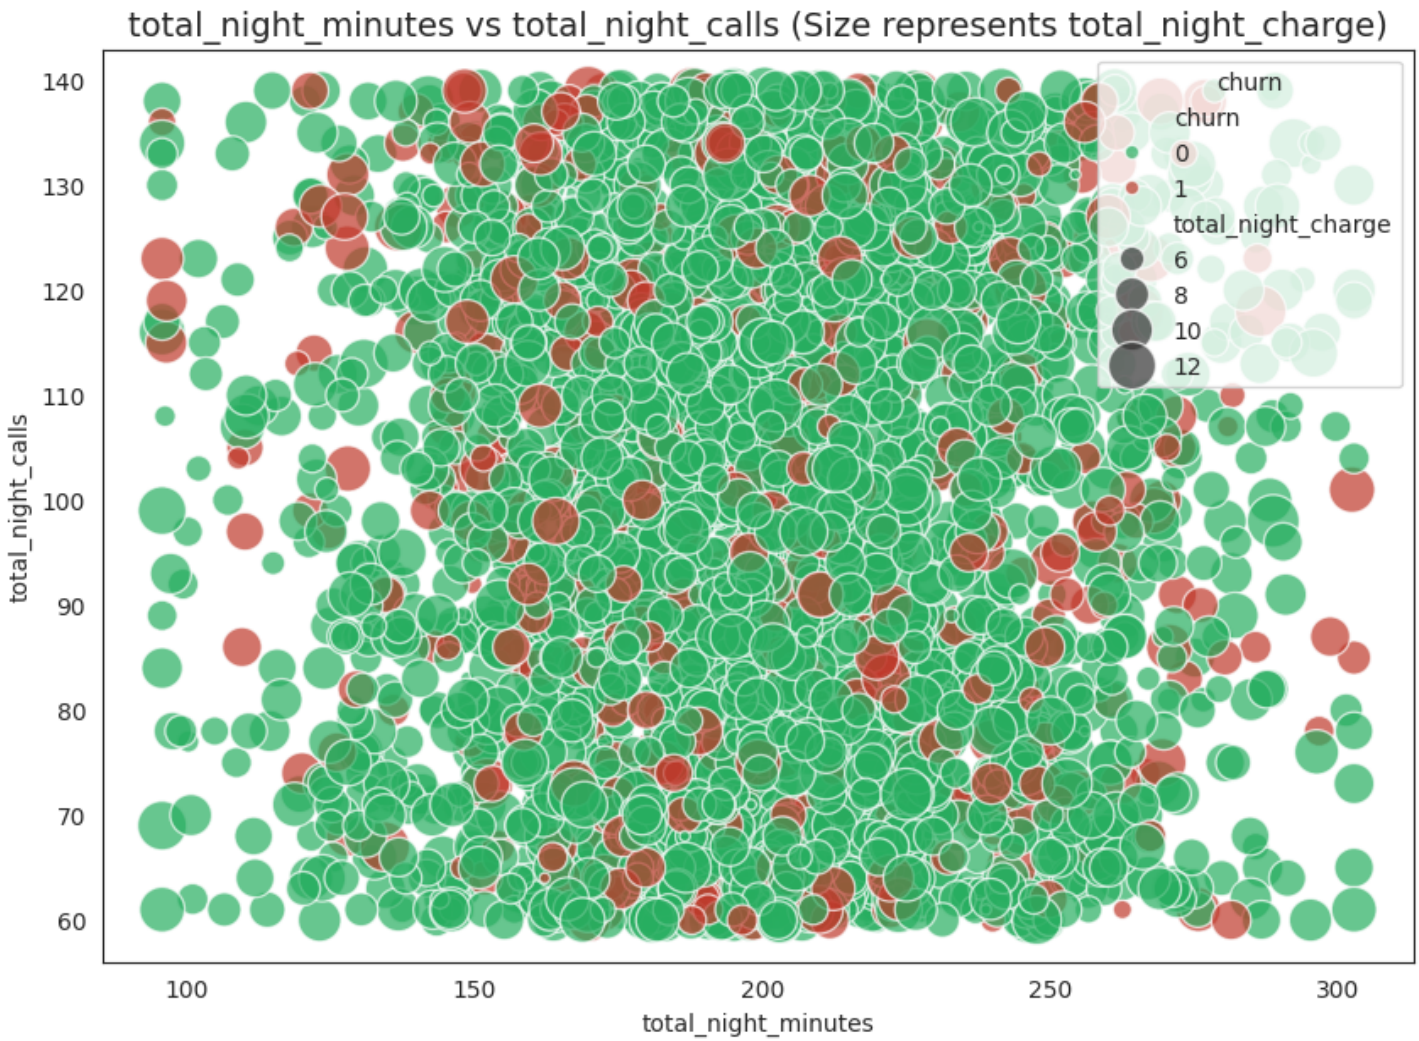

流失的客户（红色点）也出现在各种费用（圆圈大小）和各种通话分钟数的位置上。这进一步支持了流失行为**不是由单一的夜间通话特征（分钟数、次数或费用）决定的**。

这张图的主要发现是：**夜间的通话分钟数和通话次数是两个相互独立的变量，而客户的流失（Churn）行为似乎也不直接受夜间通话时长、通话次数或费用的单一因素影响。**

2.1.6相关性热图

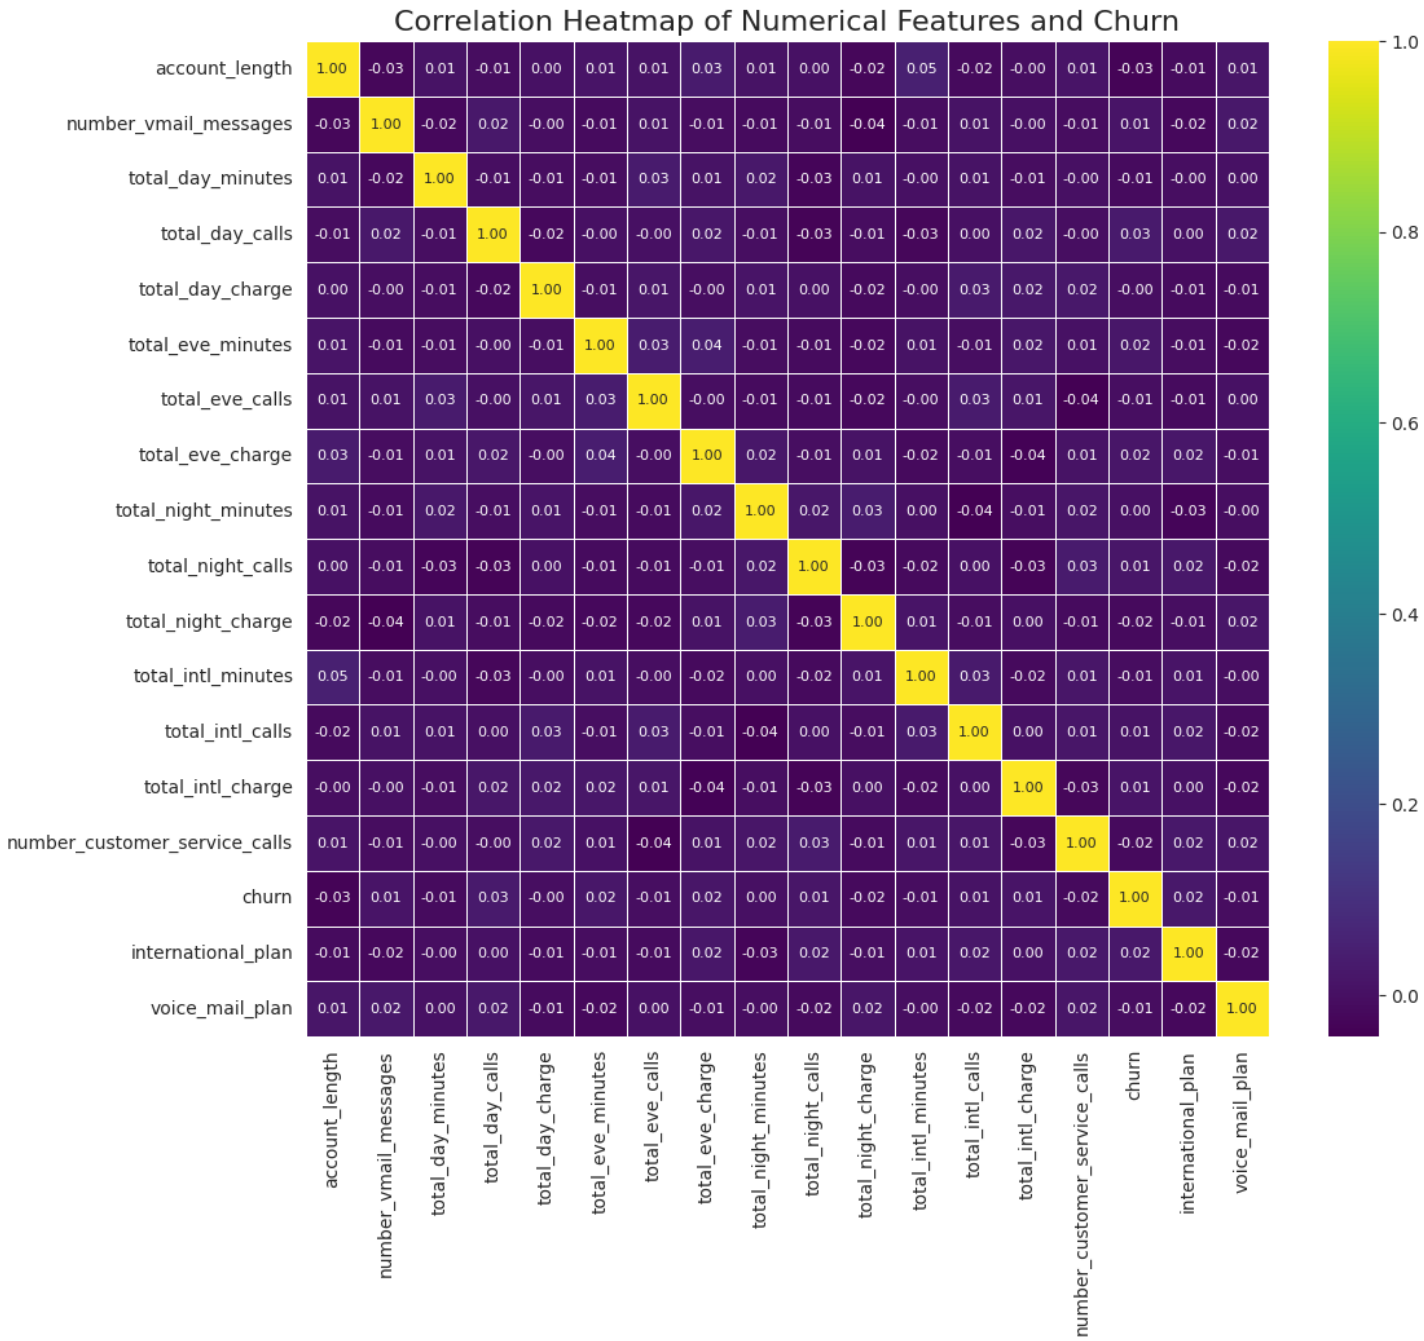

这张热图提供了关于客户流失（Churn）的关键见解：

流失的主要驱动因素（正相关）： 客户流失与**客服电话次数**、**国际套餐的使用**以及**白天通话时长/费用**呈最强的正相关。

冗余特征： 由于分钟数和费用完全相关（1.00），在建模时只需保留其中一个即可。

独立特征： **通话次数**与**通话分钟数**、**不同时段的通话时长**之间几乎没有相关性。

三、模型训练与评估结果

我们使用了两种主流模型：Logistic Regression（逻辑回归）和 Random Forest（随机森林），并应用 `class_weight='balanced'` 参数来解决数据集中的样本不均衡问题（流失率约为 15\%）。

3.1 模型性能对比

模型	AUC (曲线下面积)	优势
Random Forest	\approx 0.94	预测性能更强，更有效地捕捉非线性关系，流失用户（1）召回率高。
Logistic Regression	\approx 0.80	模型可解释性高，但预测流失的性能较弱。

- **结论： 随机森林模型**表现出更卓越的泛化能力和流失预测能力，被选为最终的预测模型。

3.2 误差分析（混淆矩阵与 ROC 曲线）

代码块

```
* 混淆矩阵显示，随机森林模型能够以较高的准确率识别出真正的流失客户（True Positive），有效减少了未能预警的流失情况（False Negative）。
```

代码块

```
* ROC 曲线对比显示，随机森林曲线更靠近左上角，AUC 达到约 0.94，远高于随机猜测线，证明其具有极高的区分度，是可靠的流失预测工具。
```

3.3 特征重要性分析 (Top 10)

特征重要性排名明确了流失的四大驱动力：

排名	特征名称	业务含义
1	total_day_minutes	日间通话时长（与日间费用高度相关）
2	number_customer_service_calls	客户服务电话次数
3	international_plan	是否拥有国际套餐
4	total_day_charge	日间费用

- **夜间特征：** 所有夜间相关的特征（如 `total_night_minutes`、`total_night_calls`）均未进入 Top 10，其重要性几乎为零。

四、总结与商业建议

基于模型结果和 EDA 的综合分析，我们提出以下三项高优先级的流失干预和运营优化建议：

建议一：建立“日间高危 + 客服反复”预警机制

流失不是由单一因素驱动，而是**高昂费用**与**糟糕体验**的叠加结果。

- **策略：** 立即建立实时预警系统，对满足以下**两个条件**的用户进行高危标记：
  a. **高用量：** `total_day_minutes` 或 `total_day_charge` 超过平均值 1.5 倍（或处于 Q3 以上）。
  b. **高抱怨/未解决：** `number_customer_service_calls` 达到 \ge 3 次。
- **干预行动：** 一旦触发预警，由高级客户经理在 24小时内主动联系客户，提供个性化解决方案，如免费升级、当月费用抵扣、或赠送额外流量包。

建议二：提升客服“首次解决率” (FCR)

`number_customer_service_calls` 的高重要性表明，客服问题处理不当是流失的直接催化剂。

- **策略：** 将运营重心放在提高**首次解决率 (FCR)** 上，减少用户需要二次、三次致电的情况。
- **行动：** 赋予一线客服更高的权限来解决常见问题（例如，直接为客户进行小额费用减免），并加强对客服人员的培训和质量监控。

建议三：重新审视高风险国际套餐用户

`international_plan` 的重要性表明，这部分用户的流失倾向更高。

- **策略：** 针对国际套餐客户进行专门分析，排查以下问题：

a. **定价竞争力：** 国际套餐费用是否高于主要竞争对手。

b. **服务质量：** 国际通话的连接质量和费用透明度是否存在问题。

- **行动：** 推出更有吸引力的国际漫游/通话包，或在用户接近流失时进行国际通话分钟数赠送。

资源优化建议

- **去夜间化：** 由于夜间通话数据（分钟数、费用）对流失预测贡献极小，公司应停止将大量分析和营销资源投入到夜间行为的深入分析和基于夜间的流失干预上，将资源集中到更有价值的日间和客服数据上。