1、数据清洗运行结果

```
churn                                0       1
account_length                  100.74  102.57
number_vmail_messages             8.60    5.12
total_day_minutes               175.25  206.75
total_day_calls                 100.31  101.43
total_day_charge                 29.79   35.15
total_eve_minutes               199.10  212.28
total_eve_calls                 100.07  100.52
total_eve_charge                 16.92   18.04
total_night_minutes             200.08  205.23
total_night_calls               100.05  100.39
total_night_charge                9.00    9.24
total_intl_minutes               10.18   10.69
total_intl_calls                  4.48    4.10
total_intl_charge                 2.75    2.89
number_customer_service_calls     1.41    1.89
>>> |
```

2、各种图表

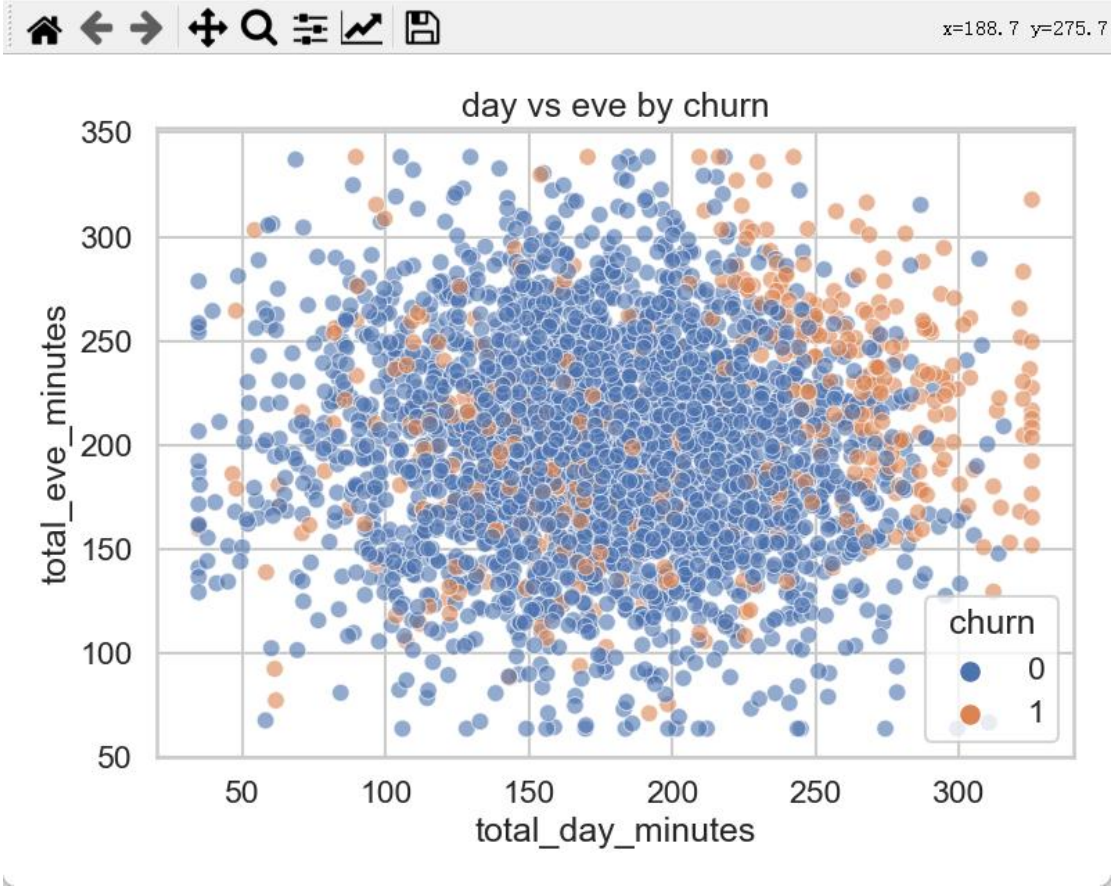

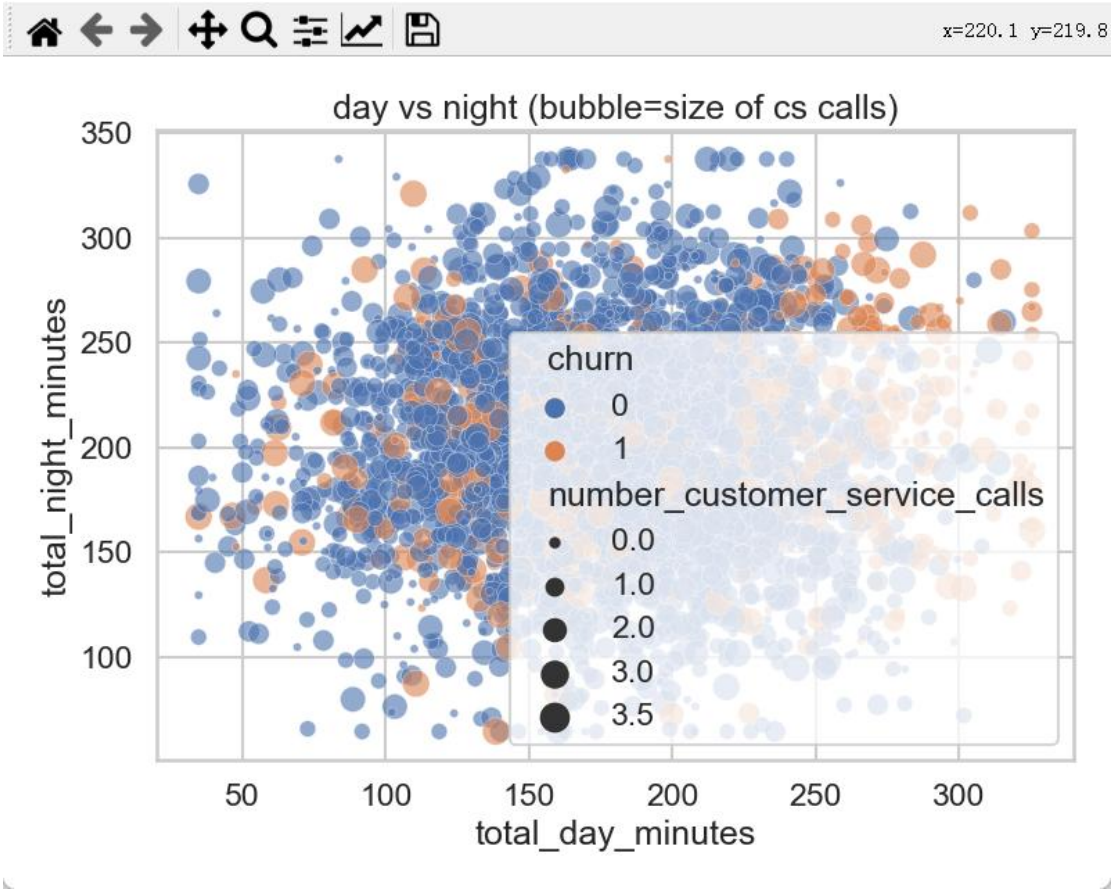
x=220.1 y=219.8
day vs night (bubble=size of cs calls)
total_night_minutes
total_day_minutes
churn
0
1
number_customer_service_calls
0.0
1.0
2.0
3.0
3.5

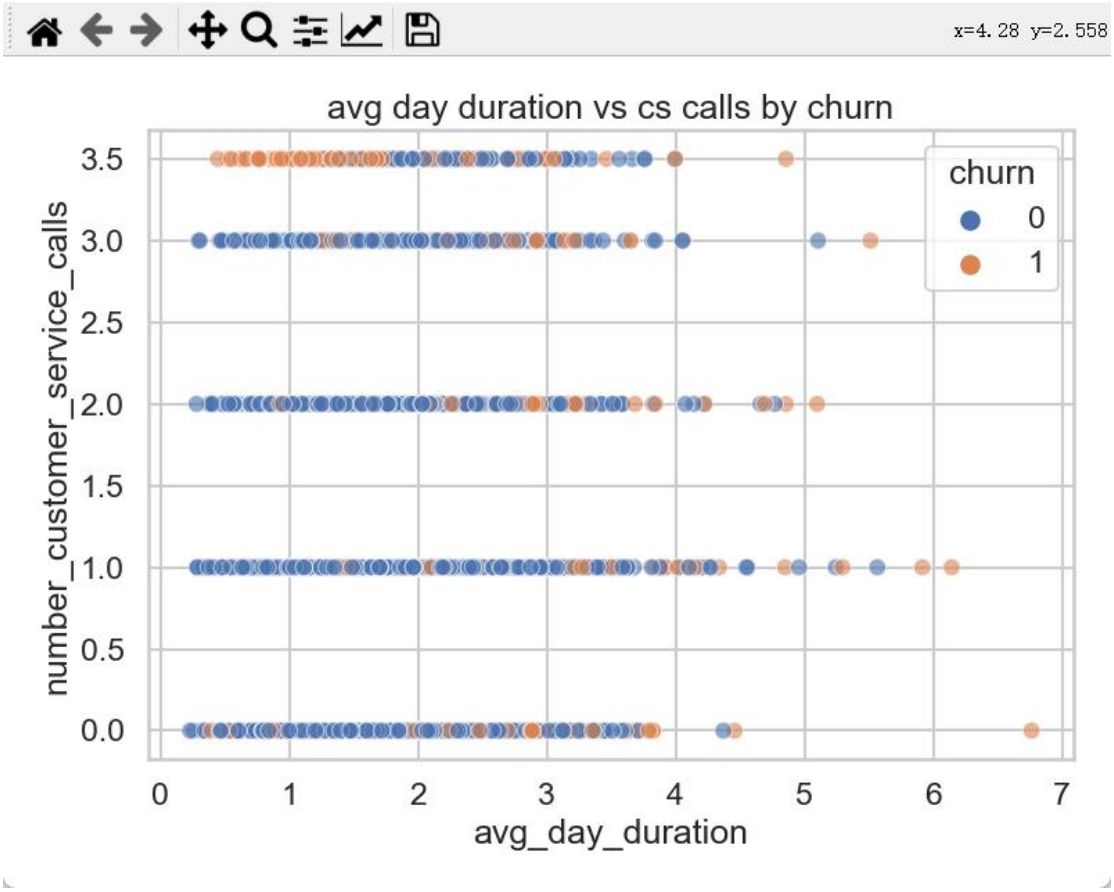
x=4.28 y=2.558
avg day duration vs cs calls by churn
number_customer_service_calls
avg_day_duration
churn
0
1

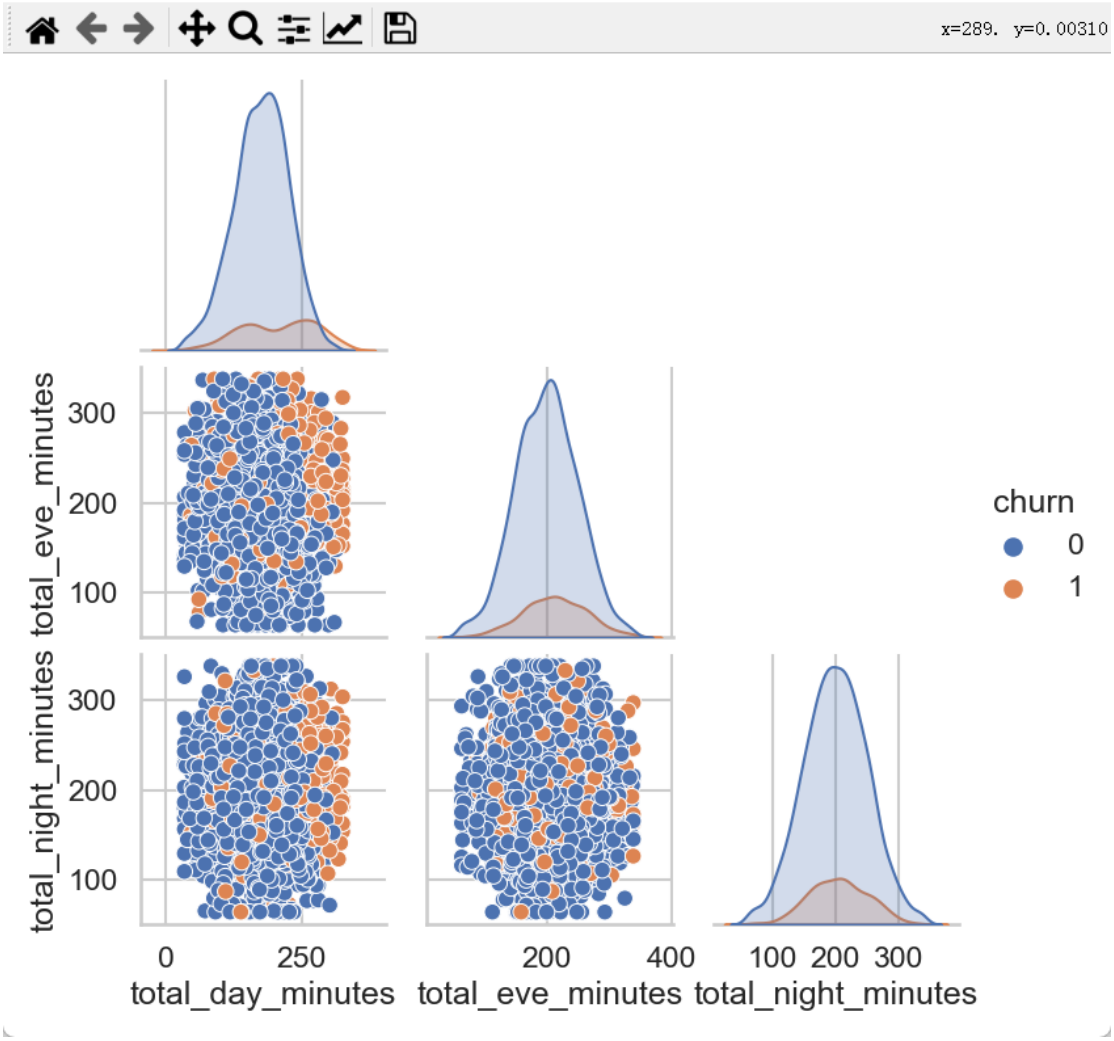
x=289. y=0.00310
total_eve_minutes
300
200
100
total_night_minutes
300
200
100
0
250
total_day_minutes
200
400
total_eve_minutes
100
200
300
total_night_minutes
churn
0
1

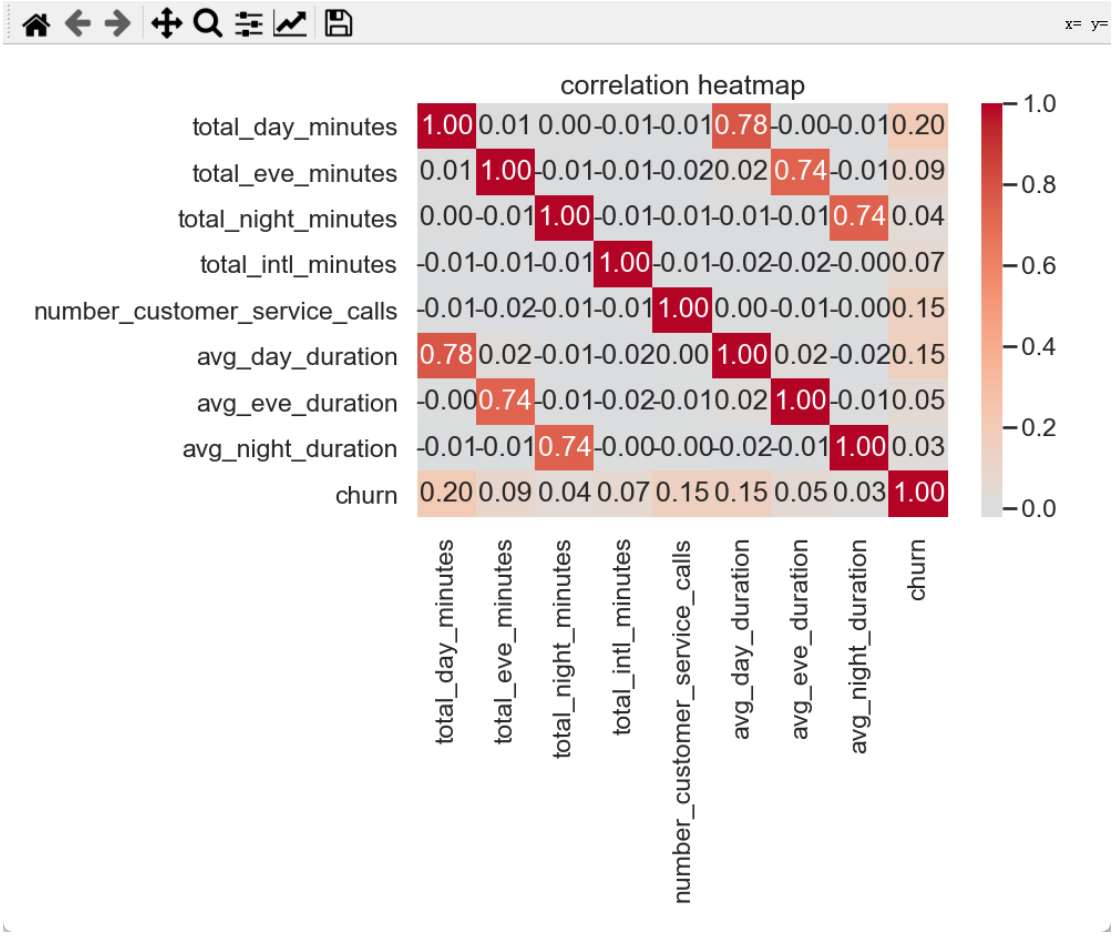

- 分布图与密度图：观察 day/eve/night minutes 与 calls 的总体分布形态与峰态，识别重尾与异常值。

- 箱线图分组 churn ： churn=1 的 total_day_minutes 、 total_eve_minutes 、 total_night_minutes 、 total_day_charge 更高； number_customer_service_calls 在 churn=1 更高。

- 散点与气泡图：

  - total_day_minutes 与 total_eve_minutes 总体正相关，高值区域的 churn 比例更高。

  - day vs night 的气泡图显示当 day_minutes 和 night_minutes 同时较高且客服来电次数较多时， churn 更高。

  - avg_day_duration 与 number_customer_service_calls 组合能揭示通话效率低且客服交互多的用户更易流失。

- 相关性热力图：确认 churn 与 total_day_minutes 、 number_customer_service_calls 、 intl_* 的正相关，以及 voice_mail_plan 的负相关（在类别分析中表现显著）。

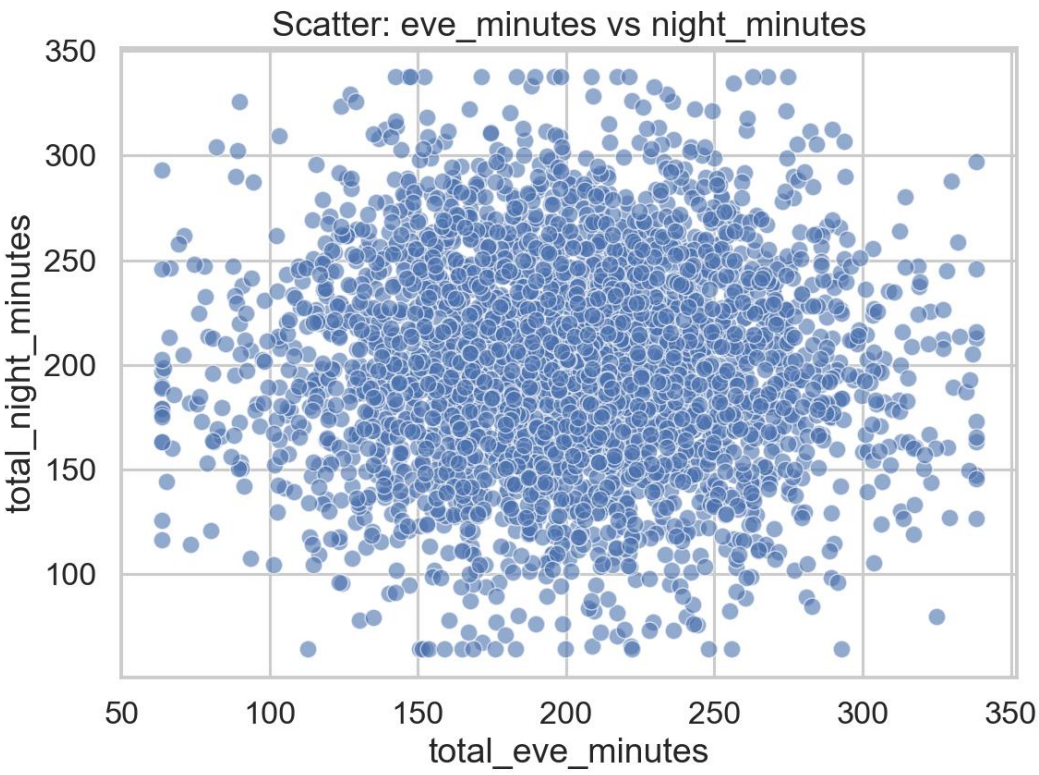

散点图（eve vs night minutes）：

- 二者呈弱至中度正相关（同为总体使用强的用户在两个时段都较高），但仍有大量点云分布，暗示用户时段偏好存在差异。

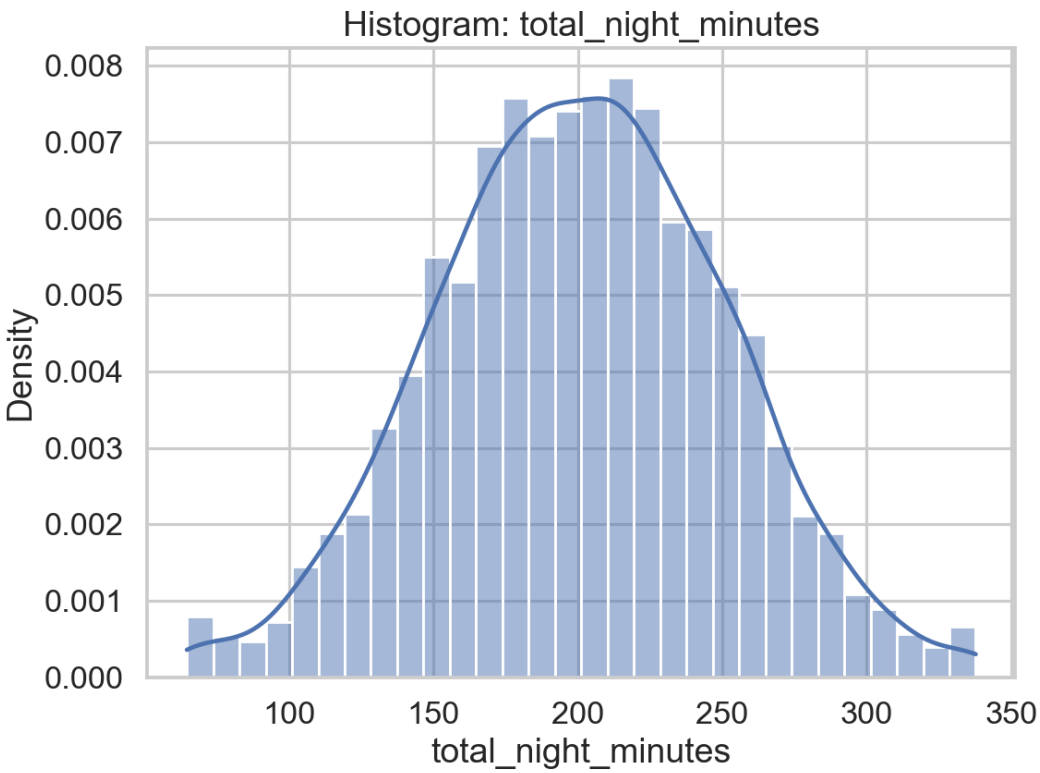

直方图（total_night_minutes）：

- 分布近似单峰，尾部略长，说明夜间通话时长有少数高值用户；IQR 截断已缓解极端异常值。

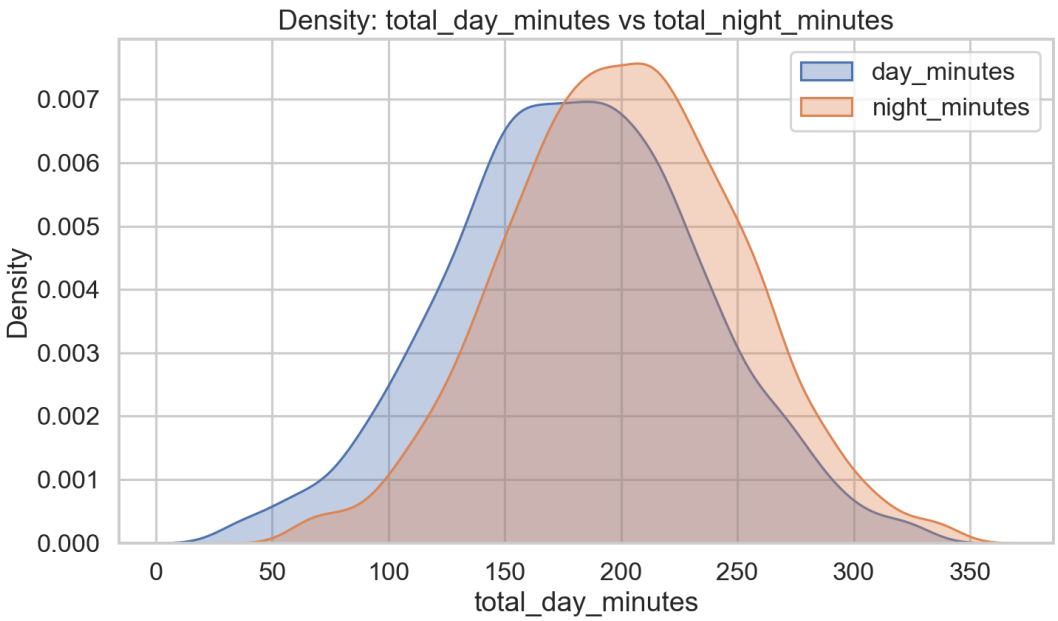

密度图（day vs night）：

- total_day_minutes 整体位置更高、峰值更靠右，白天通话强度普遍高于夜间；这与前面相关分析中 day_minutes 对流失影响较强一致。

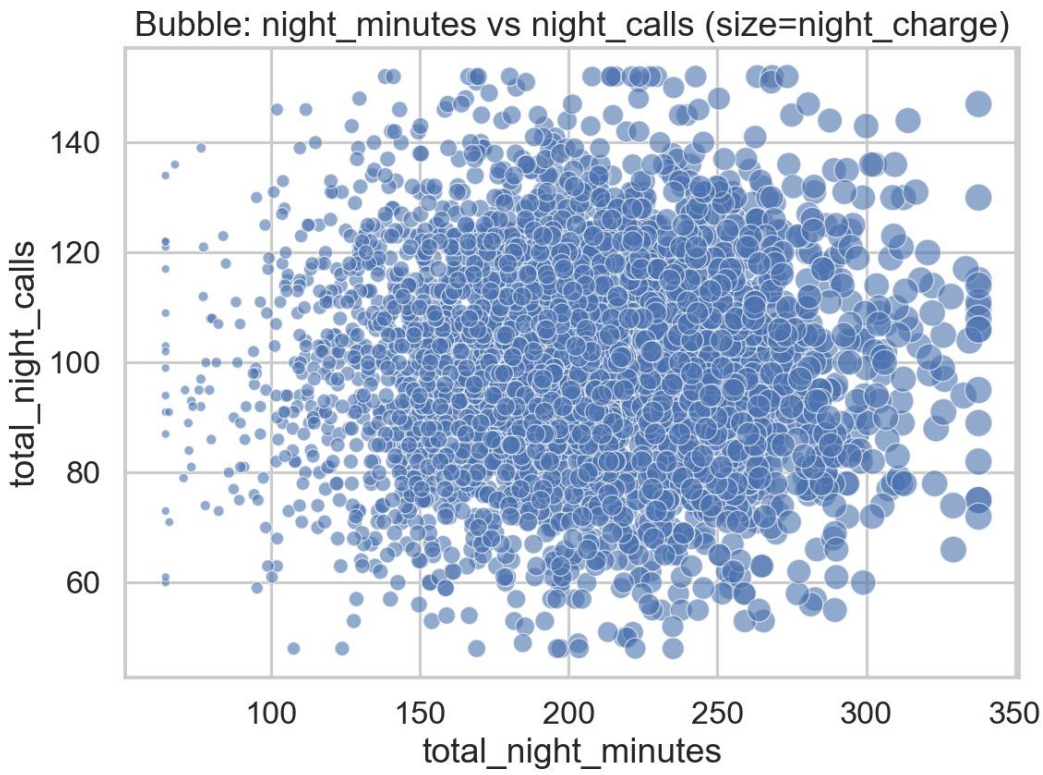

气泡图（night_minutes vs night_calls，size=night_charge）：

- 随 total_night_minutes 与 total_night_calls 增加，气泡普遍变大，符合按时长计费的逻辑；高时长高通话次数的用户夜间费用更高，可与高流失风险人群交叉筛查。

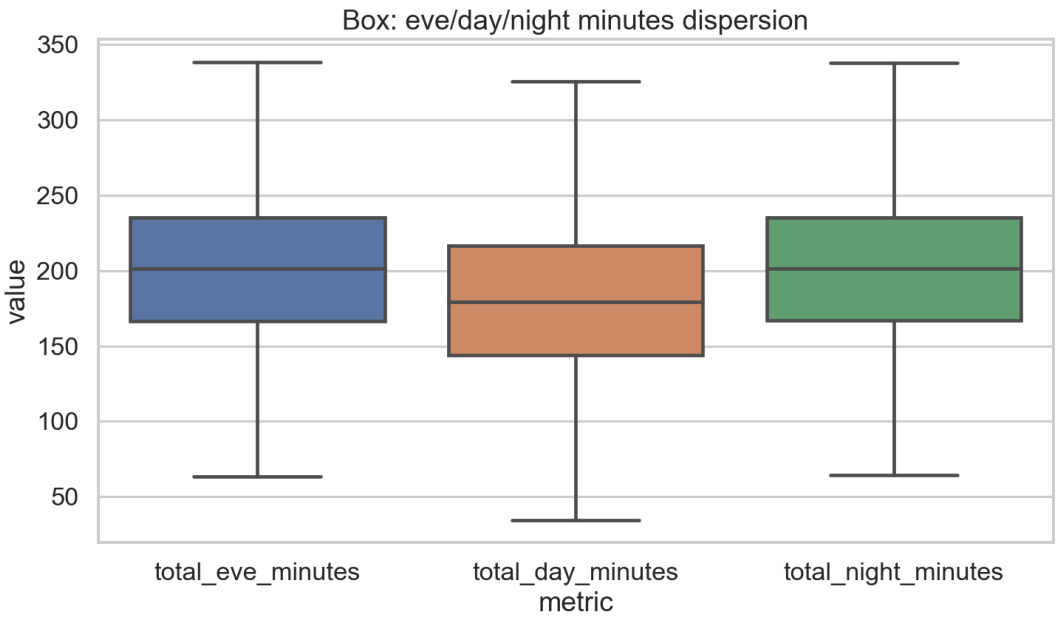

箱线图（eve/day/night minutes）：

- total_day_minutes 的中位数与 IQR 更大，离散程度高； total_eve_minutes 居中；total_night_minutes 相对更集中。离散更大的时段更可能与客服交互增加、账单提高相关。

3、提取特征值

```
  international_plan voice_mail_plan  number_customer_service_calls  ...  total_intl_charge  cs_calls_high  heavy_day
0                 no             yes                           1.0  ...               2.70              0          1
1                 no             yes                           1.0  ...               3.70              0          0
2                 no              no                           0.0  ...               3.29              0          1
3                yes              no                           2.0  ...               1.78              0          1
4                yes              no                           3.0  ...               2.73              1          0
5                yes              no                           0.0  ...               1.70              0          1
6                 no             yes                           3.0  ...               2.03              1          1
7                yes              no                           0.0  ...               1.92              0          0
8                 no              no                           1.0  ...               2.35              0          0
9                yes             yes                           0.0  ...               3.02              0          1
```

4、模型训练与预测

- 选择两种模型： LogisticRegression （线性、可解释）与 GradientBoostingClassifier（非线性、常见强基线）。
- 使用一致的特征工程与数据清洗，分层切分训练/测试集。
- 从概率输出中生成预测，评估并比较指标： ROC-AUC 、 Accuracy 、 Precision 、 Recall 、 F1 、 Confusion Matrix 。
- 输出测试集中最可能流失的前 20 位用户及其概率，便于业务落地。

LogisticRegression 模型的效果

```
模型: LogisticRegression
ROC-AUC: 0.8243 Accuracy: 0.7674 Precision: 0.3557 Recall: 0.7438 F1: 0.4813
Confusion Matrix:
[[550 163]
 [ 31  90]]
Classification Report:
              precision    recall  f1-score   support

           0     0.9466    0.7714    0.8501       713
           1     0.3557    0.7438    0.4813       121

    accuracy                         0.7674       834
   macro avg     0.6512    0.7576    0.6657       834
weighted avg     0.8609    0.7674    0.7966       834

测试集中最可能流失的Top20:
 churn_prob  pred  customer_id
   0.999616     1          542
   0.993191     1          198
   0.991819     1          985
   0.990001     1         3309
   0.987612     1         2164
   0.987553     1          184
   0.982925     1         2660
   0.982924     1         2553
   0.982239     1         2614
   0.977093     1         1662
   0.974524     1         1533
   0.969770     1         1165
   0.965572     1         2539
   0.961869     1         2696
   0.961148     1         3255
   0.959400     1         1973
   0.956510     1          792
   0.950929     1         2794
```

准确率为

GradientBoosting 模型的效果

```
Confusion Matrix:
[[705   8]
Classification Report:
              precision    recall  f1-score   support

           0     0.9527    0.9888    0.9704       713
           1     0.9149    0.7107    0.8000       121

    accuracy                         0.9484       834
   macro avg     0.9338    0.8498    0.8852       834
weighted avg     0.9472    0.9484    0.9457       834

测试集中最可能流失的Top20:
 churn_prob  pred  customer_id
   0.998704     1          985
   0.997567     1         1934
   0.997559     1         3205
   0.997111     1         2614
   0.995945     1          306
   0.986748     1         2113
   0.986550     1         1662
   0.982745     1         2099
   0.978553     1         1533
   0.977231     1         1038
   0.976050     1         2924
   0.975977     1         2824
   0.974826     1         1679
   0.968272     1         2164
   0.967505     1         2874
   0.966112     1         2747
   0.959929     1         2961
   0.956431     1         2343
   0.951020     1         2038
   0.950114     1          331
```

两者间的比较

```
GradientBoosting ROC-AUC= 0.8997 F1= 0.8
LogisticRegression ROC-AUC= 0.8243 F1= 0.4813
```

运用深度学习加强性能

- 在现有特征工程基础上引入一个神经网络模型： MLPClassifier （多层感知机），无

需额外安装深度学习库，直接用 scikit-learn 实现反向传播与多层网络。

- 与此前的 LogisticRegression 和 GradientBoostingClassifier 共同训练与评估，统一输出对比结果与 Top 流失名单，便于业务落地。

```
Confusion Matrix:
[[687  26]
 [ 36  85]]
              precision    recall  f1-score   support

           0     0.9502    0.9635    0.9568       713
           1     0.7658    0.7025    0.7328       121

    accuracy                         0.9257       834
   macro avg     0.8580    0.8330    0.8448       834
weighted avg     0.9234    0.9257    0.9243       834

测试集中最可能流失的Top20:
 churn_prob  pred  customer_id
   0.999975     1          985
   0.999927     1         3205
   0.999837     1         2824
   0.999824     1         1679
   0.999512     1         1934
   0.999222     1         2113
   0.999181     1         2874
   0.998903     1         2747
   0.998813     1         3272
   0.998400     1         2924
   0.998346     1         1662
   0.998172     1         1933
   0.997664     1         1912
   0.997407     1         1038
   0.997399     1         2099
   0.997364     1         1865
   0.997209     1          331
   0.996577     1         2038
   0.996374     1         2979
   0.996225     1         3168
```

比较

模型	**ROC-AUC** **精确度**	**F1 Score** 精确率和召回率调和平均值	**总体评价**
GradientBoosting	**0.8997**	**0.8000**	最佳
MLPClassifier	0.8931	0.7328	其次
LogisticRegression	0.8243	0.4813	最弱

可以看到添加了深度模型后效果并不好，然后后面换了一个模型之后就一直报错了…