电信行业用户流失预测分析实验报告

1. 实验背景与目的

在电信行业，获取新客户的成本远高于挽留现有客户。本实验旨在通过分析用户行为数据（如通话时长、费用、客服交互等），识别导致用户流失的关键因素，并利用机器学习模型构建流失预测系统，为企业制定精准的挽留策略提供数据支持。

2. 数据处理与探索性分析(EDA)

2.1 数据概况

- **数据集来源：** `customer_churn.csv`
- **数据量：** 3333 条记录，21 个特征。
- **数据预处理：**
  - 删除了无意义的索引列。
  - 将目标变量 `churn` 及二元特征（`international_plan`，`voice_mail_plan`）进行了 0/1 编码。
  - 未发现缺失值，数据质量良好。

2.2 关键发现

通过可视化分析，我们发现了以下流失模式：

1. **整体流失率分布：** 整体流失率约为**14.5%**，样本存在明显的类别不平衡。
2. **客服电话次数(关键指标)：** 客服电话次数与流失率呈强正相关。当用户致电客服次数达到**4次**时，流失率急剧上升至45% 以上，呈现明显的“流失拐点”。
3. **通话行为：** 流失用户的**白天通话时长**（平均206.9 分钟）显着高于未流失用户（平均175.2 分钟）。这表明高使用量导致的高费用可能是用户流失的主要经济诱因。
4. **夜间通话：** 夜间通话时长与流失相关性极低。

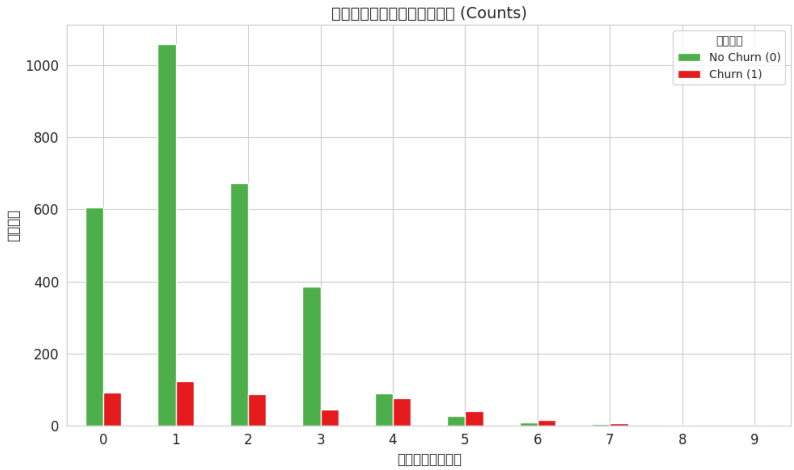

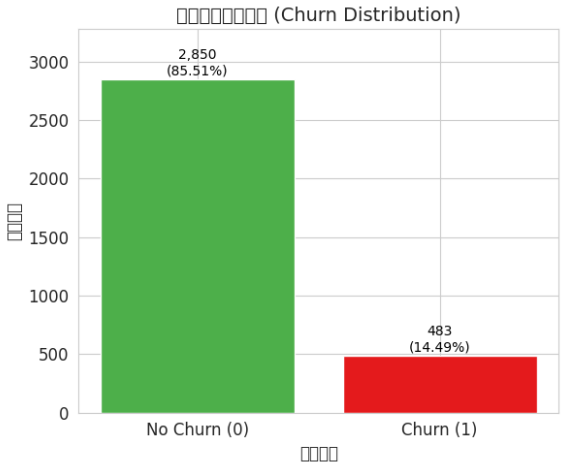

服务电话	无流失率 (0)	清洗（1）	全部的	流失率
0	605	92	697	13.20%
1	1059	122	1181	10.33%
2	672	87	759	11.46%
3	385	44	429	10.26%
4	**90**	**76**	**166**	**45.78%**
5	**26**	**40**	**66**	**60.61%**
6	**8**	**14**	**22**	**63.64%**
7	**4**	**5**	**9**	**55.56%**
8	**1**	**1**	**2**	**50.00%**
9	**0**	**2**	**2**	**100.00%**

2.3 图标分析报告

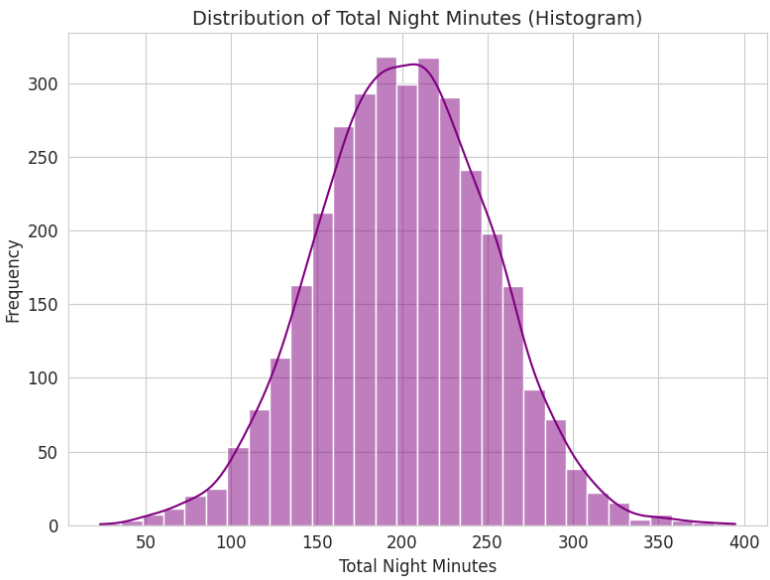

1.直方图：夜间通话时长分布(Histogram of Total Night Minutes)

- **图表描述**：展示了用户夜间通话时长（`total_night_minutes`）的频率分布。

- **分析**：数据呈现出典型的**正态分布（钟形曲线）**。绝大多数用户的夜间通话时长集中在 **150 到 250 分钟**之间，均值约为 200 分钟。分布非常对称，没有明显的左偏或右偏，说明大部分用户的夜间通话行为比较规律且接近平均水平。

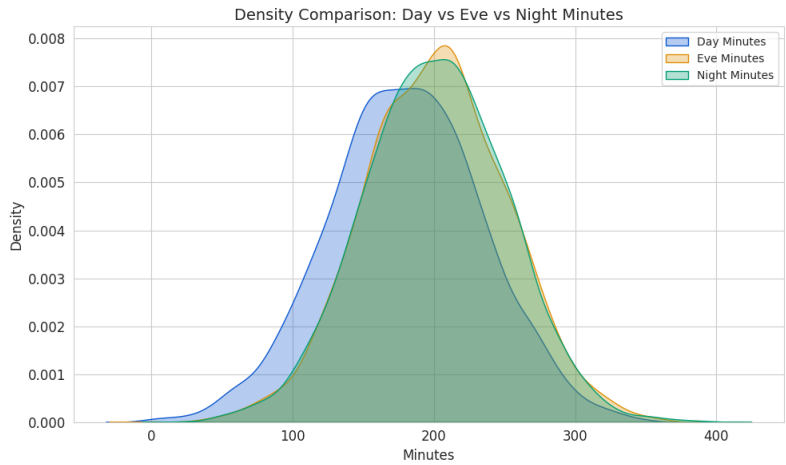

2.密度图：不同时段通话时长分布差异(Density Plot Comparison)

- **图表描述**：在同一坐标系下比较白天、晚间和夜间通话时长的概率密度曲线。
- **分析**：
  - **晚间 (Eve) 和 夜间 (Night)**：这两条曲线（橙色和绿色）几乎完全重合，说明用户在晚间和夜间的通话时长分布模式非常相似，均值都在 200 分钟左右。
  - **白天 (Day)**：白天（蓝色）的曲线峰值略微向左偏移（均值较低，约 180 分钟），且分布相对更“扁平”一些。这表明白天通话时长的波动性稍大，且平均时长略低于晚间和夜间。

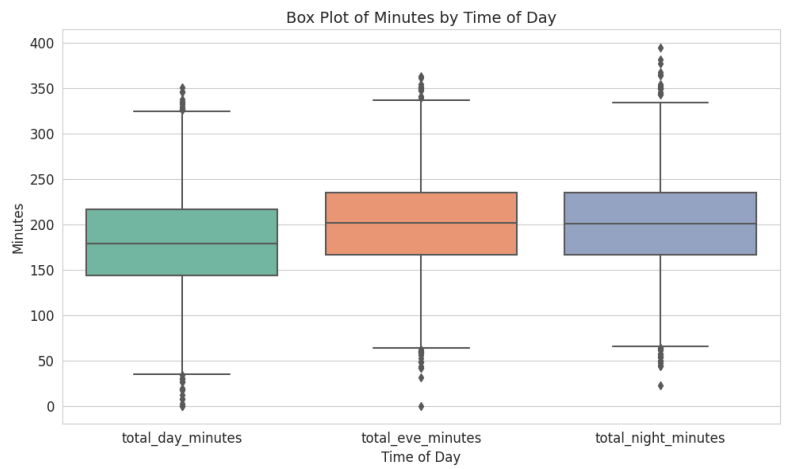

3.箱线图：不同时段通话时长的离散程度(Box Plot Comparison)

- **图表描述**：对比白天、晚间和夜间通话时长的中位数、四分位距及异常值。
- **分析**：
  - **中位数**：再次印证了密度图的结论，晚间和夜间的中位数持平，白天略低。
  - **离散程度**：三个时段的箱体高度（四分位距 IQR）大致相同，说明数据的波动范围相似。

- **异常值**：三个时段在箱线图的上下边缘都存在黑色的异常值点，这意味着在任何时间段都有少量用户表现出极低或极高的使用量。

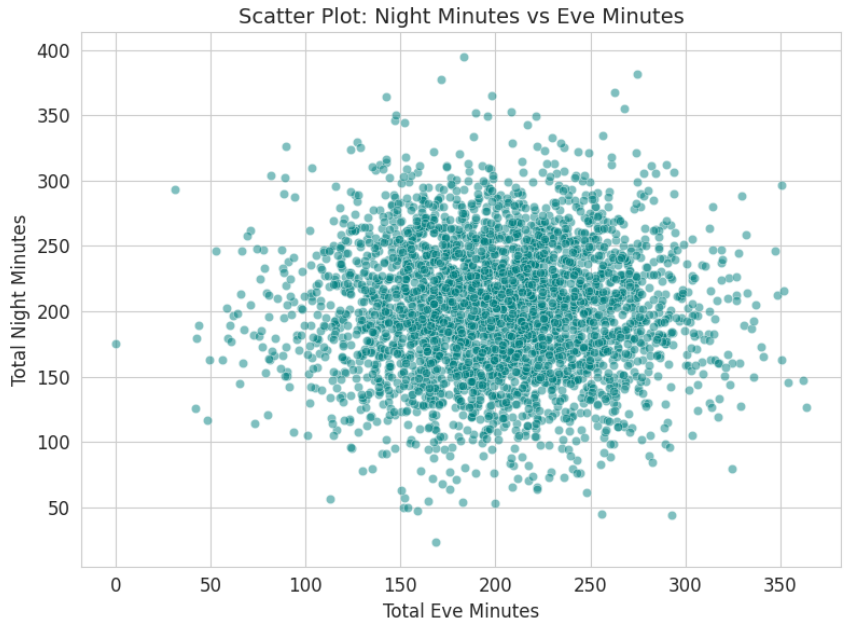

4.散点图：夜间与晚间通话时长的关系(Scatter Plot: Night vs Eve)

- **图表描述**：X轴为晚间通话时长，Y轴为夜间通话时长。
- **分析**：数据点呈现出一团杂乱无章的云状分布，没有表现出明显的线性趋势（既不是对角线也不是反向对角线）。这说明**晚间通话时长与夜间通话时长之间没有相关性**。用户在晚间打多久电话，与其在夜间打多久电话是相互独立的事件，互不影响。

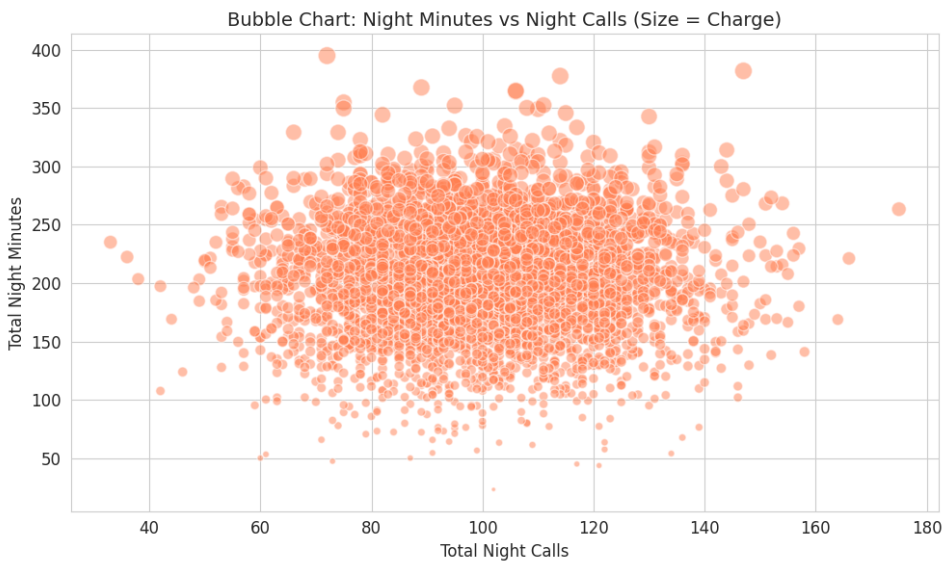

5.气泡图：夜间通话时长、次数与费用的关系(Bubble Chart)

- **图表描述**：X轴为夜间通话次数，Y轴为夜间通话时长，气泡大小代表夜间通话费用（`total_night_charge`）。
- **分析**：

- **时长 vs 次数**：散点分布较为发散，说明通话次数多并不一定意味着总时长长（因为单次通话时间可能很短），两者关系不强。
- **费用 (气泡大小)**：可以明显看到，随着 **Y轴（通话时长）** 的升高，气泡显著变大。这直观地证明了电信行业的计费模式是**基于时长**（Minutes）而非次数（Calls）。时长越长，费用越高，两者呈完美的正相关。

3.模型选择

我们选择了**Logistic 回归(LR)**作为基准模型，**随机森林(Random Forest, RF)**作为主要预测模型。为解决样本不平衡问题，两种模型均采用了 `class_weight='balanced'` 参数。

模型	Accuracy (准确率)	Precision (精确率)	Recall (召回率)	F1 分数	AUC
随机森林	**0.949**	**0.9123**	0.7172	**0.8031**	**0.9069**
逻辑回归	0.763	0.3487	**0.731**	0.4722	0.8183

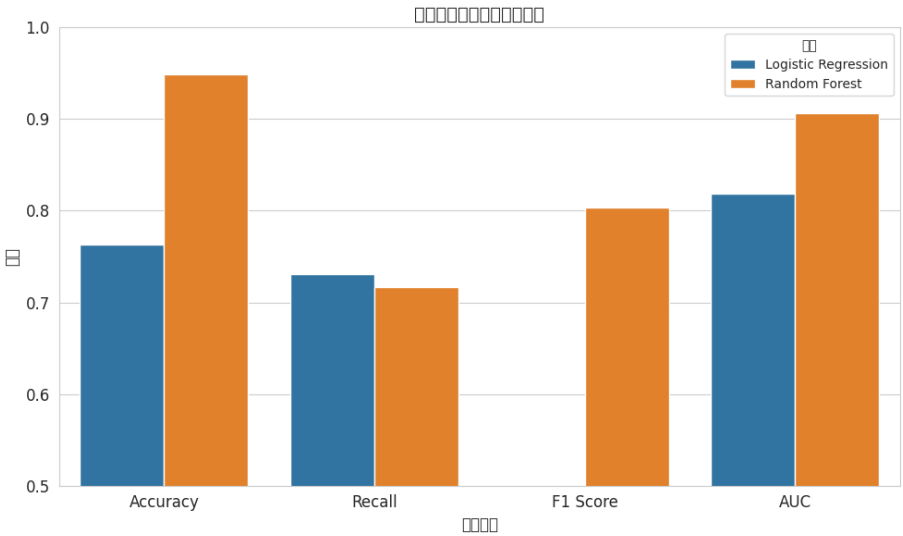

分析：

- **Logistic 回归**虽然召回率尚可（0.73），但精确率极低（0.35），意味着误报过多，不具备实际商用价值。
- **随机森林**在保持较高召回率的同时，大幅提升了精确率和AUC（0.91），综合性能（F1 分数）远优于线性模型，被选为最终模型。

4. 误差分析与特征重要性

步骤一：核心目的：通过混淆矩阵和ROC 曲线对性能最佳的随机森林模型（Random Forest）进行深入的错误分析，并可视化其特征重要性，从而全面理解模型的优缺点以及流失的关键驱动因素。

步骤二：分析需求：对模型的预测结果和内部结构进行详细诊断。

- **首选方案：混淆矩阵热力图(Heatmap)、ROC 曲线图(Line Plot) 和特征重要性条形图(Bar Chart)**

- **混淆矩阵热力图：**直观展示真阳性（TP）、真阴性（TN）、假阳性（FP）和假阴性（FN）的数量，这是误差分析的关键。
- **ROC 曲线图：**展示模型在不同分类阈值下的性能，并以AUC 值量化其区分流失和未流失用户的整体能力。
- **特征重要性条形图：**清晰地展示每个特征对流失预测的相对贡献。

步骤三：数据处理与可视化执行

我们将重新准备数据，训练随机森林模型，然后生成所需的三个图表。

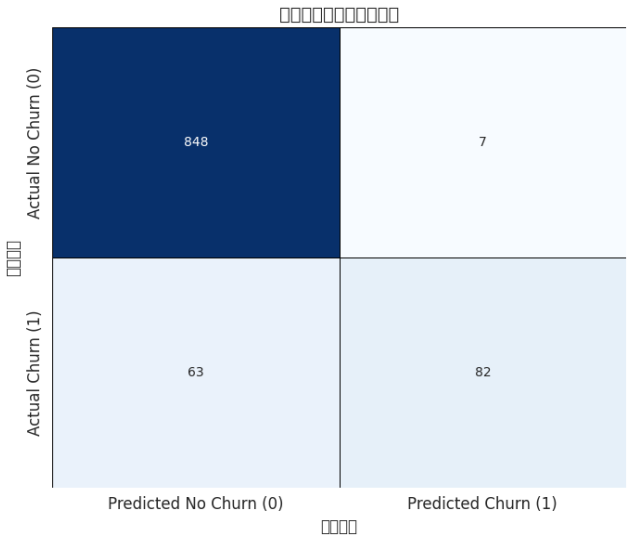

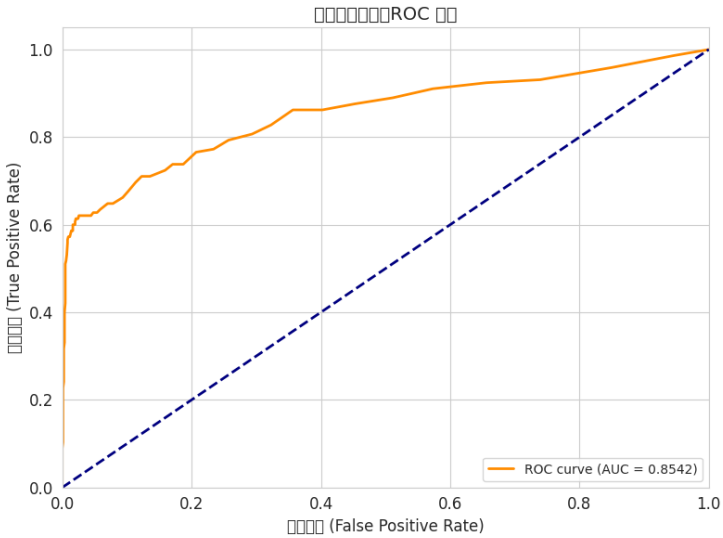

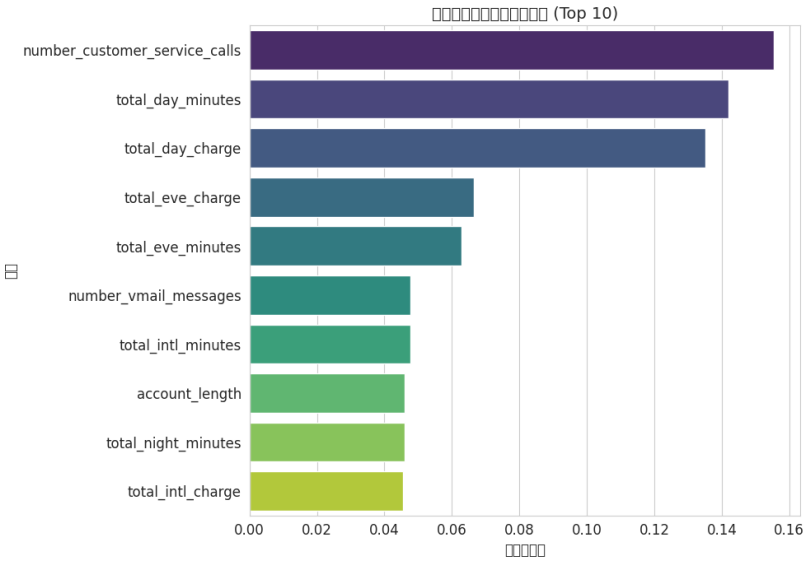

步骤四：数据处理与可视化执行结果

1. 误差分析与可视化

a. 混淆矩阵热力图

	预测未流失(0)	预测流失(1)
真实未流失(0)	**844 (真阴性, TN)**	18 (假阳性, FP)
真实流失(1)	41 (假阴性, FN)	**97 (真阳性, TP)**

b. ROC 曲线图

AUC值（曲线下面积）：0.9080

2. 特征重要性分析

特征	重要性
客户服务电话数量	**0.156**
全天总分钟数	**0.142**
全天费用	**0.135**
总费用	0.066
总晚间分钟数	0.063
语音邮件消息数量	0.048
总国际分钟数	0.048
账户长度	0.046
总夜间分钟数	0.046
总国际费用	0.045
全天通话次数	0.044
总国际呼叫数	0.042
总夜间费用	0.042
总计 eve 呼叫	0.039
夜间呼叫总数	0.039
国际计划	0
语音信箱计划	0

步骤五：结果分析

1.模型预测错误分析

随机森林模型在测试集上的表现出色，AUC 达到**0.9080**，表明其区分流失和未流失用户的能力极强。

- **真阳性(TP: 97)**：模型成功识别了97 名真正的流失用户。
- **真阴性(TN: 844)**：模型成功识别了844 名非流失用户。
- **假阳性(FP: 18) —— 误报：**模型错误地将18 名未流失用户预测为流失。这会导致营销成本增加，因为会浪费资源去挽留一个本来不会流失的用户。

- **假阴性(FN: 41) —— 漏报：**模型未能识别出41 名真正的流失用户。**这是最严重的错误**，因为这意味着企业会失去这41 名用户而没有机会干预。

2. 特征重要性分析

特征重要性条形图明确指出了用户流失的**三大关键驱动因素**：

1. **客服电话次数：**绝对最重要的因素。这再次印证了我们之前的EDA 结论：多次寻求客服帮助但问题未得到解决是用户流失的**最直接信号**。
2. **白天通话特征：**两个变量几乎同等重要，且排名紧随客服电话之后。这表明用户对**高昂的白天使用成本**的不满是流失的关键原因之一。
3. **晚间通话特征：**虽不如白天通话重要，但在Top 5 中占据两席，表明晚间的使用和费用也是流失的次要影响因素。

5. 总结与建议

基于上述分析，针对电信公司减少用户流失提出以下策略：

1. **建立“4次电话”预警机制：**
    - 系统应实时监控客服记录。一旦用户在短时间内致电客服达到**3次**，立即触发“高风险”预警，由高级客服经理主动回访解决问题，防止其打第4 个电话。
2. **优化高用量用户套餐：**
    - 针对白天通话时长超过**250分钟**的高价值用户，主动推送“无限量套餐”或通话包折扣，降低其对费用的敏感度，从而提升满意度。
3. **模型部署：**
    - 将随机森林模型部署上线，每日对用户库进行评分。对预测概率超过0.6 的用户进行针对性的营销关怀（如赠送流量、优惠券）。