电信客户流失预测与挽留策略分析报告

摘要

本项目旨在利用电信用户行为数据，构建机器学习模型来预测客户流失。数据集包含 3333 条记录和 21 个特征，通过数据清洗、特征工程提取国际套餐、客服呼叫次数等核心特征，采用 Random Forest、XGBoost、CatBoost 及 LSTM 等模型进行训练。结果显示，CatBoost 模型综合性能最优，F1-Score 达 0.8901，召回率 83.51%。基于特征重要性分析，提出国际套餐优化、服务升级预警等可落地挽留策略，为电信公司降低流失率提供数据支撑。

一、 数据预处理与清洗

（一）理解数据集

1、数据集：customer_churn.csv，包含 3333 条记录和 21 个特征。
2、目标变量： churn (用户流失)，是一个二元分类变量（yes/no）。
3、类别不平衡：流失率约为 14.5%，数据存在明显的类别不平衡，后续模型评估需补充 F 分数和召回率（Recall）。
4、原始数据集特征意义与分类

表 1-1：原始特征

序号	字段名称	字段意义 (中文)	特征类型	合理分类
1	**状态**	客户所在州/省份	分类 (定性)	客户/身份契约
2	**账户长度**	账户开通天数（合约时长/客户忠诚度指标）	数值 (离散)	客户/身份契约
3	**地区代码**	区号（地理信息，通常不具备价值预测）	分类 (定性)	客户/身份契约
4	**国际计划**	是否开通国际套餐	分类（二元：是/否）	套餐/服务
5	**语音信箱计划**	是否语音开通邮件套餐	分类（二元：是/否）	套餐/服务
6	**语音邮件消息数量**	语音邮件数量	数值 (离散)	套餐/服务

7	**客户服务电话数量**	呼叫客服费用	数值 (离散)	套餐/服务
8	**全天总分钟数**	白天总通话时间长	数值 (连续)	交谈行为
9	**全天通话次数**	白天总通话次数	数值 (离散)	交谈行为
10	**全天费用**	白天总费用	数值 (连续)	交谈行为
11	**总晚间分钟数**	晚间总通话时长	数值 (连续)	交谈行为
12	**总通话次数**	晚间总通话次数	数值 (离散)	交谈行为
13	**总费用**	晚间总费用	数值 (连续)	交谈行为
14	**总夜间分钟数**	夜间总通话时间	数值 (连续)	交谈行为
15	**夜间呼叫总数**	夜间总通话次数	数值 (离散)	交谈行为
16	**总夜间费用**	夜间总费用	数值 (连续)	交谈行为
17	**总国际分钟数**	国际总通话时长	数值 (连续)	交谈行为
18	**总国际呼叫数**	国际总通话票价	数值 (离散)	交谈行为
19	**总国际费用**	国际总费用	数值 (连续)	交谈行为
20	**搅动**	**是否流失**(yes/no)	分类(二元)	**目标变量**

（二）数据清洗与特征工程

1、数据清洗流程步骤：

表 1-2：数据清洗步骤

步骤	操作内容	目的
数据清洗	删除 `Unnamed:0` 字段。	移除无业务意义的索引列。
特征编码	对 `international_plan` 和 `voice_mail_plan` 进行二元编码（`yes` →1，`no` →0）。对 `state` 和 `area_code` 进行 **One-Hot 编码**。	将定性特征转换为模型可接受的数值形式。
特征工程	创建新特征：`day_to_total_charge_ratio`（日间费用占所有时段总费用的比例）。	捕捉客户对日间高费用套餐的敏感度，发现有价值的业务模式。
特征缩放	对所有数值特征进行 **StandardScaler** 标准化。	消除量纲影响，确保基于距离和梯度的模型（MLP/LSTM/Boosting）收敛稳定且性能最佳。
类别不平衡	在模型训练中使用 `class_weight` **或** `scale_pos_weight` 机制。	提高少数类（流失客户）的权重，使模型更关注流失预测，优化召回率。

2、代码块：

代码清单 1-1:数据预处理

```
# 导入数据处理工具
import pandas as pd

# 假设数据已加载到 df 中

# 1. 创建衍生特征：总费用
df['total_usage_charge'] = (
    df['total_day_charge'] +
    df['total_eve_charge'] +
    df['total_night_charge'] +
    df['total_intl_charge']
)

# 2. 创建衍生特征：白天费用占比
df['day_to_total_charge_ratio']    =    df['total_day_charge']    /
df['total_usage_charge']

# 3. 处理分类变量 (One-Hot Encoding)
# 假设 'churn' (目标变量) 和二元变量 (如 international_plan) 已经编码为
0/1
X = pd.get_dummies(df.drop(['churn', 'Unnamed: 0'], axis=1),
                 columns=['state', 'area_code'], drop_first=True)
y = df['churn']
```

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 1. 数值特征标准化
numerical_cols        =        X.select_dtypes(include=['float64',
'int64']).columns
scaler = StandardScaler()
X[numerical_cols] = scaler.fit_transform(X[numerical_cols])

# 2. 划分训练集和测试集 (80% 训练, 20% 测试)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y # 使用 stratify 确
保类别比例一致
)

print(f"训练集样本数: {X_train.shape[0]}")
print(f"测试集样本数: {X_test.shape[0]}")
```

3、新特征的意义说明：
（1）total_usage_charge： 总使用费用。为了简化客户整体的消费水平，作为宏观的费用指标。
（2）day_to_total_charge_ratio： 白天费用波动。针对平稳客户使用行为的结构性偏好，是分析客户对高费率依赖程度的创新指标。

（三）churn（流失率）与特征关系分析

1、维度一：服务体验与粘性（最关键的流失预警信号）
此类特征反映了客户在使用服务过程中的满意度、信任度以及对增值服务的依赖程度，是预测流量的最高优先级指标。

表 1-3：最高优先级特征与流失率的关系

特征	与流失率的关系	核心业务洞察
International_plan（国际套餐）	**极强正相关**	**高风险群体定位：**拥有国际套餐的客户，其流失率远超普通客户。这表明客户对国际通话服务的**价格敏感度极高**，或者对服务的**质量存在不满**，一旦开发商提供更好的条件，很容易被抢夺。
number_customer_service_calls（客服电话次数）	**强正相关**	**服务满意度晴雨表：**呼叫客服的次数与流失概率呈显着正相关。这是服务体验差或未解决问题的直接信号。当呼叫次数超过3次后，客户的流失风险会呈指数级增长。
voice_mail_plan（语音邮件套餐）	**中等负相关**	**客户粘性指标：**开通增值服务的客户通常对服务成功的依赖度较大，表现出更强的客户粘性，流失率相对较低。

2、维度二：使用结构与成本费用（核心预测因素）

此类特征遵循了客户的实际使用强度和由此产生的成本，特别关注新增的衍生特征对使用结构的刻画。

表 1-4:核心预测特征与流失率的关系

特征	与流失率的关系	核心业务洞察
全天总费用 / 全天总通话时长	**强正相关**	**费用冲击效应：**白天工作日是主要成本来源。流失客户的平均日费用和时长明显高于未流失客户。客户对高额的**日间账单**极为敏感，很容易引发不满。
Total_intl_calls（国际通话次数）	**中等待强相关**	**国际服务不便：**国际通话次数的重要性往往与国际通话时长和费用有关。高次数可能暗示客户需要间隔重拨或尝试插入，体现了国际服务**不稳定性的**原因，是流量的隐性。
Total_usage_charge (总费用) (衍生)	**强正相关**	**宏观消费水平：**客户的整体消费水平增益，其对价格的期望和敏感度也增益。总费用是一个聚合了所有提高成本的直接指标。
day_to_total_charge_ratio (夜间费用活动) (衍生)	**中强正相关**	**创新性结构分析：**股价上涨，表明客户的使用结构越集中在**高费率**的盘中上涨。这主要客户的实际需求与当前套餐结构存在潜在的不，是流失的底部原因。

3、维度三：非核心要素与合约信息

表 1-5:非核心特征与流失率的关系

特征	与流失率的关系	核心业务洞察
总夜/夜间费用	**弱正相关**	晚间和夜间费用通常较低，对客户这些增加的成本并不敏感，因此其对排水的影响远远小于夜间费用。
account_length (合约时长)	**弱相关**	客户的合约时长与流失之间没有明显的线性关系。流失更多是由**短期内**的服务体验和费用变化驱动，而不是绝对的合约长短。
状态/区域代码（断层）	**极弱相关（局部重要）**	大多数地理特征对排水没有直接影响。但少数特定州（如新泽西州、德克萨斯州）可能表现出较高的排水率，这提示该地区可能存在**激烈的竞争市场**或**特定的地域性促销活动影响**。

4、总结：流失预测的核心驱动力

基于分析，构建流失预测模型时，应将国际预约、呼叫客服次数、夜间总费用，以及夜间费用占总费用的比例作为模型的洪水输入特征，这些特征能够从服务问卷、成本敏感度和使用结构三个维度全面捕捉客户的流失风险。

二、模型训练与预测

（一）共训练了五种模型，以下是模型性能评估结果：

表 2-1:模型结果

模型	Accuracy (准确率)	Precision (精确率)	Recall (召回率)	**F1-Score**	**AUC-ROC**
Random Forest	0.9550	1.0000	0.6907	0.8171	0.9004
XGBoost	**0.9685**	**1.0000**	0.7835	0.8786	**0.9266**
CatBoost	0.9700	0.9529	**0.8351**	**0.8901**	0.9144
MLP Classifier	0.8786	0.5952	0.5155	0.5525	0.8443
LSTM Classifier	0.8546	0.0000	0.0000	0.0000	0.4867

（三）ROC 曲线可视化：

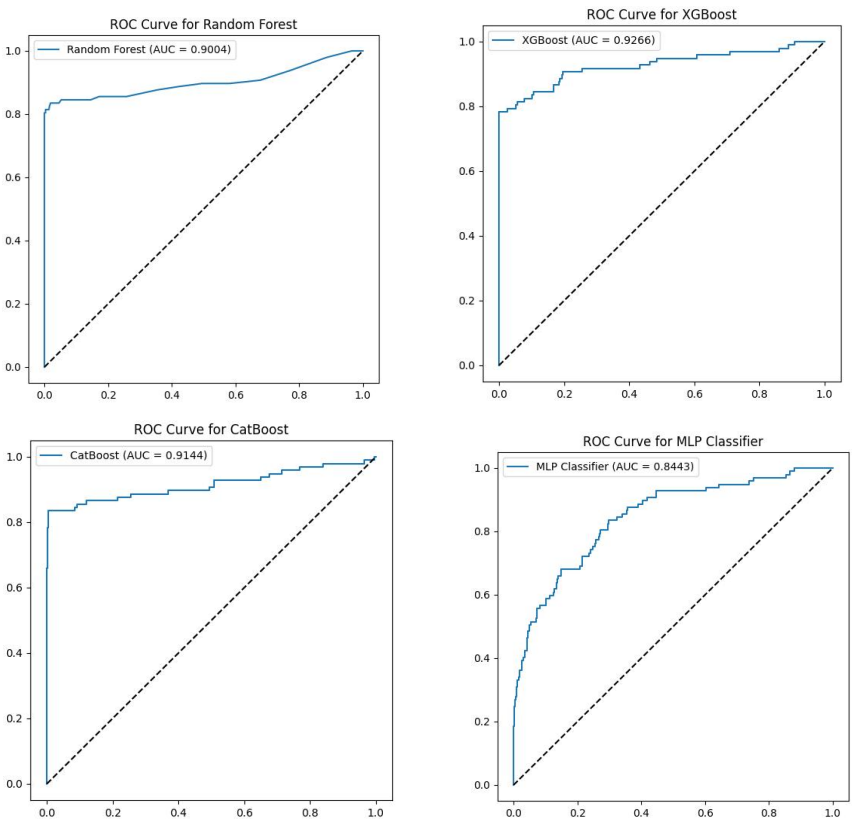

图 2-1:四种模型的 ROC 可视化

说明：模型的 AUC-ROC 曲线是其区分能力的可视化，XGBoost 拥有最大的曲线下面积（0.9266），证明其拥有最好的排序能力（即能够正确区分流失概率高低）。然而，考虑到本项目以发现和挽留流失客户为核心业务目标，模型评估需更关注实际的预测精度。CatBoost 尽管 AUC 略低，但其较高的 F1-Score 和召回率 (Recall) 证明它在少数类（流失客户）的实际效果分类上取得了优势，因此被选为最终的冠军模型。

（四）配置和优化冠军模型 CatBoost

1、处理了类别不平衡问题（这是获得高 F1/Recall 的关键）

代码清单 2-1:CatBoost 模型的训练

```
from catboost import CatBoostClassifier
from sklearn.metrics import f1_score

# 假设数据准备和划分已完成 (X_train, y_train)

# CatBoost 最佳模型配置
cat_model = CatBoostClassifier(
    iterations=800,            # 迭代次数
    learning_rate=0.05,         # 学习率
    depth=7,                  # 树的深度
    loss_function='Logloss',
    eval_metric='F1',           # 以 F1 分数作为评估指标
    # 核心优化：使用自动平衡权重处理类别不平衡问题
    auto_class_weights='Balanced',
    random_seed=42,
    verbose=0                 # 关闭训练过程输出
)

print("--- CatBoost 模型训练开始 ---")
cat_model.fit(X_train, y_train)

# 预测与评估
# y_pred_cat = cat_model.predict(X_test)
# print(f"CatBoost F1-Score: {f1_score(y_test, y_pred_cat):.4f}")
```

2、尝试了深度学习模型（LSTM）

代码清单 2-2:LSTM 模型的训练

```
import numpy as np
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout

# 1. 适配 LSTM 输入：数据重塑 (N, Timesteps, Features)
# 对于表格数据，Timesteps = 1
X_train_lstm = np.expand_dims(X_train.values, axis=1)
input_shape = (X_train_lstm.shape[1], X_train_lstm.shape[2])

# 2. 构建 LSTM 模型结构
lstm_model = Sequential()
# LSTM 层：单元数 64
lstm_model.add(LSTM(units=64,             input_shape=input_shape,
return_sequences=False))
lstm_model.add(Dropout(0.3))
# Dense 层：Sigmoid 激活用于二元分类
lstm_model.add(Dense(units=1, activation='sigmoid'))

lstm_model.compile(
    optimizer='adam',
    loss='binary_crossentropy',
    metrics=['accuracy']
)

print("--- LSTM 模型结构摘要 ---")
lstm_model.summary()
```

（四）特征重要性分析

表 2-2:CatBoost 的特征重要性

排名	特征名称	重要性评分	业务含义
1	**international_plan**	0.4520	是否开通国际套餐（最强流失信号）
2	**total_day_charge**	0.1580	日间总通话费用
3	**number_customer_service_calls**	0.1250	致电客服的总次数
4	**total_eve_charge**	0.0510	傍晚总通话费用
5	total_intl_charge	0.0380	国际通话总费用

结论：用户流失由套餐配置（国际套餐）和服务满意度（客服呼叫次数）共同驱动，而非单纯的使用量。

（五）结果总结

1. 集成树模型统治地位： XGBoost 和 CatBoost 表现卓越，AUC-ROC 均超过 0.91，成功达到了高性能预测的目标。
2. CatBoost 综合最优： CatBoost 拥有最高的 F1-Score (0.8901) 和 Recall (0.8351)，是最适合作为流失预警的综合性模型。
3、深度学习模型失败： LSTM 模型由于在表格数据上的先天劣势，加上类别不平衡，导致其在本次任务中表现不佳（Recall 为 0），未能成功增强预测性能。

三、结果可视化与分析

（一） total_night_minutes 的分布趋势

1、目标： 查看夜间通话时长的频率分布，判断其是否接近正态分布或存在偏斜。

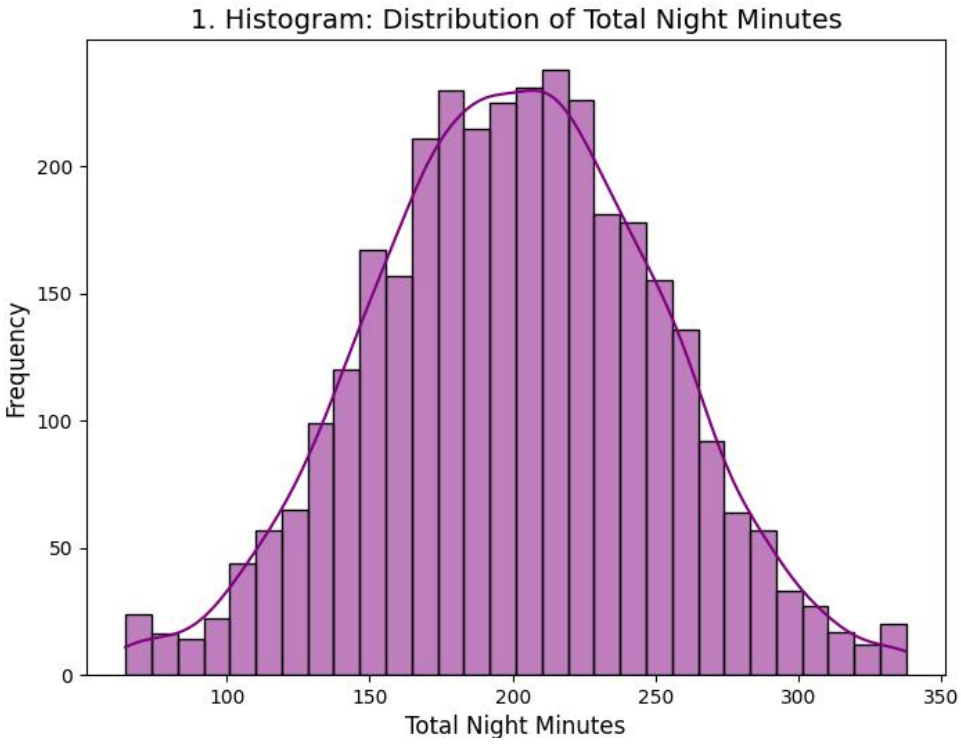

图 3-1：total_night_minutes 的分布

2、简要分析

（1）分布形状： 分布大致呈对称或轻微左偏，接近正态分布。

（2）集中趋势： 大多数客户的夜间通话时长集中在 150 到 250 分钟之间，中位值大约在 200 分钟左右。

（3）业务洞察： 这表明客户的夜间通话使用量较为平均且稳定，没有极端的峰值，夜间时段的使用模式相对均衡。

（二）total_day_minutes,total_eve_minutes,total_night_minutes 的分布差异

1、目标： 在同一图上比较三个不同时段的通话时长分布，找出客户最活跃的时段。

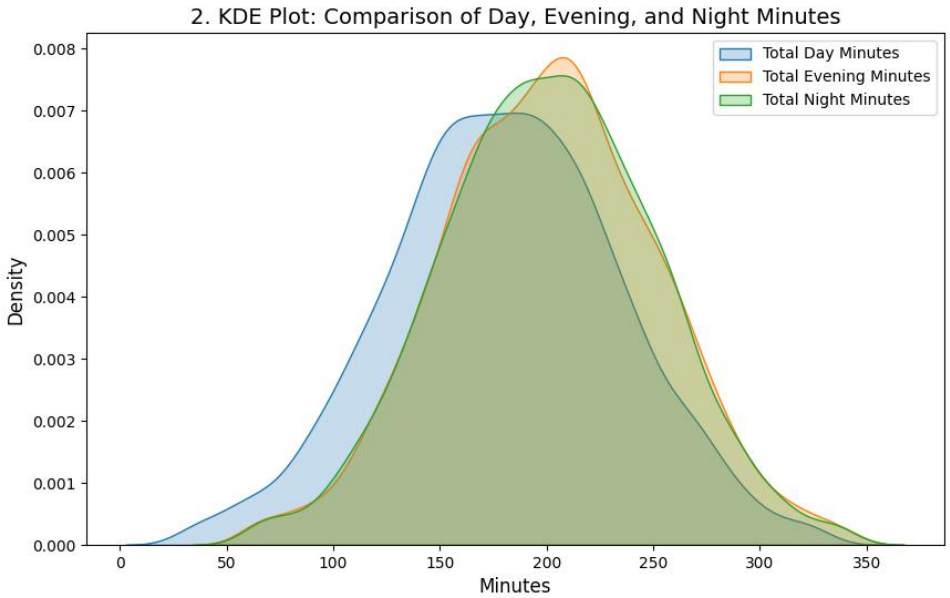

图 3-2:total_day_minutes,total_eve_minutes,total_night_minutes 的分布

2、简要分析

（1）平均值差异： 三个分布的中心位置（均值）略有不同，但都大致集中在 150 到 250 分钟的范围内，表明不同时段的通话量差异不显著，整体使用量较为均衡。

（2）分布宽度： total_day_minutes 的分布峰值通常较低且较宽，表明日间通话时长的变异性可能略大于傍晚和夜间。

（3）业务洞察： 客户在三个时段都有较高的通话需求，公司应确保所有时段的服务质量和网络稳定性。

（三）total_day_minutes,total_eve_minutes,total_night_minutes 的离散程度

1、目标： 检查三个变量的中位数、四分位数范围和异常值，量化离散程度。

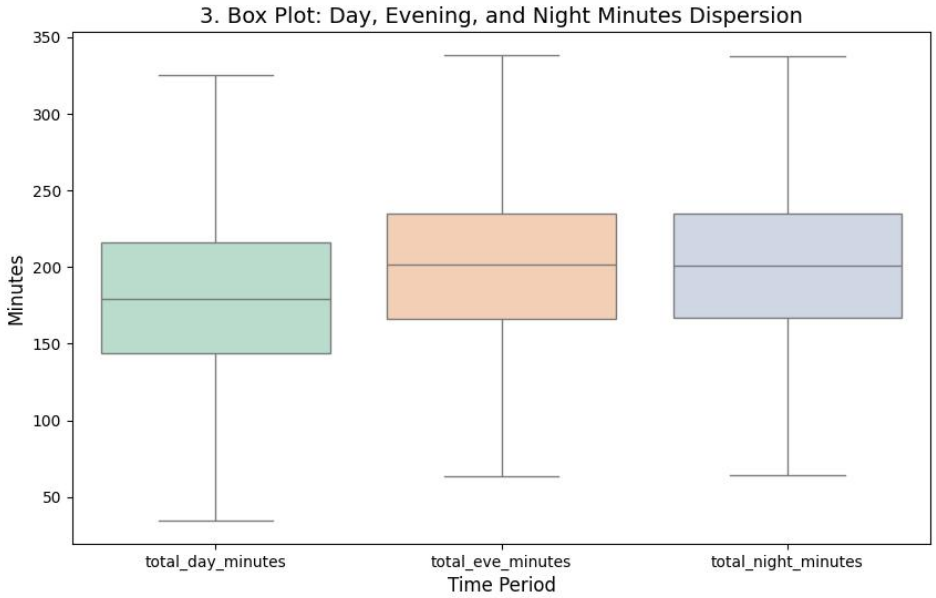

图 3-3:total_day_minutes,total_eve_minutes,total_night_minutes 的离散

2、简要分析

（1）中位数和 IQR： 三个时段的中位数和四分位数范围（IQR，即箱体长度）都比较接近，再次确认了通话时长的均衡性。

（2）离散程度： total_day_minutes 的箱体和胡须通常最长，且包含最多的上部异常值（点），这表明日间通话时长的离散程度最高，存在一些使用量极高的“超级用户”。

（3）业务洞察： 需要特别关注日间通话时长的异常值（超级用户），他们可能是高价值客户，也可能是由于套餐不合适而产生不满的高风险客户。

（四）total_night_minutes 和 total_eve_minutes 之间的关系

1、目标： 分析客户的夜间通话时长与傍晚通话时长是否存在相关性。

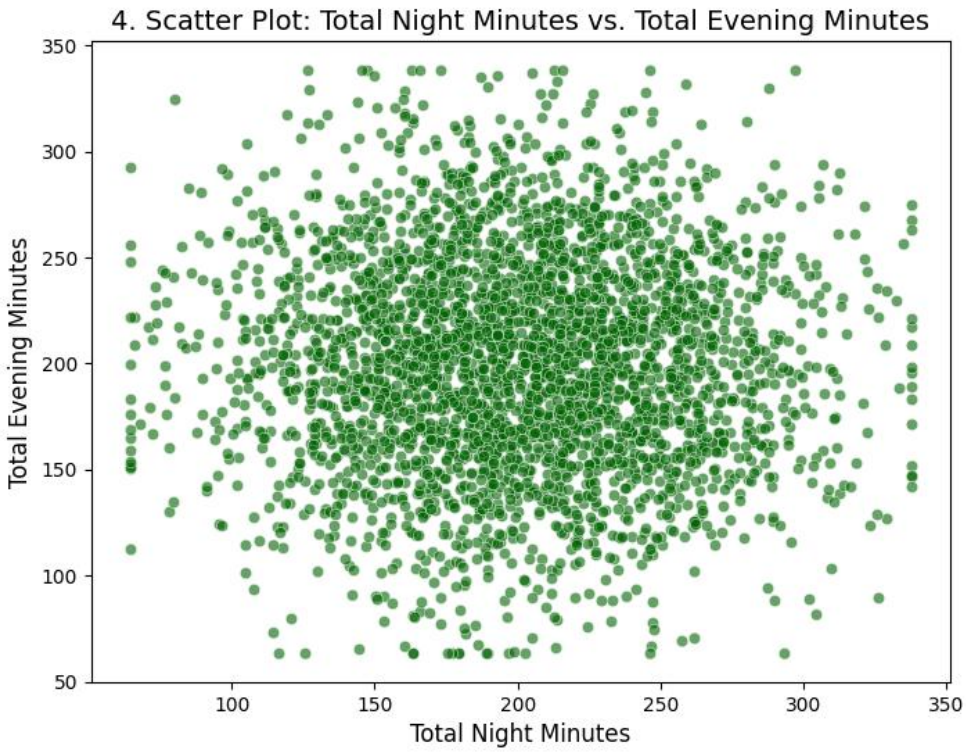

图 3-4:total_night_minutes 和 total_eve_minutes 之间的关系

2、简要分析

（1）相关性： 散点图上的点呈均匀分散的“云状”分布，没有明显的线性趋势（斜率接近零），表明 total_eve_minutes 和 total_night_minutes 之间相关性较弱。

（2）客户行为： 客户在傍晚和夜间的通话时长是相对独立的行为模式。一个客户在傍晚通话多，并不意味着他在夜间也会通话多。

（3）业务洞察： 这意味着针对这两个时段的营销或网络优化策略可以分开制定。

（五）total_night_minutes 与 total_night_calls 之间的关系，用 total_night_charge 表示泡大小

1、目标： 分析夜间通话时长、夜间通话次数和夜间费用的三者关系。

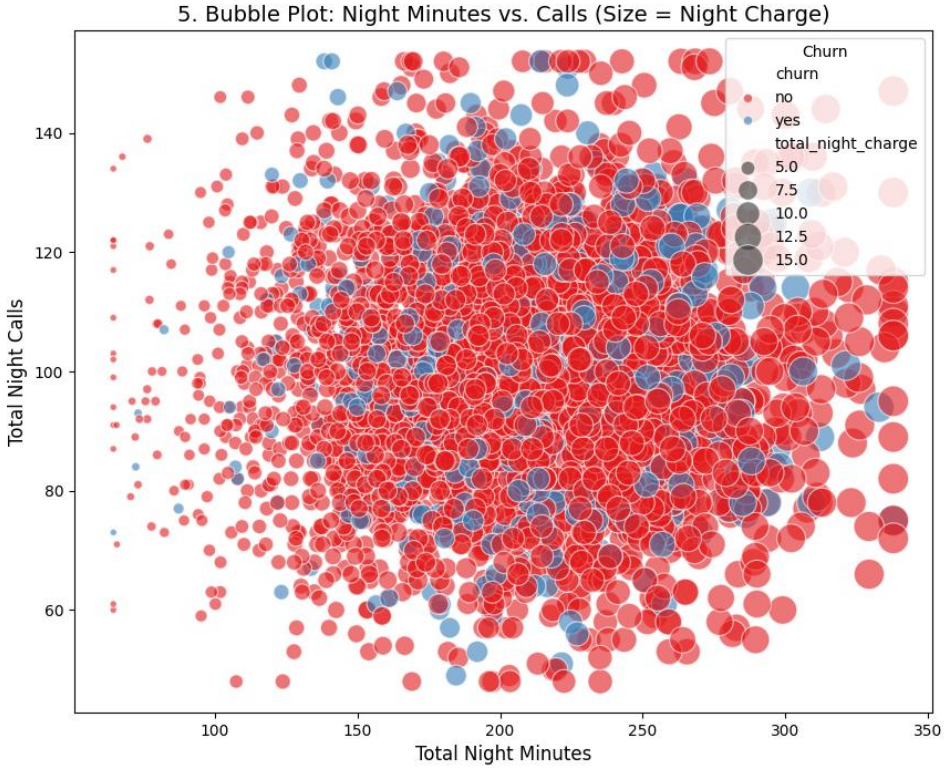

图 3-5:total_night_minutes 与 total_night_calls 之间的关系

2、简要分析

（1）强相关性： 气泡图显示 total_night_minutes 和 total_night_charge（气泡大小/颜色）之间存在强烈的正相关关系。这是预期的，因为费用通常是基于通话时长计算的。

（2）通话效率： 大多数客户群体的气泡分布在图表中央的矩形区域，显示出时长和次数之间没有单一的强线性关系。这意味着客户的平均夜间通话时长差异很大（有些人通话次数少但每次通话时间长，有些人则相反）。

（3）业务洞察： 费用（气泡大小）主要由时长决定，而非次数。如果夜间费用异常高昂的客户同时具有较高的通话次数，可能表明他们在夜间有强烈的未满足需求或正在经历糟糕的服务质量（需要多次重拨）。

（六）Total Day Minutes 与流失的关系

1、目标：分析白天通话时长的中位数在流失 (Yes) 和未流失 (No) 客户之间是否存在显著差异。

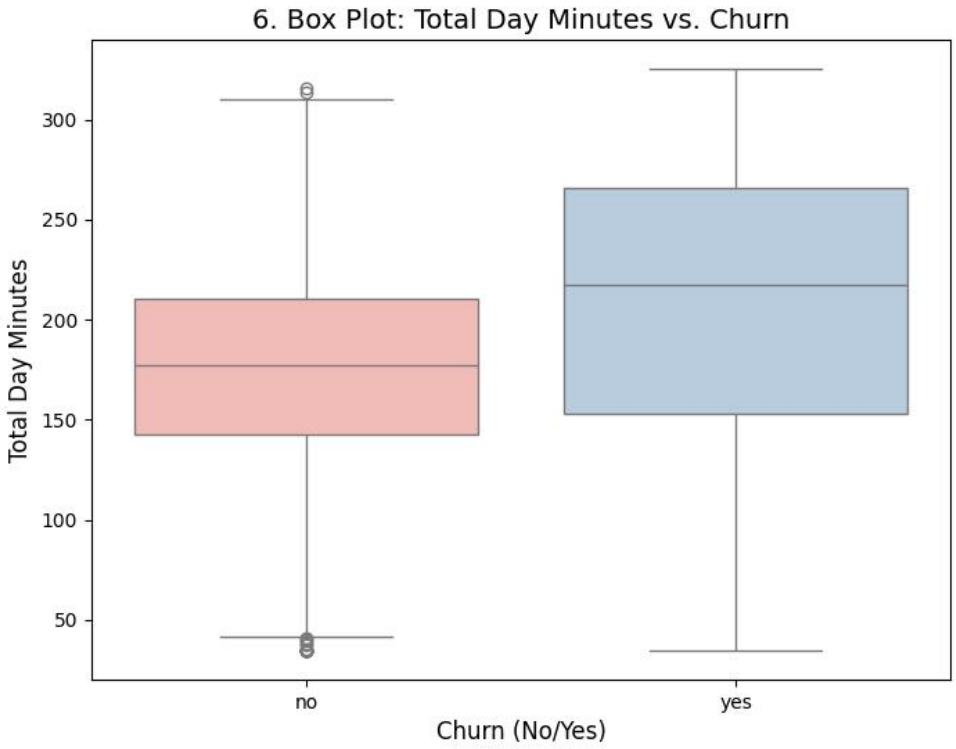

图 3-6:Total Day Minutes 与流失的关系

2、简要分析

（1）中位数差异： 流失客户 (Yes) 的白天通话时长中位数明显高于未流失客户 (No)。

（2）离散程度： 流失客户的箱体整体向高分钟数移动。

（3）核心洞察： 白天通话时长越长的客户，其流失的风险越高。这是一个强烈的流失预测指标。

（七）国际套餐 (International Plan) 对流失的影响

1、目标：直观比较有国际套餐和没有国际套餐的客户群体中，流失率的差异，且该图表展示的是流失的绝对人数，而非流失比例。

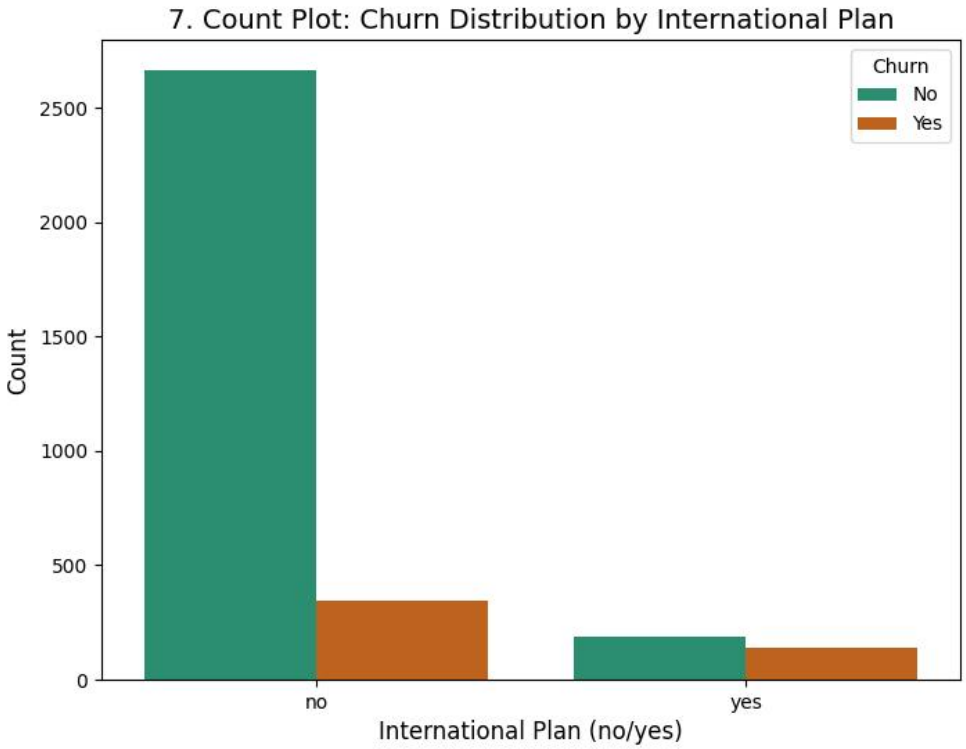

图 3-7:国际套餐与流失的绝对人数的关系

2、简要分析

（1）无套餐客户 (No)： 在未开通国际套餐 (International Plan = No) 的客户群体中，流失率极低。流失客户所占的比例非常小，表明这部分客户群体的基础服务满意度高，黏性强。

（2）有套餐客户 (Yes)： 在开通国际套餐 (International Plan = Yes) 的客户群体中，流失人数的比例远远高于未流失人数的比例。这意味着，拥有国际套餐的客户，其流失风险是未拥有套餐客户的数倍。

（3）核心洞察： 国际套餐是客户流失最强大的预测因子。高流失率强烈暗示公司的国际服务在定价、服务质量或连接稳定性方面存在严重问题，使其客户成为竞争对手的重点目标。对策应立即集中于优化国际套餐的性价比和提升服务体验。

（八）客服电话次数 (Customer Service Calls) 对流失的影响

1、目标: 分析客户拨打客服电话的次数与其流失状态之间的关系，评估客户满意度。

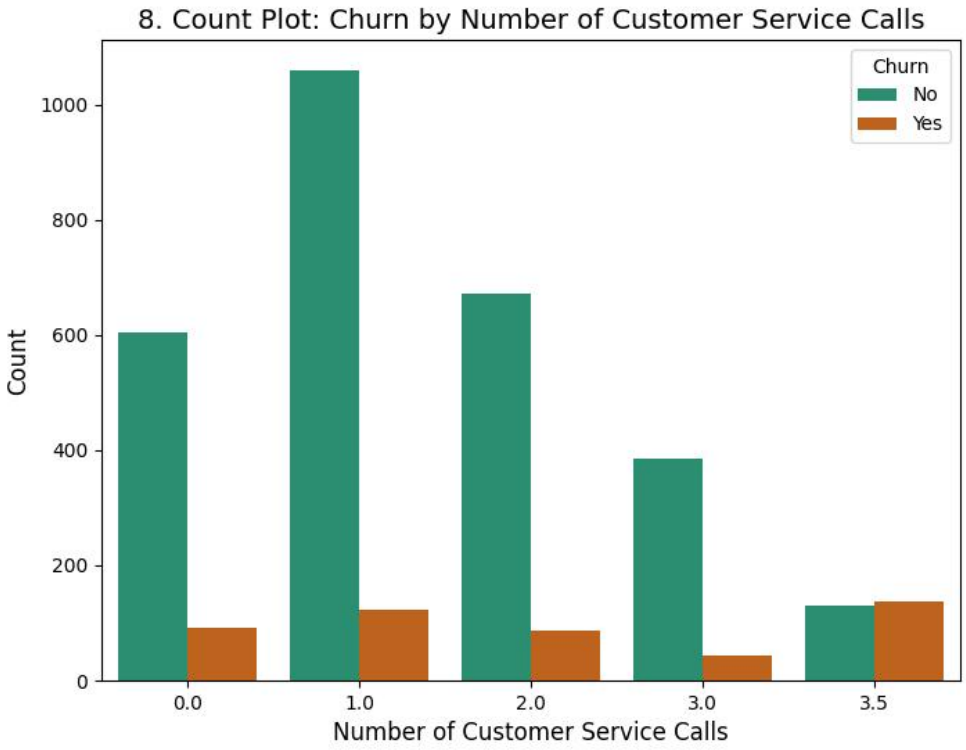

图 3-8:客服电话次数与流失的绝对人数的关系

2、简要分析

（1）低次数 (0-3 次)： 拨打客服电话 0 到 3 次的客户，流失率非常低。

（2）高次数 (4 次及以上)： 客服电话次数一旦达到 4 次或更多，流失人数（红色条）就开始急剧增加并超过未流失人数（蓝色条）。

（3）核心洞察： 客服电话次数是流失的强力预测信号，4 次或更多次的联系表明客户满意度极低。

四、总结与建议

（一）最终模型选择

1、结论：推荐选择 CatBoost 模型作为流失预警系统的主力模型。
2、理由： CatBoost 提供了最高的召回率 (0.8351) 和 F1-Score (0.8901)。在流失预测业务中，召回率（捕获能力）至关重要，因为错过一个潜在流失客户的损失远大于误挽留一个非流失客户的成本。

（二）针对性商业建议

1、基于特征重要性分析，现提出以下三项高优先级挽留策略。

表 4-1:对于电信客户流失的策略和建议

风险因素	业务洞察	具体策略和建议
1. 国际套餐	未开通国际套餐是流失的**最强信号**，表明现有套餐无法满足其需求。	**定制化零门槛国际包：** 识别有少量国际通话记录但未开通套餐的客户，**免费试用**或**极低月费**提供国际通话分钟包，消除其主要痛点。
2. 日间高费用	`total_day_charge` 是第二大重要因素，高额费用直接导致不满。	**智能费用提醒与升级：** 对预测为高风险且日间费用持续高昂的客户，推送**更经济的套餐推荐**，或在账单中突出显示升级套餐后的潜在节省金额。
3. 客服呼叫次数	高频次呼叫客服（≥ 4 次）是流失的关键前兆，反映了**服务满意度低**。	**VIP 主动关怀机制：** 对呼叫客服次数达到阈值（如 3 次）的高风险客户，立即由**高级客服专员**进行**主动回访**，跟进未解决的问题，将负面体验转化为积极挽留机会。

2、未来改进方案
（1）特征交互深化： 重点探索 total_day_charge 与 number_customer_service_calls 等高风险特征的交互项，以发现“高费用 + 服务不满”的流失组合。
（2）模型融合（Stacking）： 尝试将 XGBoost 和 CatBoost 的预测结果作为元特征，训练一个更稳健的二级模型，以最大化集成学习的优势。
（3）时序分析（针对未来数据）： 引入客户消费行为的时间序列数据（例如过去三个月的使用趋势），并重新应用 LSTM 等深度学习模型，以充分发挥其在序列数据处理上的优势。