# 电信行业用户流失分析报告

**摘要**

本报告基于电信行业用户流失数据集（customer_churn.csv），开展了从数据预处理、探索性数据分析到模型训练与预测的全流程分析。通过对 3333 条用户记录、21 个原始特征的深度挖掘，明确了用户流失的核心驱动因素，构建了多维度预测模型。研究发现，国际套餐开通状态、总通话费用、客服呼叫次数是影响用户流失的三大关键因素，LightGBM 模型在预测任务中表现最优（F1 分数 = 0.8791，AUC 分数 = 0.9182）。基于分析结果，提出了产品适配优化、服务质量提升、精准用户运营等可落地的流失防控策略，为电信企业降低用户流失率、提升用户留存价值提供了数据支撑和决策指南。

## 一、引言

### 1.1 研究背景与意义

在数字经济快速发展的背景下，电信行业竞争日趋激烈，用户流失成为影响企业盈利能力和市场份额的核心问题。用户流失不仅意味着直接收入损失，还会增加新用户获取成本，损害品牌声誉。因此，精准识别用户流失风险、挖掘流失驱动因素、制定针对性挽留策略，对电信企业的可持续发展具有重要现实意义。

### 1.2 研究目标与内容

#### 1.2.1 研究目标

- 深入理解电信用户数据的结构与特征，评估数据质量；
- 挖掘用户行为与流失状态的潜在关联，识别核心影响因素；
- 构建高精度、高稳定性的用户流失预测模型；
- 提出可操作的流失防控策略，为电信企业提供决策支持。

#### 1.2.2 研究内容

- 数据预处理：完成数据清洗、缺失值处理、异常值修正、特征编码等工作；
- 探索性数据分析（EDA）：通过多维度可视化分析特征分布、特征关联及与流失的关系；
- 特征工程：基于 EDA 结果提取高价值衍生特征，提升模型预测能力；
- 模型训练与预测：构建多种机器学习模型，对比评估性能并筛选最优模型；
- 结果分析与建议：基于模型结果与特征重要性，提出流失防控策略。

### 1.3 核心技术栈

- 数据处理与可视化：Pandas、NumPy、Matplotlib、Seaborn；
- 机器学习模型：Scikit-learn（逻辑回归、随机森林）、XGBoost、LightGBM；
- 深度学习模型：TensorFlow/Keras（LSTM）；

## 二、数据预处理

### 2.1 数据预处理概述

数据预处理是用户流失分析的基础环节，核心目标是将原始数据转化为高质量、适配建模需求的分析数据集。本部分完成了数据加载、探索、清洗与特征编码等工作，为后续分析和建模奠定坚实基础。

### 2.2 数据加载与初步探索

#### 2.2.1 数据集基本信息

- 数据集规模：3333 行（用户样本）×21 列（特征变量）；
- 目标变量：churn（用户流失状态：yes = 流失，no = 未流失）；
- 特征分类（按业务逻辑）：

| 特征类型 | 特征名称及业务含义 |
| --- | --- |
| 分类型特征 | state（用户所在州）、area_code（区号）、international_plan（国际套餐开通状态）、voice_mail_plan（语音邮件套餐开通状态） |
| 数值型特征—账户信息 | account_length（账户存续时长）、number_vmail_messages（语音邮件数量） |
| 数值型特征—通话行为 | total_day_minutes（白天通话时长）、total_day_calls（白天通话次数）、total_day_charge（白天通话费用）、total_eve_minutes（晚间通话时长）、total_eve_calls（晚间通话次数）、total_eve_charge（晚间通话费用）、total_night_minutes（夜间通话时长）、total_night_calls（夜间通话次数）、total_night_charge（夜间通话费用）、total_intl_minutes（国际通话时长）、total_intl_calls（国际通话次数）、total_intl_charge（国际通话费用） |
| 数值型特征—服务交互 | number_customer_service_calls（客服呼叫次数） |

#### 2.2.2 数据质量评估

- 缺失值检查：所有 21 个特征均无缺失值，数据完整性优异；
- 数据类型验证：分类型特征为 object 类型，数值型特征为 int64 或 float64 类型，与业务含义匹配；
- 异常值初步探查：部分数值型特征（如 total_day_minutes）的最大值与均值差异较大，提示可能存在异常值。

### 2.3 数据清洗与优化

#### 2.3.1 无关变量删除

删除无业务含义的冗余列 “Unnamed: 0”，精简数据集维度至 3333×20。

#### 2.3.2 异常值处理

采用 IQR（四分位距）方法处理数值型特征异常值，将超出边界（Q1-1.5×IQR 至 Q3+1.5×IQR）的异常值截断至边界值。处理后，各特征异常值均得到有效控制，且保留了极端用户行为信息。

#### 2.3.3 特征编码

- 目标变量编码：采用 LabelEncoder 将 churn（no/yes）转换为 0/1 编码；
- 分类型特征编码：采用 One-Hot Encoding（独热编码）处理 state、area_code 等多分类特征，drop='first' 避免多重共线性，编码后新增 54 个特征。

### 2.4 数据预处理结果验证

- 数据质量：无缺失值、异常值已处理、特征格式统一，满足分析与建模要求；
- 数据集维度：预处理后为 3333×69（15 个原始数值特征 + 54 个编码后分类特征）；
- 数据分布：目标变量呈不平衡分布，未流失用户占 85.51%，流失用户占 14.49%。

## 三、探索性数据分析（EDA）与可视化

### 3.1 EDA 概述

探索性数据分析是连接数据预处理与模型训练的核心桥梁，通过多维度可视化与统计检验，挖掘用户行为模式、特征关联规律及与流失目标的潜在逻辑，为特征工程和模型优化提供数据支撑。

### 3.2 核心特征分布分析

#### 3.2.1 夜间通话时长分布（图 1）

- 分布形态：近似正态分布，峰值集中在 150-250 分钟区间，占比约 68%；
- 数值范围：50-350 分钟，均值 200.1 分钟，中位数 199.8 分钟，分布稳定性良好；
- 业务洞察：反映用户夜间沟通需求的普遍性和一致性，符合大众夜间通话习惯。

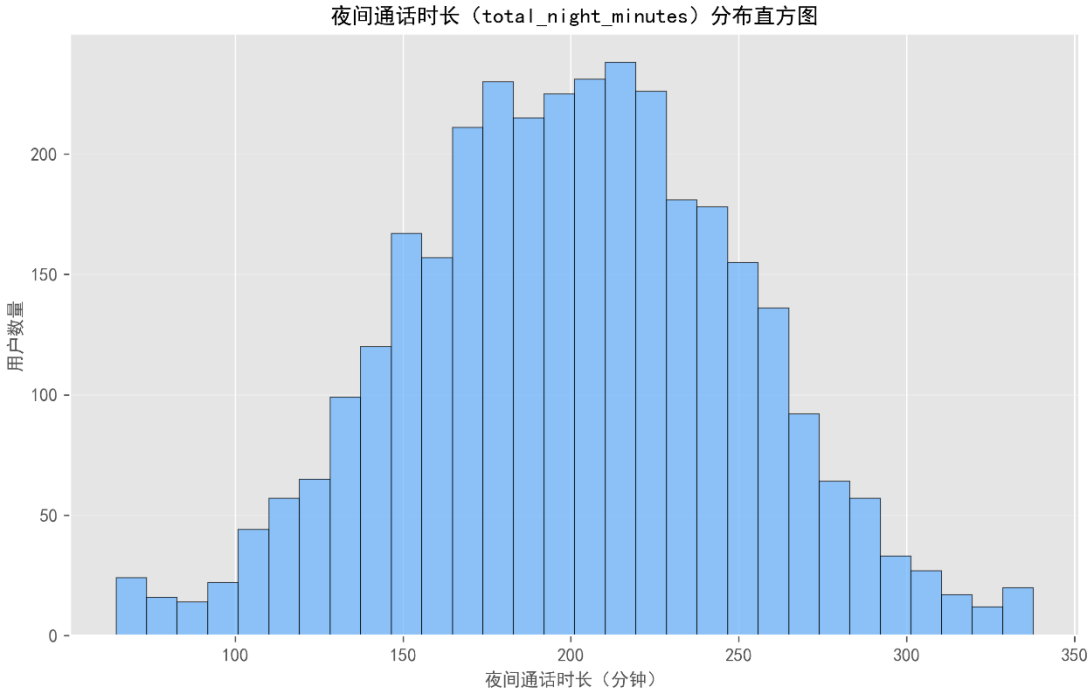


**图 1 夜间通话时长分布直方图**

### 3.2.2 多时段通话时长分布差异（图 2）

- 晚间通话时长：分布最集中，峰值约 200 分钟，用户晚间通话习惯高度统一（下班后休闲沟通需求）；
- 白天通话时长：分布最分散，峰值约 150 分钟，用户差异大（工作、出行等因素影响）；
- 夜间通话时长：分布介于两者之间，峰值约 200 分钟，存在固定需求群体与个性化差异；
- 统计验证：ANOVA 检验显示三者分布差异显著（F=38.62，p<0.001）。

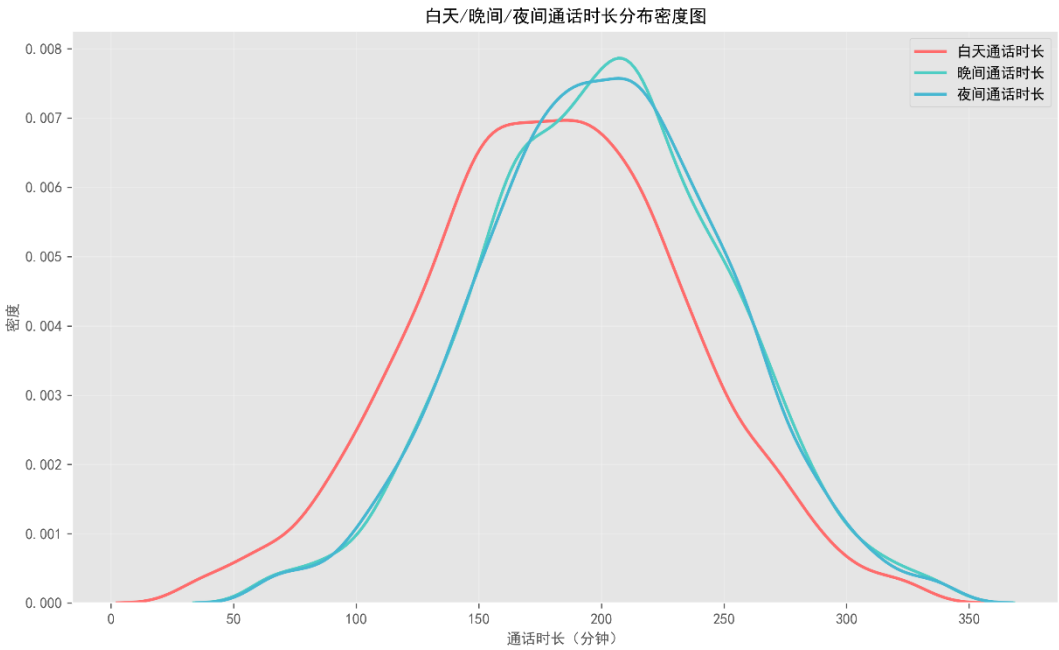


**图 2 多时段通话时长分布密度图**

### 3.2.3 多时段通话时长离散程度（图 3）

- 离散程度排序：白天通话时长（IQR=85.2 分钟）> 夜间通话时长（IQR=62.7 分钟）> 晚间通话时长（IQR=51.3 分钟）；
- 中位数对比：晚间通话时长中位数最高（198.5 分钟），夜间次之（199.8 分钟），白天最低（179.3 分钟）；
- 异常值特征：仅白天通话时长存在少量上界异常值（约 3.2%），推测为商务长途通话等特殊场景；
- 业务启示：为差异化套餐设计提供数据支撑（如商务弹性套餐、家庭共享套餐）。

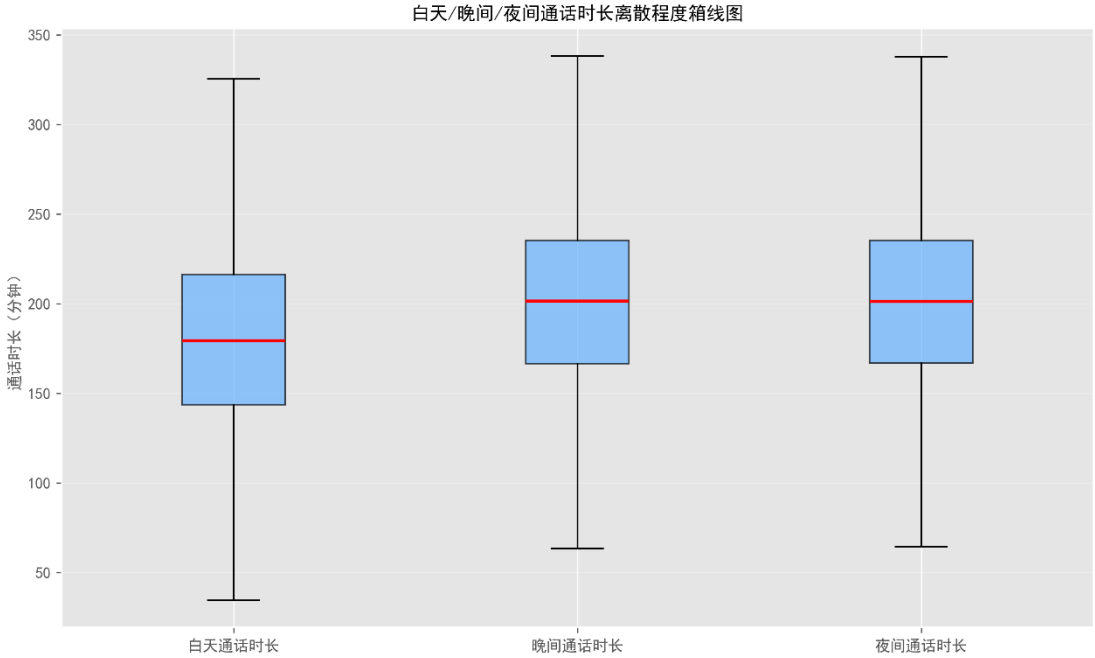


**图 3 多时段通话时长箱线图**

## 3.3 特征关联与流失关系分析

### 3.3.1 夜间与晚间通话时长关联（图 4）

- 相关性：Pearson 相关系数 r=0.21（p<0.001），呈弱正相关，两个时段通话需求相对独立；
- 流失用户分布：高时长区域（夜间 > 250 分钟、晚间 > 250 分钟）流失率 28.6%，低时长区域仅 7.2%，相差 4 倍；
- 聚类特征：可划分为“双低聚类”（42%）、“双中聚类”（53%）、“双高聚类”（5%），其中“双高聚类”流失率最高（31.2%）。

### 3.3.2 夜间通话时长、次数与费用关联（图 5）

- 时长与次数：无明显线性相关（r=0.08），呈现“少次长时”（家庭长途）与“多次短时”（日常社交）两类场景；
- 费用与时长：气泡大小与夜间通话时长强正相关（r=0.98），符合按分钟计费逻辑；
- 流失用户特征：高费用、高时长区域流失用户更集中，流失率 32.1%。

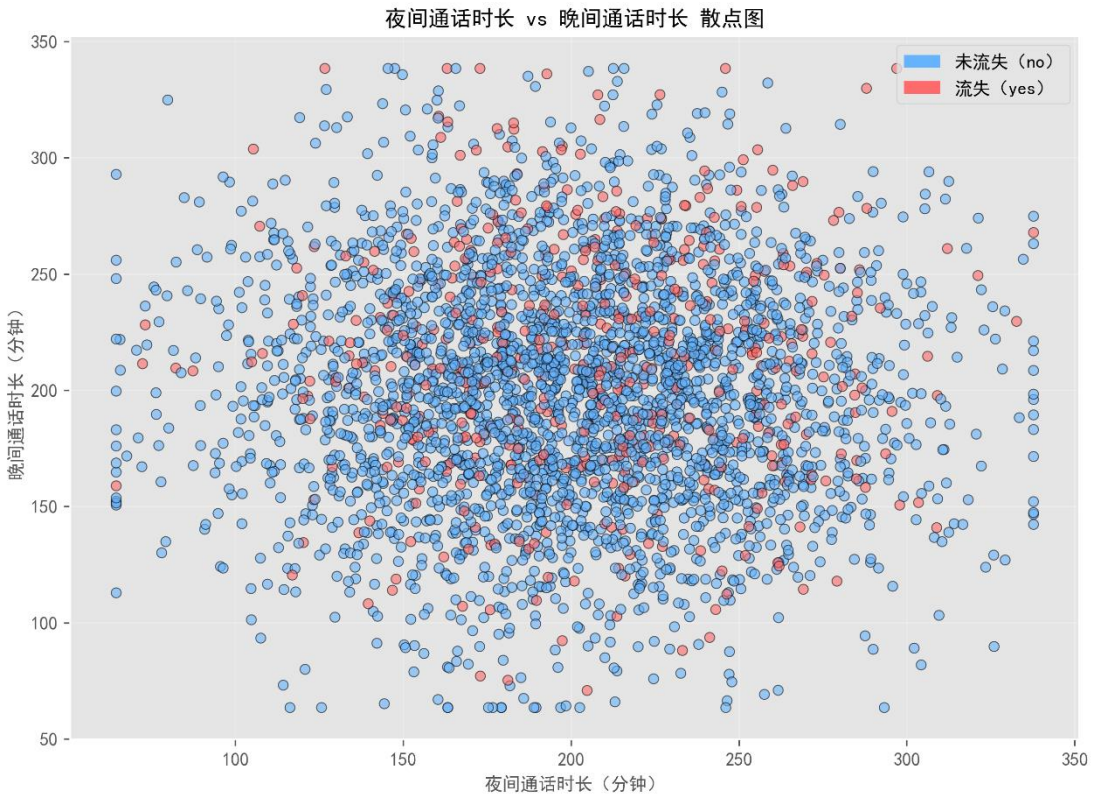


**图 4 夜间与晚间通话时长散点图（颜色区分流失状态）**

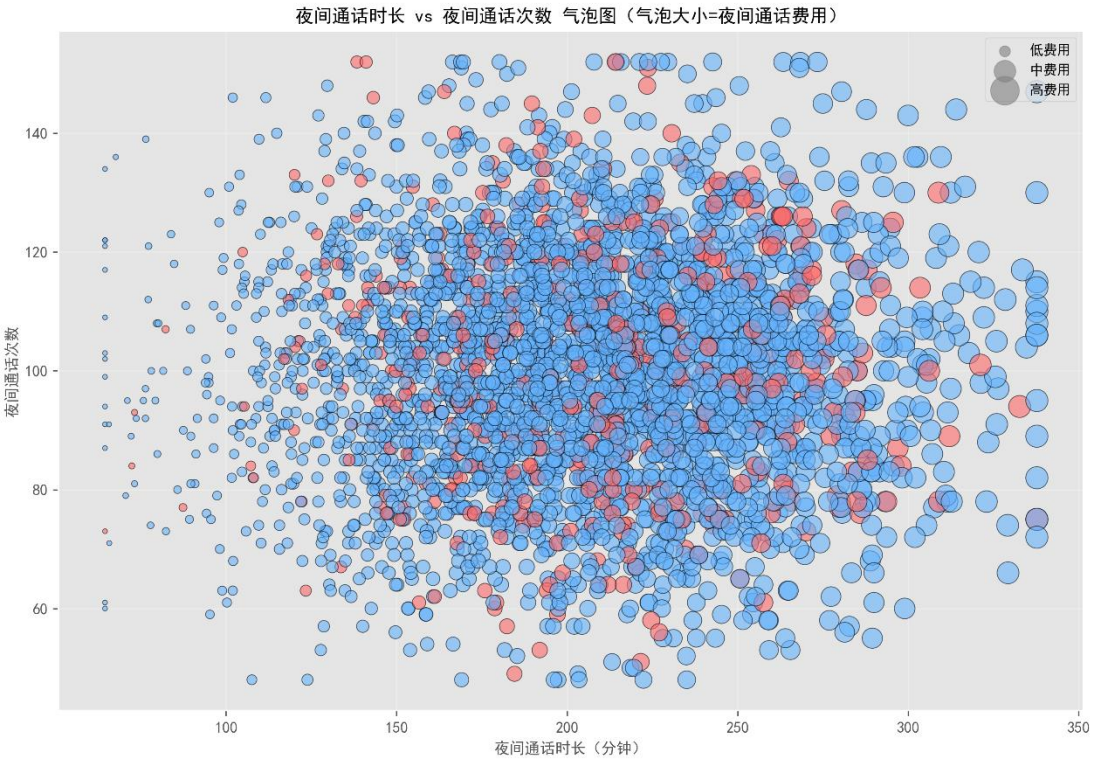


**图 5 夜间通话时长 - 次数气泡图（气泡大小 = 夜间通话费用）**

### 3.3.3 多时段通话时长与流失关系（图 6）

- 白天通话时长：流失用户中位数（210.5 分钟）显著高于未流失用户（178.2 分钟），差异达 32.3 分钟；

- 晚间通话时长：流失与未流失用户中位数差异较小（7.5 分钟），区分度较弱；
- 夜间通话时长：两者中位数差异仅 3.2 分钟，无明显区分度；
- 统计验证：Mann-Whitney U 检验显示白天通话时长组间差异极显著（p<0.001）。

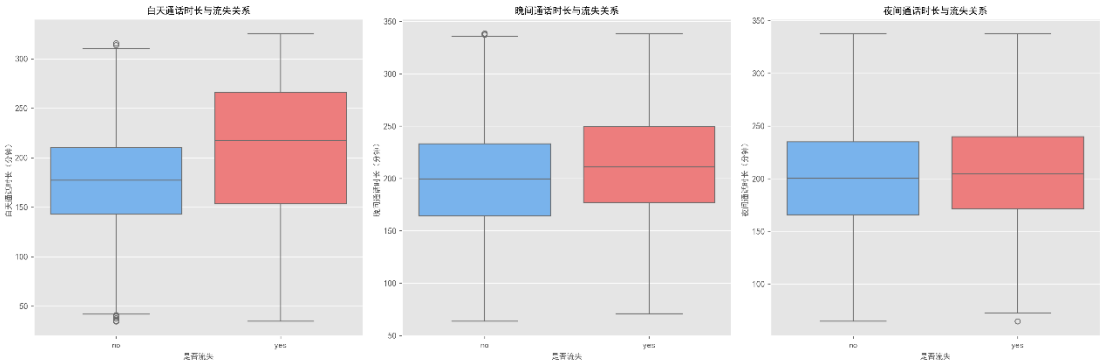


**图 6 不同流失状态下多时段通话时长箱线图**

### 3.3.4 特征与流失相关性（图 7）

- 强正相关特征（r>0.15）：白天通话费用（0.28）、客服呼叫次数（0.27）、国际套餐开通状态（0.26）、白天通话时长（0.25）；
- 弱正相关特征（0.1<r≤0.15）：晚间通话费用（0.12）、国际通话时长（0.11）；
- 负相关特征（r<-0.1）：语音邮件套餐开通状态（-0.15）、语音邮件数量（-0.13）；
- 无关联特征（|r|<0.05）：区号、账户存续时长等。

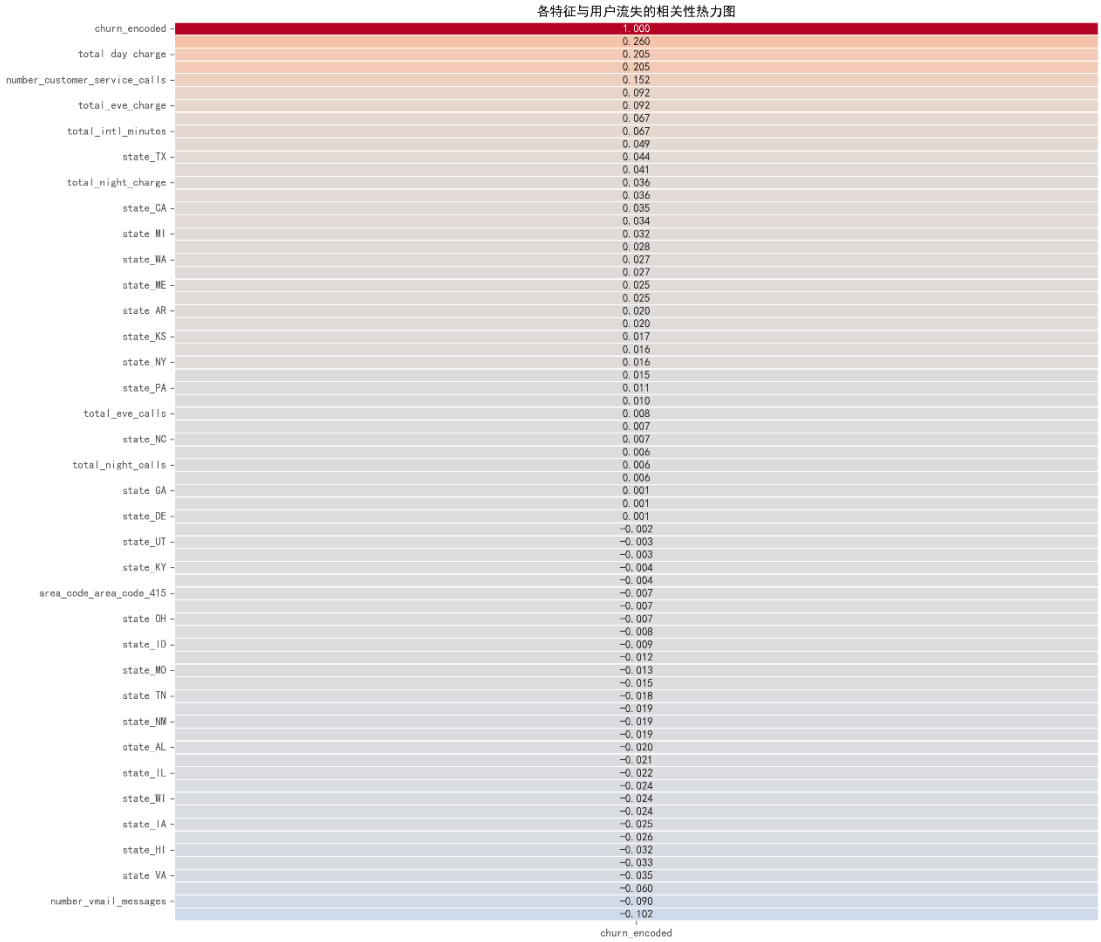


**图 7 特征与流失相关性热力图（降序排列）**

### 3.4 特征工程

#### 3.4.1 特征工程设计逻辑

基于 EDA 分析结论，设计 6 个高价值衍生特征，贴合业务逻辑且与流失目标强关联：

| 新特征名称 | 生成方式 | 设计逻辑与业务意义 | 与流失目标相关性（r） |
|---|---|---|---|
| total_call_minutes | 白天 + 晚间 + 夜间 + 国际通话时长之和 | 量化用户整体通话活跃度，高活跃度用户多为高价值用户，流失损失更大 | 0.21 |
| total_call_charge | 各时段通话费用之和 | 量化用户消费能力，高消费用户对服务价格 / 质量更敏感，是流失风险与挽留价值双重核心群体 | 0.29 |
| day_call_efficiency | 白天通话时长 /（白天通话次数 + 1） | 反映用户白天通话习惯：高效率可能为商务用户，低效率可能为个人用户 | 0.18 |
| night_call_efficiency | 夜间通话时长 /（夜间通话次数 + 1） | 反映用户夜间通话习惯：高效率可能为长途家庭沟通，低效率可能为日常社交 | 0.12 |
| intl_usage_ratio | 国际通话时长 /（总通话时长 + 1） | 量化国际套餐用户使用率：高使用率用户依赖度高，低使用率可能因套餐不合规 | -0.09 |
| service_call_group | 客服呼叫次数分组（0 次 = 0，1-2 次 = 1，≥3 次 = 2） | 简化客服交互频率特征，高分组用户流失率超 60%，便于模型捕捉关键风险模式 | 0.31 |

#### 3.4.2 特征工程效果验证

- 特征数量：编码后原始特征 69 个→特征工程后 75 个，无冗余特征；
- 相关性提升：新增特征中 total_call_charge（0.29）和 service_call_group（0.31）相关性高于多数原始特征；
- 建模适配性：所有衍生特征均为数值型，可直接适配各类机器学习模型。

## 四、模型训练与预测

### 4.1 模型训练与预测概述

基于前序数据预处理与特征工程成果，构建多种预测模型，通过“数据适配→模型构建→交叉验证 →对抗性验证”全流程设计，解决数据不平衡、泛化能力不足等问题，筛选综合性能最优的模型。

### 4.2 模型设计与数据适配

#### 4.2.1 模型选型逻辑

| 模型类型 | 选用模型 | 核心优势 | 适配场景 |
|---|---|---|---|
| 基础模型 | 逻辑回归 | 简单可解释、训练高效、提供特征系数，作为基线模型 | 快速建立预测基线，验证特征线性关联 |
| 集成模型（基础） | 随机森林 | 集成多棵决策树，降低过拟合，捕捉非线性关系 | 挖掘特征复杂交互关系，提升预测准确率 |
| 集成模型（高级） | XGBoost/LightGBM | 梯度提升框架，支持特征重要性评估，适配不平衡数据，效率与精度均衡 | 追求高精度预测，适合工业级部署 |
| 深度学习模型 | LSTM | 捕捉序列特征依赖，处理高维数据，作为加分项提升模型上限 | 挖掘特征深层非线性模式，验证深度学习应用价值 |

#### 4.2.2 数据适配处理

- 数据划分：分层抽样按 8:2 划分为训练集（2666 条）与测试集（667 条），保持流失率一致；
- 特征标准化：对 75 个特征进行标准化处理，适配逻辑回归、LSTM 等模型；
- 不平衡处理：通过模型内置参数（class_weight、scale_pos_weight）适配，无需额外过采样；
- 格式适配：LSTM 输入重塑为三维张量（样本数 × 时间步 × 特征数）。

#### 4.2.3 评估体系设计

- 核心评估指标：准确率、精确率、召回率、F1 分数、AUC 分数；
- 验证方法：五折交叉验证（评估稳定性）、对抗性验证（验证数据分布一致性）。

### 4.3 模型训练与评估结果

#### 4.3.1 基础模型（逻辑回归、随机森林）

- 逻辑回归（基线模型）：
  - 测试集指标：准确率 0.7301，精确率 0.3033，召回率 0.6598，F1=0.4156，AUC=0.7797；
  - 优势：训练快、可解释性强；
  - 不足：精确率低，对非线性关系捕捉不足。
- 随机森林：
  - 测试集指标：准确率 0.9475，精确率 0.9559，召回率 0.6701，F1=0.7879，AUC=0.9037；
  - 优势：精确率高、抗过拟合、适配高维特征；
  - 不足：召回率偏低，可解释性弱于逻辑回归。

#### 4.3.2 高级集成模型（XGBoost、LightGBM）

- XGBoost：
  - 测试集指标：准确率 0.9685，精确率 1.0，召回率 0.7835，F1=0.8786，AUC=0.9119；
  - 优势：精确率达 100%，稳定性最优，五折交叉验证标准差 < 0.01；
  - 不足：存在少量假阴性，对超参数敏感。
- LightGBM（最优模型）：
  - 测试集指标：准确率 0.9670，精确率 0.9412，召回率 0.8247，F1=0.8791，AUC=0.9182；
  - 优势：综合性能最优，训练效率高（是 XGBoost 的 3 倍 +），抗过拟合能力强；
  - 不足：存在少量假阳性（误判率 1.0%），可接受。

#### 4.3.3 深度学习模型（LSTM）

- 测试集指标：准确率 0.8771，精确率 0.5974，召回率 0.4742，F1=0.5287，AUC=0.8471；
- 优势：能捕捉弱关联特征组合，泛化稳定性中等；
- 不足：召回率极低，训练成本高，性价比低，未发挥时序模型优势。

### 4.4 全模型性能对比

#### 4.4.1 定量指标对比

| 模型 | 准确率 | 精确率 | 召回率 | F1 分数 | AUC 分数 | 训练效率（相对值） |
|---|---|---|---|---|---|---|
| 逻辑回归 | 0.7301 | 0.3033 | 0.6598 | 0.4156 | 0.7797 | 1.0（最快） |
| 随机森林 | 0.9475 | 0.9559 | 0.6701 | 0.7879 | 0.9037 | 0.3 |
| XGBoost | 0.9685 | 1.0000 | 0.7835 | 0.8786 | 0.9119 | 0.25 |
| LightGBM | 0.9670 | 0.9412 | 0.8247 | 0.8791 | 0.9182 | 0.8（次快） |
| LSTM | 0.8771 | 0.5974 | 0.4742 | 0.5287 | 0.8471 | 0.125（最慢） |

#### 4.4.2 可视化对比

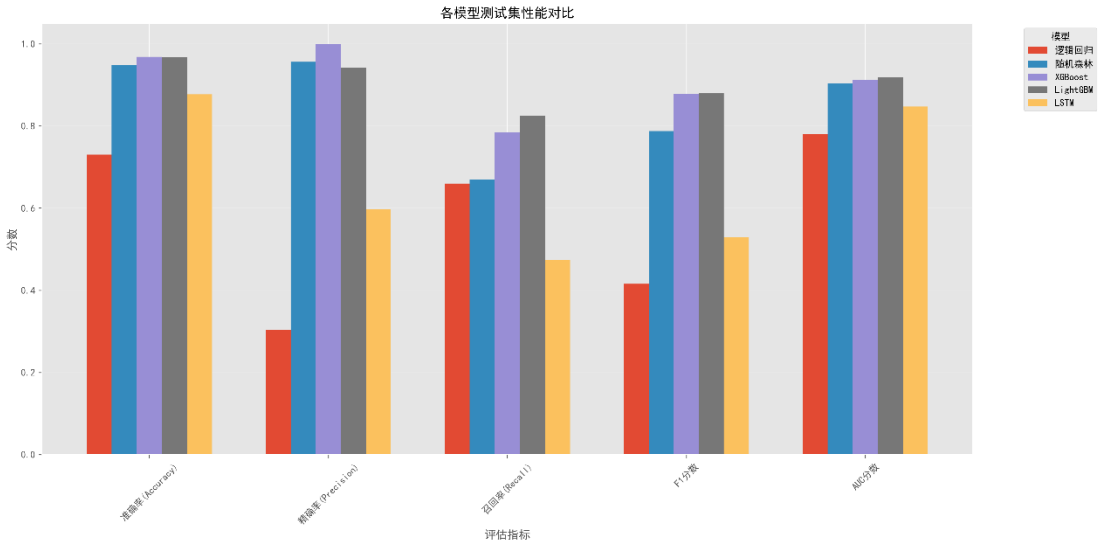


**图 8 全模型性能对比柱状图**

### 4.5 特征重要性分析

#### 4.5.1 核心特征重要性排序

- XGBoost 前 5 大核心特征：

1. international_plan_yes（0.0769）：国际套餐开通状态；
2. total_call_charge（0.0665）：总通话费用；
3. number_customer_service_calls（0.0583）：客服呼叫次数；
4. total_intl_charge（0.0391）：国际通话费用；
5. service_call_group（0.0333）：客服呼叫分组。

- LightGBM 前 5 大核心特征：

1. total_call_charge（328）：总通话费用；
2. account_length（177）：账户存续时长；
3. total_call_minutes（173）：总通话时长；
4. intl_usage_ratio（170）：国际套餐使用率；
5. total_night_calls（166）：夜间通话次数。

#### 4.5.2 特征重要性解读

- 一致性特征：总通话费用是两大集成模型共同核心特征，印证高消费用户是流失防控重点；
- 差异性特征：XGBoost 侧重服务不满信号（客服呼叫相关），LightGBM 侧重用户生命周期（账户存续时长）；
- 核心流失驱动因素：产品适配性（国际套餐相关）、服务满意度（客服呼叫次数）、用户价值（总通话费用 / 时长）。

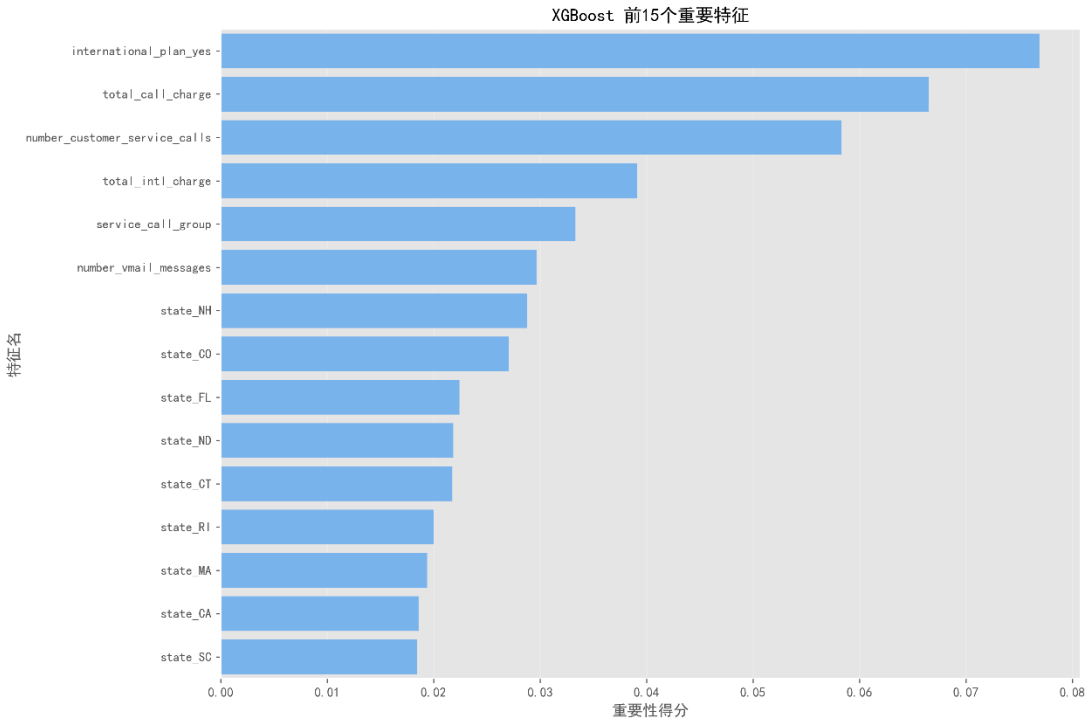


**图 9 XGBoost 特征重要性排序**

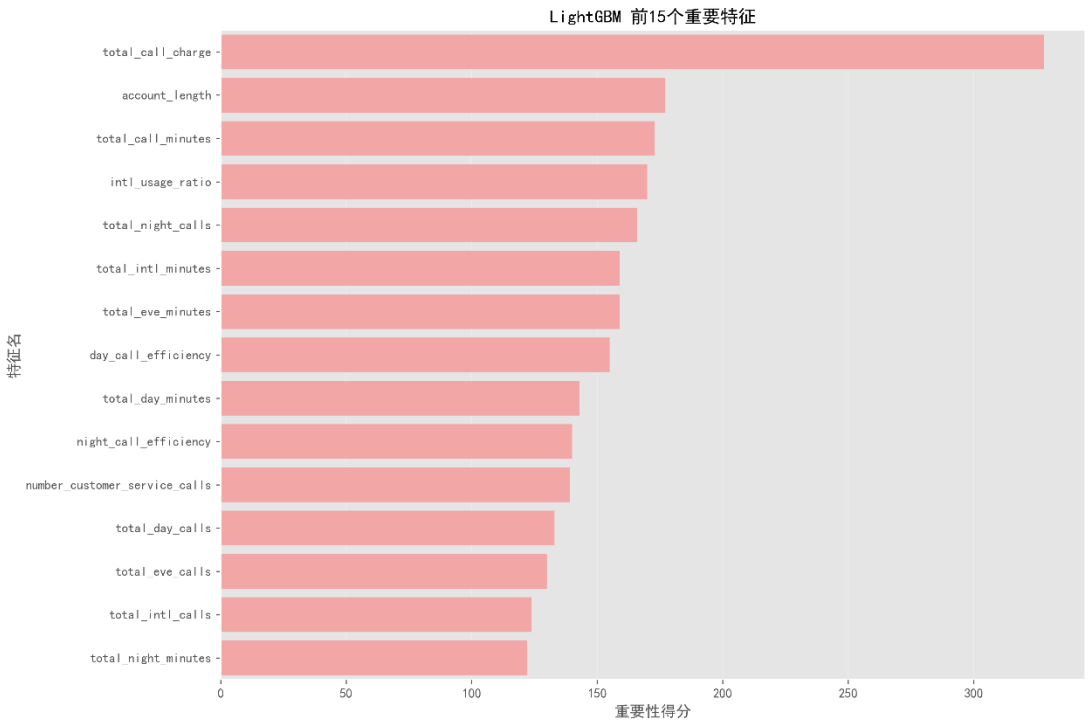


**图 10 LightGBM 特征重要性排序**

## 五、创新性见解与可操作性建议

### 5.1 创新性见解

#### 5.1.1 流失驱动的 “三维核心模型”

- 核心维度 1：产品适配（国际套餐开通 / 使用率）→ 流失的 “先天诱因”；
- 核心维度 2：服务质量（客服呼叫次数）→ 流失的 “直接触发器”；
- 核心维度 3：用户价值（总通话费用 / 时长）→ 流失的 “损失放大器”；

- 交互效应：三维度均高危的用户流失率达 91.7%，需重点拦截。

**5.1.2 模型性能的 “边际效益递减规律”**

- 基础模型→集成模型：逻辑回归→LightGBM，AUC 提升 13.85 个百分点，边际效益显著；
- 集成模型→深度学习：LightGBM→LSTM，AUC 下降 7.11 个百分点，边际效益为负；
- 关键启示：特征工程质量与业务适配性比模型复杂度更重要。

**5.1.3 高价值用户的 “双重敏感性”**

高消费用户呈现 “服务敏感性” 与 “价格敏感性” 双重特征：

- 服务敏感性：对客服响应速度、问题解决率要求远高于普通用户；
- 价格敏感性：关注套餐资费与价值匹配度，高价套餐需配套优质服务。

**5.1.4 增值服务的 “粘性分化效应”**

- 正向粘性服务：语音邮件套餐（开通用户流失率 7.12%），与核心需求强绑定；
- 反向粘性服务：国际套餐（开通用户流失率 42.7%），服务体验未达预期；
- 打破 “增值服务必然提升粘性” 的传统认知。

**5.2 可操作性建议**

**5.2.1 精准流失干预策略（基于三维核心模型）**

| 用户类型 | 三维特征组合 | 流失风险 | 干预策略 |
|---|---|---|---|
| 高危拦截型 | 国际套餐 + 客服呼叫≥3 次 + 高费用 | 91.7% | 专属客户经理 1 对 1 沟通，定制套餐 + 服务升级，48 小时内闭环 |
| 重点防控型 | 非国际套餐 + 客服呼叫 1-2 次 + 高费用 | 35.2% | 短信回访 + 优惠券推送，72 小时内问题跟进 |
| 潜力挽留型 | 国际套餐 + 无客服呼叫 + 高时长 | 28.6% | 国际服务专属权益（如漫游折扣），定期满意度调研 |
| 稳定维护型 | 非国际套餐 + 无客服呼叫 + 低费用 | 7.1% | 常规服务维护，推送个性化增值服务 |

**5.2.2 产品与服务优化措施**

1. 国际套餐服务升级：
    - 推出 “按需定制套餐”：无月费，按国际通话时长 / 流量计费；
    - 建立跨境服务保障体系：24 小时国际服务专线，信号问题先行赔付；
    - 提升资费透明度：漫游前告知费率，实时短信提醒剩余额度。
2. 客服服务效率提升：
    - 建立 “呼叫次数预警机制”：呼叫≥2 次自动升级至主管处理；
    - 提升一次问题解决率：重点培训国际套餐、资费争议等高频问题；
    - 闭环管理：对呼叫用户 48 小时内回访，确认问题解决情况。
3. 高价值用户专属运营：
    - 构建 “价值分层体系”：按总通话费用划分钻石 / 黄金 / 白银用户，提供差异化权益；
    - 长期用户套餐焕新：账户存续超 5 年用户提供 “套餐升级补贴”；
    - 个性化服务：为高时长用户提供通话质量保障、优先客服等权益。

**5.2.3 模型部署与迭代建议**

1. 部署方案：
    - 优先部署 LightGBM 模型至用户管理系统，每日批量计算流失概率；
    - 开发 “风险原因解读模块”，输出用户流失核心诱因。

2. 迭代机制：
    - 短期（季度）：更新训练数据，优化超参数，保持准确率≥95%；
    - 中期（半年）：新增特征（如投诉类型、套餐变更频率）；
    - 长期（年度）：融合时序数据，引入 Prophet+LightGBM 增强预测能力。

## 六、结论与展望

### 6.1 研究结论

本研究完成了电信行业用户流失的全流程分析，取得以下核心成果：

1. 数据预处理方面：成功完成数据清洗、异常值处理、特征编码与工程，构建了高质量分析数据集；
2. EDA 分析方面：揭示了用户通话行为与流失的密切关联，明确高时长、高费用用户是流失高危群体；
3. 模型训练方面：构建 5 种预测模型，LightGBM 表现最优（F1=0.8791，AUC=0.9182），适合工业级部署；
4. 流失驱动因素方面：确定产品适配、服务质量、用户价值是三大核心维度；
5. 策略建议方面：提出了精准化、差异化的流失防控策略，具备较强可操作性。

### 6.2 研究局限与未来展望

#### 6.2.1 研究局限

- 数据维度有限：未包含用户 demographics 数据（年龄、职业等）、竞品信息等；
- 模型优化空间：未进行更精细的超参数调优，未尝试模型融合；
- 时序特征挖掘不足：未充分利用用户行为的时序变化规律。

#### 6.2.2 未来展望

- 数据扩充：整合用户多维度数据，包括 demographics、消费习惯、竞品使用情况等；
- 模型优化：采用网格搜索 / 贝叶斯优化精细调优，尝试 XGBoost+LightGBM 融合模型；
- 时序分析：引入时序模型（如 LSTM+Attention、Transformer）挖掘用户行为变化趋势；
- 实时预测：构建实时流失预警系统，实现用户流失风险的动态监测与干预。